

RESOLUCIÓN AUTOMÁTICA DE EXÁMENES
DE COMPRENSIÓN LECTORA EN ESPAÑOL
MEDIANTE LLMs

AUTOMATIC RESOLUTION OF SPANISH
READING COMPREHENSION EXAMS USING
LLMs



TRABAJO FIN DE MÁSTER
CURSO 2025-2026

AUTOR

PABLO FOLGUEIRA GALÁN

DIRECTOR

ALBERTO DÍAZ ESTEBAN

MÁSTER EN INTELIGENCIA ARTIFICIAL
FACULTAD DE INFORMÁTICA
UNIVERSIDAD COMPLUTENSE DE MADRID

RESOLUCIÓN AUTOMÁTICA DE EXÁMENES
DE COMPRENSIÓN LECTORA EN ESPAÑOL
MEDIANTE LLMs

AUTOMATIC RESOLUTION OF SPANISH
READING COMPREHENSION EXAMS USING
LLMs

TRABAJO FIN DE MÁSTER
CURSO 2025-2026

AUTOR
PABLO FOLGUEIRA GALÁN

DIRECTOR
ALBERTO DÍAZ ESTEBAN

CONVOCATORIA: JUNIO 2026

CALIFICACIÓN: 10

MÁSTER EN INTELIGENCIA ARTIFICIAL
FACULTAD DE INFORMÁTICA
UNIVERSIDAD COMPLUTENSE DE MADRID

19 DE JUNIO DE 2026

Abstract

The rise of Large Language Models (LLMs) has transformed the field of Natural Language Processing (NLP) and its many subfields. In particular, machine reading comprehension (MRC) has seen significant progress in recent years. However, most existing resources and shared tasks have been designed primarily for English, leaving Spanish, like many other languages, underrepresented in this area. Moreover, many of these resources rely on data that models may have already seen during pretraining, which makes it difficult to properly measure their true comprehension capabilities. This work addresses both limitations by participating in PROFE 2026, a shared task within IberLEF 2026, which evaluates automatic reading comprehension in Spanish using official Instituto Cervantes proficiency exams, under the same conditions applied to human candidates and without any task-specific training data.

To this end, different solutions have been explored and compared for two of the subtasks proposed by the competition: multiple-choice question answering and text matching. The approaches tested include *zero-shot prompting*, *chain-of-thought* reasoning, *fine-tuning* on external corpora, and multi-agent systems designed for the collaborative resolution of these exercises. Most solutions are built on small open-source models, seeking a balance between competitive performance and computational and environmental efficiency, for which the energy consumption and carbon footprint of each system are measured as an additional evaluation criterion.

Results are satisfactory on both subtasks. Multi-agent architectures achieve the highest accuracy, while *prompting* strategies on open-source models reach very competitive results at a considerably lower cost. *Fine-tuning*, on the other hand, does not improve over the other approaches, suggesting that tasks requiring varied texts and global reasoning about them favours approaches that take advantage of the capabilities inherent to models rather than supervised adaptation. Overall, these findings show that current LLMs, even in their smaller variants, can solve Spanish reading comprehension exams at a level close to that of human candidates, and that a well-designed *prompt* can be very useful to take advantage of this capacity without the need for specific adaptation or solutions that require high cost.

Keywords: reading comprehension, LLMs, natural language processing, prompting, fine-tuning, multi-agent systems, multiple choice, matching, computational efficiency, Spanish.

Resumen

La aparición de los grandes modelos de lenguaje (*Large Language Models*, LLMs) ha transformado el campo del Procesamiento de Lenguaje Natural (PLN) y sus diferentes ramas. Concretamente, la comprensión lectora automática ha experimentado avances muy significativos durante los últimos años. Sin embargo, la mayor parte de los recursos y competiciones existentes se han diseñado principalmente para el inglés, por lo que el español, al igual que otros idiomas, sigue infrarrepresentado dentro de este ámbito. Además, muchos de estos recursos utilizan datos que los modelos pueden haber visto durante su preentrenamiento, lo que dificulta medir su verdadera capacidad de comprensión. Este trabajo aborda ambas limitaciones mediante la participación en la tarea PROFE 2026, enmarcada en IberLEF 2026, cuyo objetivo es evaluar la comprensión lectora automática en español a partir de exámenes oficiales del Instituto Cervantes, bajo las mismas condiciones que se aplican a los candidatos humanos y sin datos de entrenamiento específicos para la tarea.

Para ello, se han explorado y comparado distintas soluciones para dos de las subtareas que propone la competición: selección múltiple y emparejamiento de textos. Entre los enfoques probados se encuentran el *prompting zero-shot*, el razonamiento con *chain-of-thought*, el *fine-tuning* sobre corpus externos y los sistemas multi-agente orientados a la resolución colaborativa de este tipo de ejercicios. La mayoría de las soluciones se han desarrollado sobre modelos de código abierto de tamaño reducido, buscando un equilibrio entre rendimiento competitivo y eficiencia computacional y medioambiental, para lo cual se ha medido el consumo energético y la huella de carbono de cada sistema como criterio de evaluación adicional.

Los resultados obtenidos fueron satisfactorios en ambas subtareas. Las arquitecturas multi-agente alcanzaron la mayor precisión, mientras que las estrategias de *prompting* sobre modelos *open source* alcanzaron resultados muy competitivos a un coste considerablemente menor. El *fine-tuning*, en cambio, no mejora al resto de aproximaciones, lo que sugiere que este tipo de tareas, donde los textos son variados y es necesario realizar un razonamiento global sobre ellos, favorece los enfoques que aprovechan las capacidades inherentes de los modelos frente a la adaptación supervisada. En conjunto, estos resultados demuestran que los LLMs actuales, incluso en sus versiones más pequeñas, son capaces de resolver exámenes de comprensión lectora en español a un nivel muy próximo al de los candidatos humanos, y que un *prompt* bien diseñado puede ser de gran utilidad para aprovechar esa capacidad sin necesidad de adaptación específica ni de soluciones que requieran un alto coste.

Palabras clave: comprensión lectora, LLMs, procesamiento del lenguaje natural, *prompting*, *fine-tuning*, sistemas multi-agente, selección múltiple, emparejamiento, eficiencia energética, español.

Índice general

1. Introducción	1
1.1. Motivación	1
1.2. Objetivos	2
1.3. Plan de trabajo	3
1.4. Estructura del documento	3
2. Estado de la Cuestión	5
2.1. Comprensión lectora en el ámbito del Procesamiento de Lenguaje Natural	5
2.2. LLMs y técnicas de resolución en MRC	7
2.2.1. Prompting en MRC	8
2.2.2. <i>Fine-tuning</i> en MRC	9
2.2.3. Sistemas multi-agente en MRC	10
2.3. Tareas de comprensión lectora en español	11
2.3.1. QA4MRE (CLEF 2011–2013)	11
2.3.2. ReCoRES (IberLEF 2022)	12
2.3.3. PROFE 2025 (IberLEF 2025)	12
2.3.3.1. Tareas propuestas	14
2.3.3.2. Evaluación y conjunto de datos	18
2.3.3.3. Soluciones propuestas para la subtask de selección múltiple	19
2.3.3.4. Soluciones propuestas para la subtask de emparejamiento	20
2.3.3.5. Síntesis y aprendizajes	21
3. Metodología y desarrollo	23
3.1. Primera aproximación al problema	23
3.1.1. Tarea de referencia: ReCoRES 2022	23
3.1.2. Fine-tuning con mDeBERTa	24
3.1.3. Aproximaciones basadas en <i>prompting</i>	26
3.1.3.1. Técnicas evaluadas	26
3.1.3.2. Resultados y análisis	26
3.2. Competición PROFE 2026	28
3.3. Conjunto de desarrollo para la tarea PROFE 2026	31
3.4. Experimentación y desarrollo de soluciones	33
3.4.1. Entorno de ejecución y modelos utilizados	33
3.4.2. Selección múltiple	34
3.4.2.1. <i>Zero-shot prompting</i>	34
3.4.2.2. <i>Few-shot prompting</i>	36
3.4.2.3. <i>Chain-of-Thought</i> y autoconsistencia	37
3.4.2.4. <i>Ensemble</i> multi-agente (<i>LLM-as-a-Judge</i>)	38
3.4.2.5. <i>Fine-tuning</i>	41

Índice general

3.4.3. Emparejamiento	44
3.4.3.1. <i>Zero-shot prompting</i>	44
3.4.3.2. Sistema multi-agente	45
3.5. Participación en PROFE 2026	61
4. Discusión y resultados	63
4.1. Resultados oficiales en PROFE 2026	63
4.1.1. Selección múltiple	63
4.1.2. Emparejamiento	63
4.2. Análisis comparativo entre estrategias	64
4.2.1. Selección múltiple	64
4.2.2. Emparejamiento	66
4.3. Análisis de eficiencia energética	67
4.3.1. Emisiones de las estrategias propuestas para la sub- tarea de selección múltiple	67
4.3.2. Emisiones de las estrategias propuestas para la sub- tarea de emparejamiento	68
5. Conclusiones y trabajo futuro	70
5.1. Conclusiones	70
5.2. Trabajo futuro	72
6. Introduction	74
6.1. Motivation	74
6.2. Objectives	75
6.3. Work Plan	75
6.4. Document Structure	76
7. Conclusions and future work	78
7.1. Conclusions	78
7.2. Future Work	80
A. <i>Prompts</i> de la primera aproximación al problema	87
B. Ejemplos de ejercicios para las tareas de selección múltiple y em- parejamiento	91
B.1. Ejercicio de selección múltiple	92
B.2. Ejercicios de emparejamiento	96
C. Repositorio de código	105

Índice de figuras

2.1.	Ejemplo del <i>dataset</i> de la tarea ReCoRES con una pregunta de comprensión lectora con su correspondiente texto, opciones y justificación.	13
2.2.	Ejemplo de ejercicio de la subtarea de <i>multiple choice</i> extraído del corpus IC-UNED-RC-ES (Peñas, Rodrigo, Fruns-Jiménez, Soria-Pastor, Moreno-Álvarez, Pérez et al. 2026), correspondiente a un examen de nivel A1. . .	14
2.3.	Ejemplo de ejercicio de la subtarea de <i>matching</i> extraído del corpus IC-UNED-RC-ES (Peñas, Rodrigo, Fruns-Jiménez, Soria-Pastor, Moreno-Álvarez, Pérez et al. 2026), correspondiente a un examen de nivel B1, en el que un mismo elemento del primer conjunto puede emparejarse con varios elementos del segundo.	15
2.4.	Ejemplo de ejercicio de la subtarea de <i>matching</i> extraído del corpus IC-UNED-RC-ES (Peñas, Rodrigo, Fruns-Jiménez, Soria-Pastor, Moreno-Álvarez, Pérez et al. 2026), correspondiente a un examen de nivel B1, con asignación uno a uno y presencia de distractores.	17
2.5.	Ejemplo de ejercicio de la subtarea de <i>fill-the-gaps</i> extraído del corpus IC-UNED-RC-ES (Peñas, Rodrigo, Fruns-Jiménez, Soria-Pastor, Moreno-Álvarez, Pérez et al. 2026), correspondiente a un examen de nivel B2. . .	18
3.1.	<i>System prompt</i> definido para obtener directamente la respuesta a una pregunta de selección múltiple siguiendo una estrategia <i>zero-shot</i>	35
3.2.	<i>System prompt</i> definido para obtener directamente la respuesta a una pregunta de selección múltiple junto a un razonamiento breve en formato JSON	36
3.3.	<i>System prompt</i> de la estrategia <i>chain-of-thought</i> para la subtarea de selección múltiple, que obliga al modelo a descartar las opciones incorrectas una a una antes de emitir su respuesta final en formato JSON.	39
3.4.	Arquitectura del sistema <i>ensemble</i> multi-agente para la subtarea de selección múltiple, donde tres modelos responden de forma independiente y un agente juez (<i>LLM-as-a-Judge</i>) arbitra en caso de discrepancia.	40
3.5.	<i>System prompt</i> del agente juez en la estrategia <i>ensemble</i> multi-agente, encargado de arbitrar entre las opciones en conflicto cuando los tres modelos no alcanzan un acuerdo unánime.	42
3.6.	Formato de los datos de entrenamiento utilizados en el <i>fine-tuning</i> de Gemma 4 E4B sobre el <i>dataset</i> ReCoRES.	43
3.7.	<i>System prompts</i> de la estrategia <i>zero-shot</i> para la subtarea de emparejamiento: la variante para ejercicios con respuestas repetibles (arriba) y la variante para ejercicios con correspondencia uno a uno y posibles distractores (abajo).	46

Índice de figuras

3.8. Arquitectura del sistema multi-agente para la subtask de emparejamiento, con el agente orquestador que clasifica cada ejercicio y activa la Ruta A (<i>Proposer-Critic Collaboration</i>) para ejercicios con respuestas reutilizables o la Ruta B (<i>Bidirectional Consensus and Auditing</i>) para ejercicios con correspondencia uno a uno.	47
3.9. <i>Prompts</i> del agente orquestador del sistema multi-agente para la subtask de emparejamiento, encargado de analizar la estructura del ejercicio y determinar si debe activarse la Ruta A o la Ruta B.	48
3.10. <i>Prompts</i> del agente <i>Resolver</i> en la Ruta A (<i>Proposer-Critic Collaboration</i>), encargado de proponer un candidato para cada pregunta evaluando las opciones disponibles e incorporando el <i>feedback</i> del agente <i>Reviewer</i> en caso de rechazo.	49
3.11. <i>Prompts</i> del agente <i>Reviewer</i> en la Ruta A (<i>Proposer-Critic Collaboration</i>), encargado de validar o rechazar la propuesta del agente <i>Resolver</i> comparándola con el resto de opciones disponibles y emitiendo un <i>feedback</i> explicado en caso de discrepancia.	51
3.12. <i>Prompts</i> del agente <i>Direct Resolver</i> en la Ruta B (<i>Bidirectional Consensus and Auditing</i>), encargado de recorrer las preguntas de forma secuencial y asignar a cada una la respuesta más adecuada entre las todavía disponibles, garantizando la restricción de correspondencia uno a uno.	52
3.13. <i>Prompts</i> del agente <i>Inverse Resolver</i> en la Ruta B (<i>Bidirectional Consensus and Auditing</i>), encargado de recorrer las respuestas en sentido inverso e identificar a qué pregunta pertenece cada una, devolviendo <code>null</code> cuando detecta que una respuesta actúa como distractor.	53
3.14. <i>Prompts</i> del agente <i>Auditor</i> en la Ruta B (<i>Bidirectional Consensus and Auditing</i>), encargado de arbitrar entre los candidatos en conflicto tras la fase de <i>cross-validation</i> , determinando cuál de las opciones en disputa es un distractor y cuál es la respuesta correcta.	54
3.15. Ejemplo de ejercicio de <i>matching</i> extraído del corpus IC-UNED-RC-ES (Peñas, Rodrigo, Fruns-Jiménez, Soria-Pastor, Moreno-Álvarez, Pérez et al. 2026), correspondiente a un examen de nivel B1, en el que un mismo texto puede ser la respuesta correcta de varias preguntas (respuestas repetibles).	56
3.16. Diagrama de secuencia de la Ruta A (<i>Proposer-Critic Collaboration</i>), donde el <i>Resolver</i> propone un emparejamiento para cada pregunta y el <i>Reviewer</i> lo valida o rechaza de forma iterativa hasta alcanzar un acuerdo.	57
3.17. Ejemplo de ejercicio de <i>matching</i> extraído del corpus IC-UNED-RC-ES (Peñas, Rodrigo, Fruns-Jiménez, Soria-Pastor, Moreno-Álvarez, Pérez et al. 2026), correspondiente a un examen de nivel B1, en el que se incluyen textos que no corresponden a ningún enunciado y que actúan como distractores.	58
3.18. Diagrama de secuencia de la Ruta B (<i>Bidirectional Consensus and Auditing</i>), donde el <i>Direct Resolver</i> y el <i>Inverse Resolver</i> abordan el ejercicio en paralelo y los conflictos entre sus propuestas se delegan al <i>Auditor</i> para su resolución.	60

Índice de figuras

A.1.	<i>Prompts</i> definidos para la estrategia <i>zero-shot</i> básica para resolver la tarea ReCoRES.	87
A.2.	<i>Prompts</i> definidos para la estrategia <i>zero-shot</i> con <i>role prompting</i> , que asigna al modelo el rol de profesor experto en comprensión lectora.	88
A.3.	<i>User prompt</i> definido para la estrategia <i>few-shot</i> , que incorpora ejemplos resueltos para orientar al modelo sobre el formato de respuesta esperado, manteniendo el mismo <i>system prompt</i> que la estrategia <i>zero-shot</i> básica (figura A.1).	89
A.4.	<i>Prompts</i> definidos para la estrategia que combina <i>role prompting</i> con <i>chain-of-thought</i> , obligando al modelo a descartar las opciones una a una antes de emitir su respuesta final.	90
B.1.	Ejemplo de ejercicio de selección múltiple del conjunto IC-UNED-RC-ES, con el texto y las instrucciones (arriba) y las preguntas correspondientes, incluyendo una con opciones de respuesta en formato imagen (abajo).	93
B.2.	Archivo JSON correspondiente al ejercicio de selección múltiple de la figura B.1, donde puede verse que la pregunta con imágenes representa cada opción de respuesta mediante una referencia al fichero correspondiente en lugar de texto.	95
B.3.	Ejemplo de ejercicio de emparejamiento del conjunto IC-UNED-RC-ES, con más preguntas (arriba) que textos (abajo), lo que permite que un mismo texto pueda responder a varias de las preguntas planteadas.	97
B.4.	Archivo JSON correspondiente al ejercicio de emparejamiento de la figura B.3, donde puede verse cómo una misma respuesta del primer conjunto puede repetirse y asociarse a varias preguntas del segundo.	99
B.5.	Ejemplo de ejercicio de emparejamiento del conjunto IC-UNED-RC-ES, con más textos en el primer conjunto (arriba) que en el segundo (abajo), lo que da lugar a la presencia de distractores. Algunos de los textos incluyen además imágenes que no siempre aportan información relevante para resolver el ejercicio.	101
B.6.	Archivo JSON correspondiente al ejercicio de emparejamiento de la figura B.5, donde puede verse cómo se representan los textos adicionales que actúan como distractores y las imágenes asociadas a algunos de los textos.	104

Índice de tablas

2.1. Distribución de número de respuestas del corpus IC-UNED-RC-ES por tipo de ejercicio.	19
3.1. Resultados del <i>fine-tuning</i> de <i>mDeBERTa-v3-base</i> para cada fase del entrenamiento.	25
3.2. Resultados de <i>accuracy</i> en la tarea 1 (selección múltiple) sobre el conjunto de validación de ReCoRES según modelo y estrategia de <i>prompting</i>	27
3.3. Resultados de BERTScore F1 en la tarea 2 (explicación de la opción elegida) sobre el conjunto de validación de ReCoRES según modelo y estrategia de <i>prompting</i>	28
3.4. Distribución de ejercicios y preguntas por nivel en las subtareas de ejercicios de <i>multiple choice</i> y <i>matching</i>	30
3.5. Distribución por nivel del MCER de los exámenes, ejercicios, preguntas y preguntas con imagen que componen el conjunto de desarrollo para la subtarea de selección múltiple.	32
3.6. Número de opciones de respuesta por pregunta en el conjunto de desarrollo de la subtarea de selección múltiple, desglosado por nivel del MCER.	32
3.7. Distribución por nivel del MCER de los ejercicios y textos a emparejar que componen el conjunto de desarrollo para la subtarea de emparejamiento.	33
3.8. Comparativa de precisión (<i>accuracy</i>) entre las estrategias <i>Zero-shot</i> y <i>Zero-shot</i> con explicación para los diferentes modelos según el nivel de dificultad de los ejercicios.	37
3.9. Desglose detallado de la precisión (<i>accuracy</i>) por niveles de dificultad y presencia de imágenes para el modelo Gemma 4 E4B utilizando una configuración <i>few-shot</i>	37
3.10. Comparativa de precisión (<i>accuracy</i>) bajo las estrategias de <i>Chain of Thought</i> (CoT) y Autoconsistencia, desglosada por nivel de dificultad y rendimiento global para cada modelo.	40
3.11. Resultados de precisión (<i>accuracy</i>) en la subtarea de <i>matching</i> bajo la estrategia <i>zero-shot</i> , detallando el rendimiento por niveles de cada modelo.	45
3.12. Resultados de precisión (<i>accuracy</i>) en la subtarea de <i>matching</i> bajo las estrategias <i>zero-shot</i> y el sistema multi-agente, desglosados por nivel del MCER y global.	61
4.1. Resultados oficiales obtenidos en la subtarea de selección múltiple de PROFE 2026, ordenados por <i>accuracy</i> descendente. Se incluye la línea de base publicada por los organizadores como referencia.	64
4.2. Resultados oficiales obtenidos en la subtarea de emparejamiento de PROFE 2026, ordenados por <i>accuracy</i> descendente. Se incluye la línea de base publicada por los organizadores como referencia.	64

Índice de tablas

4.3. Comparativa de precisión (<i>accuracy</i>) para la tarea de <i>multiple-choice</i> entre el conjunto de datos de desarrollo y el test oficial.	65
4.4. Comparativa de precisión (<i>accuracy</i>) para la tarea de <i>matching</i> entre el conjunto de datos de desarrollo y el test oficial.	66
4.5. Tiempo de ejecución, <i>hardware</i> utilizado y emisiones de CO ₂ equivalente registradas con <i>CodeCarbon</i> para los cinco envíos oficiales de la subtask de selección múltiple.	67
4.6. Tiempo de ejecución, <i>hardware</i> utilizado y emisiones de CO ₂ equivalente registradas con <i>CodeCarbon</i> para las estrategias <i>zero-shot</i> de la subtask de emparejamiento.	68

1. Introducción

En este capítulo se introduce el Trabajo de Fin de Máster. En primer lugar, la sección 1.1 presenta la motivación detrás del trabajo y las razones que han llevado a su desarrollo. Posteriormente, en la sección 1.2 se detallan los objetivos planteados al comienzo del proyecto. A continuación, la sección 1.3 describe el plan de trabajo seguido durante el desarrollo y, por último, la sección 1.4 contiene una descripción de la estructura del documento, con un breve resumen de cada una de las secciones que lo componen.

1.1. Motivación

La aparición de los grandes modelos de lenguaje (*Large Language Models*, LLMs) ha transformado profundamente el ámbito del Procesamiento de Lenguaje Natural (PLN). En los últimos años, estos modelos han pasado de resolver tareas lingüísticas relativamente simples a enfrentarse con éxito a problemas que requieren una comprensión profunda del lenguaje, como la extracción de información, el razonamiento lógico o la resolución de preguntas sobre textos complejos. Sin embargo, determinar si estos sistemas realmente comprenden el lenguaje o simplemente reproducen patrones aprendidos durante su entrenamiento no es algo trivial, ya que la mayoría de los *benchmarks* y competiciones actuales utilizan datos que los modelos han podido ver o inferir durante su fase de pre-entrenamiento, lo que impide medir con rigor su verdadera capacidad de generalización y comprensión.

A este problema general se suma una asimetría lingüística evidente en la investigación sobre comprensión lectora automática o *Machine Reading Comprehension* (MRC), ya que la gran mayoría de los recursos, conjuntos de datos y competiciones de referencia están diseñados para el inglés. El español, a pesar de ser una lengua con cientos de millones de hablantes, sigue claramente subrepresentado en esta línea de trabajo, lo que dificulta el desarrollo y la evaluación rigurosa de sistemas adaptados a sus particularidades lingüísticas.

En este contexto surge la tarea PROFE¹ (*Language Proficiency Evaluation for Spanish*), organizada en el marco del *Iberian Languages Evaluation Forum*² (IberLEF). Su objetivo principal es evaluar la comprensión lectora en español bajo condiciones controladas, donde los sistemas deben resolver exámenes oficiales del Instituto Cervantes³, diseñados originalmente para medir la competencia lingüística de los humanos, sin disponer de datos de entrenamiento específicos para la tarea. Esta restricción es precisamente lo que permite medir la capacidad de comprensión real de los modelos y no solo su habilidad para ajustarse a un conjunto de datos que ya hayan visto previamente.

¹<https://sites.google.com/view/profe2026>

²<https://sites.google.com/view/iberlef-2026/home>

³<https://exámenes.cervantes.es/es/dele/exámenes/a1>

1. Introducción

Entender hasta qué punto los LLMs son capaces de superar estas evaluaciones tiene implicaciones que van más allá del ámbito académico. Un sistema que demuestre una alta capacidad de comprensión lectora en español podría ser el punto de partida para el desarrollo de herramientas con aplicaciones muy diversas, desde asistentes educativos capaces de apoyar el aprendizaje del idioma hasta sistemas de evaluación automática que alivien la carga de corrección en entornos de enseñanza. Poder comparar el rendimiento de estos sistemas frente al de los propios alumnos, bajo exactamente las mismas condiciones, constituye además un marco de evaluación riguroso y significativo que puede ser muy útil en el futuro.

Todas estas preguntas abiertas convierten la comprensión lectora automática en español en un área de investigación especialmente interesante dentro del campo de la inteligencia artificial. Explorar qué estrategias y arquitecturas permiten extraer el máximo rendimiento de los LLMs actuales, identificar sus limitaciones reales e intentar superarlas con soluciones que combinen eficacia y eficiencia es, en definitiva, la motivación que da origen a este trabajo.

1.2. Objetivos

El objetivo general de este proyecto es evaluar la capacidad real de comprensión lectora en español de los LLMs actuales, analizando en qué medida estos sistemas son capaces de resolver ejercicios diseñados originalmente para examinar a personas, sin disponer de datos de entrenamiento específicos para la tarea y bajo las mismas condiciones que se aplican a los propios alumnos.

Para alcanzar este objetivo general, se plantean los siguientes objetivos específicos:

1. **Explorar y comparar distintas estrategias y técnicas de inteligencia artificial** aplicadas a la comprensión lectora en español, desde aproximaciones basadas en *prompting* hasta arquitecturas multi-agente y *fine-tuning* de modelos, con el fin de identificar qué enfoques resultan más efectivos para este tipo de tareas.
2. **Desarrollar soluciones que no solo rindan bien, sino que sean eficientes:** Más allá de la precisión sobre la tarea, se busca encontrar el equilibrio entre rendimiento y coste computacional, evitando soluciones que solo sean competitivas a un coste desproporcionado en tiempo o recursos.
3. **Comprobar si es posible obtener resultados competitivos con recursos computacionales limitados:** Una parte central del trabajo es demostrar que no es necesario recurrir a modelos comerciales de gran escala ni a infraestructuras de alto coste para abordar con garantías tareas de comprensión lectora en español, y establecer hasta dónde llega ese techo de rendimiento.
4. **Medir el impacto medioambiental de las soluciones desarrolladas:** Registrar el consumo energético y la huella de carbono de cada estrategia para incorporar la sostenibilidad como criterio de evaluación, promoviendo un desarrollo de sistemas más responsable y consciente del coste real que conllevan.

1.3. Plan de trabajo

El desarrollo de este proyecto se ha organizado en diferentes fases, cada una con una serie de objetivos concretos que han permitido avanzar progresivamente desde una primera aproximación al problema hasta la participación oficial en la competición PROFE 2026.

La primera fase tuvo lugar entre noviembre de 2025 y enero de 2026 y sirvió para estudiar y realizar una primera aproximación al problema. Durante este periodo se revisó el estado del arte en comprensión lectora automática en español y se estudiaron las soluciones presentadas en ediciones anteriores de la tarea PROFE. Al mismo tiempo, se realizaron las primeras pruebas con distintos modelos y estrategias, con el objetivo de identificar posibles problemas y soluciones antes de enfocarse en la tarea principal.

A partir de febrero de 2026, el trabajo se centró en desarrollar las soluciones para la competición PROFE 2026 (sección 3.2). Esta fase incluyó la construcción del conjunto de desarrollo descrito en la sección 3.3, la implementación y evaluación iterativa de las distintas estrategias para las subtarefas tratadas durante el trabajo y la selección de los envíos definitivos antes del cierre del plazo oficial, el 11 de mayo de 2026. Tras recibir los resultados de la evaluación oficial, se realizó un análisis de los resultados que dio lugar a un artículo científico presentado y aceptado en la competición y, paralelamente, a la elaboración de este Trabajo de Fin de Máster, concluido en junio de 2026.

A lo largo de todo el proyecto se mantuvieron reuniones periódicas con el tutor cada dos semanas aproximadamente, con el objetivo de comentar los avances, resolver las dudas que surgieron en cada fase y ajustar la planificación cuando fuese necesario. Para la gestión y el control de versiones del código se utilizó GitHub, lo que permitió mantener un historial completo del desarrollo y facilitar el seguimiento de los cambios a lo largo del proyecto. Todas las soluciones desarrolladas pueden consultarse en el siguiente repositorio <https://github.com/NILGroup/TFM2526-ExamenesComprensionLectora.git>

1.4. Estructura del documento

El contenido de este documento está estructurado según los capítulos que se detallan a continuación:

- **Capítulo 1: Introducción.** Presenta la motivación principal detrás del trabajo, los objetivos planteados al inicio del proyecto, el plan de trabajo seguido durante todo el desarrollo y, finalmente, una descripción de la estructura de todo el documento.
- **Capítulo 2: Estado de la Cuestión.** Contextualiza el trabajo dentro del estado del arte del Procesamiento de Lenguaje Natural (PLN), revisando los antecedentes en comprensión lectora automática, las principales técnicas de *prompting* y *fine-tuning* de los grandes modelos de lenguaje, y los sistemas multi-agente. Incluye también una descripción de la tarea PROFE 2025, edición anterior de la competición en la que se enmarca el desarrollo del proyecto, y de las soluciones presentadas por los equipos participantes.

1. Introducción

- **Capítulo 3: Metodología y Desarrollo.** Describe el proceso seguido para desarrollar las soluciones propuestas. Parte de una primera aproximación al problema mediante la tarea ReCoRES, presenta la competición PROFE 2026 en la que se enmarca el trabajo y detalla las estrategias implementadas para las dos subtareas que se han tratado de resolver: selección múltiple y emparejamiento. El capítulo concluye con una descripción de los envíos realizados a la competición y el criterio seguido para su selección.
- **Capítulo 4: Resultados.** Presenta y analiza los resultados obtenidos en la competición PROFE 2026, tanto para la subtarea de selección múltiple como para la de emparejamiento. Incluye una comparativa entre las distintas estrategias desarrolladas y un análisis de la eficiencia energética de cada una de las soluciones presentadas a la competición oficial.
- **Capítulo 5: Conclusiones y trabajo futuro.** Recoge las conclusiones extraídas del trabajo y propone posibles líneas de trabajo futuro para continuar investigando y ampliar el alcance del proyecto.
- **Capítulo 6: Introduction.** Traducción al inglés del capítulo de introducción, incluyendo la motivación, los objetivos, el plan de trabajo y la estructura del documento.
- **Capítulo 7: Conclusions and Future Work.** Traducción al inglés del capítulo de conclusiones, recogiendo las principales aportaciones del trabajo y las líneas de trabajo futuro propuestas.

Por último, el documento incluye tres apéndices con material complementario que puede resultar de utilidad para consultar detalles concretos durante la lectura de la memoria del trabajo: los *prompts* utilizados durante la primera aproximación al problema con la tarea ReCoRES (apéndice A), una selección de ejemplos de exámenes oficiales junto con su correspondencia en el conjunto de datos utilizado durante el trabajo (apéndice B), y el enlace al repositorio de GitHub donde se encuentran disponibles todas las soluciones desarrolladas (apéndice C).

2. Estado de la Cuestión

Este capítulo presenta los conceptos y el marco necesario para contextualizar todo el desarrollo del trabajo. En primer lugar, la sección 2.1 introduce la tarea de comprensión lectora automática (*Machine Reading Comprehension*, MRC) y repasa su evolución dentro del ámbito del procesamiento de lenguaje natural (PLN). A continuación, la sección 2.2 describe los tres enfoques principales basados en LLMs que se han explorado en este trabajo para abordar las subtarefas propuestas (*prompting*, *fine-tuning* y sistemas multi-agente), enfocándolas hacia su aplicación dentro de la MRC. Finalmente, la sección 2.3 repasa las principales competiciones de comprensión lectora en español, desde QA4MRE hasta ReCoRES, para centrarse en la edición de PROFE 2025, que sirve como punto de partida para el trabajo al compartir dataset, subtarefas y formato de evaluación con la edición de 2026 en la que se ha participado.

2.1. Comprensión lectora en el ámbito del Procesamiento de Lenguaje Natural

La comprensión lectora es la capacidad que tienen los humanos para leer un texto, entender su significado y sus matices más profundos, extraer las ideas relevantes y relacionarlas con el conocimiento y sus experiencias previas. Se trata de un proceso cognitivo complejo que va mucho más allá de reconocer palabras o analizar la estructura de las frases, pues implica realizar inferencias, identificar la intención del texto, reconocer relaciones entre ideas y construir una representación coherente de su contenido. Por ello, lograr que una máquina sea capaz de llevar a cabo todo este razonamiento interno no es una tarea sencilla ni trivial.

Dentro del campo de la inteligencia artificial y, concretamente, del procesamiento de lenguaje natural (PLN), la comprensión lectora automática ha sido históricamente uno de los grandes retos a superar. Para abordarlo, existe toda una línea de investigación conocida como *Machine Reading Comprehension* (MRC), cuyo objetivo es desarrollar sistemas capaces de leer y comprender textos de manera análoga a como lo hacen los humanos (Z. Zhang, Zhao y Wang 2020).

Esta línea de trabajo de la comprensión lectora automática ha evolucionado profundamente a lo largo del tiempo, aunque esta evolución se ha acelerado notablemente en los últimos años gracias a los avances en técnicas y arquitecturas de aprendizaje profundo. Las primeras propuestas para tratar el problema se apoyaban en sistemas de reglas y técnicas de recuperación de información basadas en coincidencia léxica o modelos de bolsa de palabras (*bag of words*) (Hirschman et al. 1999), que resultaban eficaces en dominios acotados, pero eran incapaces de capturar el significado profundo de los textos ni de generalizar ante variaciones lingüísticas. Con la llegada de las redes neuronales

2. Estado de la Cuestión

profundas, y especialmente de los mecanismos de atención y los modelos de tipo *transformer* (Vaswani et al. 2017), el campo experimentó un salto cualitativo, ya que los modelos dejaron de depender de esas instrucciones diseñadas manualmente y pasaron a aprender representaciones semánticas directamente a partir de grandes volúmenes de texto. La posterior aparición de los grandes modelos de lenguaje (*Large Language Models*, LLMs) ha acelerado todo este progreso, permitiendo desarrollar soluciones que se aproximan notablemente a la capacidad de comprensión humana en una amplia variedad de tareas y dominios.

Dentro del campo de la MRC, las tareas propuestas en la literatura tratan de cubrir distintos tipos de ejercicios que evalúan la capacidad de comprensión automática de estos sistemas a distintos niveles. El formato más estudiado históricamente es la respuesta extractiva, en el que el sistema debe identificar y extraer el fragmento exacto del texto que responde a una pregunta dada. Este formato, popularizado por conjuntos de datos como SQuAD (Rajpurkar et al. 2016), permite una evaluación precisa y automatizable, pero muchos de los casos pueden resolverse mediante coincidencia léxica superficial sin necesidad de comprender realmente el texto, lo que supone una limitación importante a la hora de determinar la capacidad real de estos sistemas. Siguiendo un enfoque algo diferente, se encuentra la tarea de respuesta generativa, en la que el sistema debe producir una respuesta en lenguaje natural que no tiene por qué aparecer de forma literal en el texto, lo que exige una mayor capacidad de síntesis, paráfrasis y razonamiento. Más allá de estas tareas se encuentran los formatos de selección múltiple, emparejamiento y relleno de huecos (*fill the gaps*), que son precisamente en los que se basa la competición PROFE (sección 2.3.3) y los que se tratan de resolver a lo largo de este trabajo.

En los ejercicios de selección múltiple, el sistema recibe un texto y una serie de preguntas, cada una acompañada de un conjunto de opciones entre las que solo una es correcta. La dificultad no reside únicamente en localizar la información relevante en el texto, sino en razonar sobre los distractores, que están diseñados para resultar plausibles a primera vista y, en muchos casos, solo pueden descartarse mediante una lectura atenta y una comprensión profunda del contenido.

Por su parte, en los ejercicios de emparejamiento, se proporcionan dos conjuntos de textos y el sistema debe establecer una correspondencia biyectiva entre sus elementos, con la particularidad de que uno de los conjuntos puede incluir textos adicionales que actúan como distractores. Este formato es bastante exigente porque el sistema no puede resolver cada par de forma independiente, ya que un emparejamiento incorrecto condiciona las opciones disponibles para el resto, por lo que se requiere un razonamiento global sobre el ejercicio completo.

Finalmente, en los ejercicios de rellenar huecos, dado un texto con posiciones vacías y un conjunto de fragmentos candidatos, el sistema debe determinar qué fragmento encaja en cada hueco, pudiendo haber más fragmentos disponibles que huecos en el texto. Aunque este trabajo no aborda directamente este último formato, los tres se diferencian de las tareas de respuesta extractiva y generativa porque ninguna puede resolverse mediante una búsqueda de similitud léxica, sino que requieren un razonamiento semántico global que hace posible construir *benchmarks* más exigentes y representativos de la comprensión lectora real de los sistemas.

Para evaluar el avance de estos sistemas a nivel de comprensión lectora, la comunidad

2. Estado de la Cuestión

investigadora ha construido numerosos *datasets* y *benchmarks* que cubren los distintos formatos de tarea. Uno de los más influyentes es SQuAD (Rajpurkar et al. 2016), donde los modelos deben extraer un fragmento del texto que responde a una pregunta, y que sirvió como referencia para el desarrollo de los primeros modelos neuronales de comprensión lectora. Por su parte, RACE (Lai et al. 2017), construido a partir de exámenes de comprensión lectora de educación secundaria y bachillerato en inglés, popularizó el formato de selección múltiple como banco de pruebas para evaluar el razonamiento sobre distractores, y es uno de los recursos utilizados durante la primera aproximación a la tarea en este trabajo (sección 3.1). En la misma línea, MMLU (Hendrycks, Burns, Basart, Zou et al. 2021; Hendrycks, Burns, Basart, Critch et al. 2021) amplió esta idea proponiendo preguntas de selección múltiple sobre 57 materias distintas, desde matemáticas hasta derecho o medicina, con el objetivo de evaluar de forma más amplia el conocimiento y la capacidad de razonamiento de los modelos, y se ha convertido en uno de los *benchmarks* de referencia para comparar LLMs entre sí.

Sin embargo, todos estos recursos están diseñados para el inglés, lo que dificulta su uso directo para evaluar la comprensión lectora en otros idiomas. Para tratar de resolver esta limitación, surgieron iniciativas multilingües como XQuAD (Artetxe, Ruder y Yogatama 2019) y MLQA (Lewis et al. 2019), que proporcionan preguntas y respuestas en diferentes idiomas (incluyendo el español) traducidas a partir de conjuntos de datos en inglés, y que permiten evaluar la transferencia entre lenguas de los modelos entrenados principalmente en inglés. No obstante, al tratarse de traducciones, estos recursos no recogen necesariamente las particularidades lingüísticas del español ni los patrones propios de los textos escritos originalmente en esta lengua. En este sentido, SQAC (Gutiérrez-Fandiño et al. 2022) representa un paso importante al ser el primer corpus extractivo de comprensión lectora en español construido de forma nativa, con preguntas elaboradas directamente sobre textos en español sin pasar por ningún proceso de traducción. Aun así, la cantidad de recursos disponibles para el español sigue siendo considerablemente menor que para el inglés, lo que ha concentrado la investigación en torno a esta lengua y ha dejado el español claramente subrepresentado. Esta asimetría dificulta tanto el desarrollo de sistemas adaptados a las particularidades lingüísticas del español como la medición de su rendimiento y capacidad de comprensión real en esta lengua, y es precisamente el vacío que iniciativas como la tarea PROFE, descrita en la sección 2.3.3, tratan de cubrir.

2.2. LLMs y técnicas de resolución en MRC

La resolución automática de tareas de comprensión lectora ha experimentado una evolución profunda a lo largo de las últimas décadas. Las primeras aproximaciones se basaban principalmente en sistemas de reglas y en la coincidencia léxica para recuperar información de los textos (Hirschman et al. 1999), lo que resultaba útil en situaciones y dominios concretos, pero era insuficiente para comprender el significado de los textos y generalizar más allá del ámbito para el que los sistemas habían sido diseñados. Los avances en el aprendizaje profundo permitieron dar un gran salto cualitativo dentro de este campo, ya que la aparición de las redes neuronales recurrentes (RNN) y de los mecanismos de atención permitió que estos sistemas aprendieran representaciones semánticas directamente a partir de datos, haciendo que ya no fuese tan necesario diseñar

2. Estado de la Cuestión

reglas manualmente y mejorando así el rendimiento en los principales *benchmarks* de MRC (Hermann et al. 2015).

Sin embargo, lo que consolidó el estado del arte actual fue la aparición de la arquitectura *transformer* (Vaswani et al. 2017) y el paradigma de preentrenamiento sobre grandes corpus de texto seguido de fases de *fine-tuning*, dando lugar a dos grandes familias de modelos muy utilizadas dentro del campo de la MRC. Por un lado, los modelos de tipo *encoder-only*, como BERT (Devlin et al. 2018) o RoBERTa (Y. Liu et al. 2019), que se preentrenan prediciendo *tokens* enmascarados, lo que les permite construir representaciones semánticas que pueden utilizarse para resolver tareas como la clasificación de textos o la extracción de respuestas. No obstante, no están creados para generar secuencias de texto, por lo que carecen de esta capacidad generativa y no son capaces de razonar sobre el contenido de un texto. Por otro lado, la posterior escalada en tamaño y datos de preentrenamiento dio lugar a los modelos de tipo *decoder-only*, que sí han sido entrenados para predecir y generar texto, lo que les da la capacidad de comprender y razonar sobre los textos para abordar tareas complejas sin la necesidad de realizar un *fine-tuning* específico.

A lo largo del desarrollo de este trabajo se han explorado modelos de ambos tipos (principalmente *decoder-only*) para tratar de resolver sub tareas de selección múltiple y emparejamiento, tal y como se describe en el capítulo 3. Las tres técnicas principales empleadas (*prompting*, *fine-tuning* y sistemas multi-agente) se describen en las siguientes subsecciones, enfocadas específicamente hacia su aplicación en la MRC.

2.2.1. Prompting en MRC

Ante la dificultad de obtener datos etiquetados suficientes para entrenar sistemas de MRC en idiomas distintos al inglés y de disponer de los recursos necesarios para llevar a cabo ese entrenamiento, el *prompting* se ha consolidado como una de las estrategias más utilizadas para aprovechar las capacidades de los LLMs sin necesidad de realizar ningún tipo de ajuste adicional. La idea de esta aproximación es formular la tarea en lenguaje natural directamente en la entrada del modelo, de forma que este pueda resolverla apoyándose exclusivamente en el conocimiento adquirido durante su preentrenamiento y en su capacidad para comprender los textos y razonar sobre ellos.

La variante más sencilla de esta técnica es el *zero-shot prompting*, en la que el modelo recibe únicamente el texto, la pregunta y las opciones de respuesta sin ningún ejemplo previo ni instrucción adicional sobre cómo debe razonar. A pesar de su simplicidad, esta estrategia ha demostrado ser sorprendentemente eficaz en tareas de MRC, donde los LLMs más modernos son capaces de identificar la respuesta correcta con una precisión muy alta apoyándose únicamente en su comprensión del texto, sin haber visto ningún ejemplo de la tarea durante la inferencia. Una extensión habitual es el *few-shot prompting*, que incorpora en el *prompt* un pequeño número de ejemplos resueltos para orientar al modelo sobre el formato y el estilo de respuesta esperados (Brown et al. 2020). En el contexto de la MRC, esta técnica puede ser útil para fijar el formato de salida o para ilustrar cómo estructurar la respuesta ante formatos poco habituales, aunque su impacto sobre la precisión puede variar y en algunos casos incluso perjudicar el rendimiento si los ejemplos introducen sesgos o desplazan la atención del modelo lejos del texto relevante. Además, en tareas con ejercicios de mayor extensión, incluir ejemplos completos puede

2. Estado de la Cuestión

aumentar considerablemente la longitud de la entrada, lo que supone un coste adicional tanto en tiempo de inferencia como en consumo de memoria.

Otra estrategia habitual es *role prompting*, que consiste en asignar al modelo el rol de un experto en un dominio concreto al comienzo del *prompt* con el objetivo de orientar su comportamiento hacia un razonamiento más específico y contextualizado (Schulhoff et al. 2025). En MRC, esta estrategia puede utilizarse con la intención de que preste más atención a los detalles del texto y adopte un proceso de lectura más riguroso antes de responder. Aunque su efecto es difícil de medir de forma aislada, ya que depende en gran medida del modelo y del dominio en el que se centre la tarea, suele combinarse con otras técnicas como el *zero-shot* o el *chain-of-thought* para reforzar la atención del modelo en los aspectos relevantes del texto.

En el caso de las tareas que requieren un razonamiento más complejo, como aquellas en las que la respuesta correcta no aparece de forma explícita en el texto o en las que existen distractores especialmente elaborados, la técnica *chain-of-thought prompting* (CoT) (Wei et al. 2022) es ampliamente utilizada. Esta estrategia consiste en indicar al modelo que debe generar un razonamiento explícito paso a paso antes de dar su respuesta final. En el contexto de la MRC, esto se traduce habitualmente en pedir al modelo que analice el texto de forma progresiva, descarte las opciones incorrectas con argumentos concretos y justifique su elección final, simulando el proceso de razonamiento que seguiría un lector humano. Sin embargo, esta estrategia presenta un riesgo importante en modelos de capacidad limitada, ya que si el modelo comete un error en algún paso intermedio del razonamiento, este puede propagarse y arrastrar la conclusión final hacia una respuesta incorrecta, mientras que el *zero-shot* evita este riesgo al no forzar un proceso de razonamiento interno.

Una extensión del CoT es la autoconsistencia (*self-consistency*) (Schulhoff et al. 2025), que en lugar de generar un único camino de razonamiento, consiste en generar varios de forma independiente con cierta aleatoriedad y seleccionar la opción más repetida como respuesta final. En el contexto de la MRC, esta estrategia puede reducir la varianza ante preguntas ambiguas o con distractores elaborados, ya que la diversidad entre razonamientos permite compensar los errores puntuales que pudiera cometer un único camino de inferencia. No obstante, su beneficio respecto al CoT estándar tiende a ser modesto cuando el modelo ya opera con una precisión alta sobre la tarea. Además, para que el voto mayoritario funcione correctamente, es necesario que las respuestas de las distintas muestras sean comparables entre sí y puedan agregarse de forma directa, algo que resulta sencillo cuando la respuesta es una única opción, pero que se complica en tareas donde la respuesta es un conjunto de decisiones interrelacionadas, ya que pequeñas diferencias entre muestras pueden hacer que ninguna coincida exactamente con otra.

2.2.2. *Fine-tuning* en MRC

Una alternativa al *prompting* es el *fine-tuning*, que consiste en ajustar los pesos de un modelo preentrenado utilizando un conjunto de datos específico para la tarea objetivo. En el contexto de la MRC, esta estrategia permite especializar el modelo en el formato concreto del ejercicio (selección múltiple, extracción de respuestas, emparejamiento, etc.) y ha sido una aproximación muy utilizada durante los años anteriores a la aparición de los LLMs. Trabajos como el de Lai et al. (2017) sobre el corpus RACE o las

2. Estado de la Cuestión

distintas variantes de BERT ajustadas sobre SQuAD muestran cómo el *fine-tuning* sobre ejercicios de comprensión lectora permite desarrollar sistemas que alcancen un buen rendimiento, cuando se dispone de los datos y los recursos suficientes para llevar a cabo el entrenamiento.

Sin embargo, esta estrategia también presenta limitaciones importantes en situaciones donde los datos etiquetados son escasos o donde existe un desajuste de dominio entre los datos de entrenamiento y los de evaluación. Esto es especialmente relevante para el español, donde la cantidad de corpus de MRC anotados es considerablemente menor que para el inglés, lo que hace que el rendimiento de los modelos ajustados sobre datos en otro idioma no siempre se transfiera con suficiente precisión a nuevas tareas o dominios. En estos casos, el *fine-tuning* puede dar peores resultados que las estrategias de *prompting* aplicadas directamente sobre un LLM.

Por otro lado, para mitigar el coste computacional que implica actualizar todos los parámetros de un LLM, han surgido técnicas de *fine-tuning* más eficientes. La más común es LoRA (Hu et al. 2021), que en lugar de actualizar todos los pesos del modelo, introduce matrices de bajo rango entrenables en las capas de atención, reduciendo drásticamente el número de parámetros que es necesario optimizar sin apenas degradar el rendimiento final. Sobre esta idea, QLoRA (Dettmers et al. 2023) añade la cuantización del modelo base en precisión reducida, lo que permite ajustar modelos de varios miles de millones de parámetros en GPUs menos potentes, haciendo posible realizar un *fine-tuning* en entornos con recursos limitados.

2.2.3. Sistemas multi-agente en MRC

Los sistemas multi-agente basados en LLMs constituyen un paradigma emergente en el que varios modelos, cada uno con un rol especializado, colaboran para resolver una tarea de forma más robusta que un único modelo actuando de forma aislada. La idea central es que diferentes agentes puedan aportar perspectivas complementarias, detectar errores de los demás y llegar a una respuesta consensuada mediante un proceso de deliberación interna (T. Guo et al. 2024). El trabajo de Du et al. (2023) demostró que enfrentar a múltiples instancias de un LLM en rondas de debate mejora de forma consistente la factualidad y la capacidad de razonamiento del sistema, reduciendo las alucinaciones de los modelos individuales, lo que sentó las bases del paradigma de debate multi-agente aplicado a tareas de razonamiento complejo. En el ámbito de la MRC, este paradigma puede resultar muy útil en ejercicios que requieren razonamiento complejo sobre el texto, como aquellos en los que la respuesta correcta no aparece de forma explícita o en los que existen distractores diseñados para inducir a error, ya que en estos casos la deliberación entre agentes puede compensar los errores que cometería un único modelo resolviendo el ejercicio de forma directa.

Entre los patrones de diseño más habituales en sistemas multi-agente para MRC destacan tres. El primero es el patrón *Proposer-Critic* (Madaan et al. 2023), en el que un agente propone una respuesta candidata y otro la evalúa de forma crítica, pudiendo rechazarla y devolver retroalimentación para que el primero reformule su propuesta; este ciclo iterativo permite refinar la respuesta de forma progresiva ante ejercicios en los que la respuesta correcta no es evidente de forma inmediata. El segundo es el patrón *LLM-as-a-Judge* (Zheng et al. 2023), en el que un agente árbitro recibe las propuestas de otros

agentes y determina cuál es la más correcta, resolviendo los conflictos cuando no hay acuerdo entre ellos. El tercero es el *ensemble* de modelos (Du et al. 2023), donde varios LLMs independientes resuelven la misma pregunta y la respuesta final se determina por mayoría o por un mecanismo de agregación, lo que reduce la varianza y aumenta la robustez del sistema frente a los errores individuales de cada modelo.

2.3. Tareas de comprensión lectora en español

Con el objetivo de establecer marcos de evaluación que permitan medir el progreso de estos sistemas y su capacidad de comprensión lectora en español, se han organizado diferentes competiciones y evaluaciones compartidas (*shared tasks*), en las que distintos grupos tratan de resolver una tarea sobre un conjunto de datos común, lo que permite comparar distintos enfoques e identificar qué estrategias resultan más efectivas. En el ámbito del español, estas iniciativas han sido relevantes para intentar solucionar la escasez de recursos de evaluación en esta lengua y para impulsar el desarrollo de sistemas capaces de alcanzar un buen rendimiento en tareas de comprensión lectora. Esta sección repasa las tres competiciones más relevantes en este contexto, siguiendo un orden cronológico que refleja la evolución del campo: QA4MRE, celebrada en el marco de CLEF entre 2011 y 2013; ReCoRES, propuesta en IberLEF 2022; y PROFE, cuya edición de 2025 constituye el punto de partida del trabajo desarrollado en esta memoria.

2.3.1. QA4MRE (CLEF 2011–2013)

Una de las primeras iniciativas en proponer la resolución de exámenes como método de evaluación de la comprensión lectora automática fue QA4MRE¹ (*Question Answering for Machine Reading Evaluation*) (Peñas, Hovy et al. 2013), que tuvo lugar en el marco de la conferencia CLEF en los años 2011², 2012³ y 2013⁴. A diferencia de los sistemas de preguntas y respuestas tradicionales, en los que los modelos deben localizar una respuesta en una colección de documentos, QA4MRE reformuló el problema como una tarea de selección múltiple sobre un texto de referencia, evaluando así la capacidad de los sistemas para comprender y razonar sobre el contenido de un texto concreto en lugar de limitarse a recuperar información. La tarea se propuso en varios idiomas, entre ellos el español, y cubría distintos dominios, incluyendo noticias de actualidad y textos de divulgación científica. Aunque los sistemas participantes estaban aún lejos de la comprensión humana, QA4MRE fue una de las primeras iniciativas en utilizar exámenes como método de evaluación de la comprensión lectora automática, un paradigma que comparten competiciones posteriores en el contexto del español como ReCoRES (sección 2.3.2) y PROFE (sección 2.3.3).

¹<https://www.tensorflow.org/datasets/catalog/qa4mre?hl=es-419>

²<http://clef2011.clef-initiative.eu/>

³<http://clef2012.clef-initiative.eu/>

⁴<http://clef2013.clef-initiative.eu/>

2.3.2. ReCoRES (IberLEF 2022)

En 2022, en el marco de IberLEF⁵ (*Iberian Languages Evaluation Forum*), se celebró ReCoRES⁶ (*Reading Comprehension and Reasoning Explanation for Spanish*) (Diego Diestra y Rodrigo López y Erasmo Gómez y Arturo Oncevay y Fernando Alva-Manchego 2022), una tarea centrada específicamente en la comprensión lectora en español. A diferencia de QA4MRE, que planteaba la tarea en varios idiomas de forma simultánea, ReCoRES se diseñó íntegramente en español y con un enfoque más exigente, ya que no solo había que seleccionar la respuesta correcta entre varias opciones, sino que los sistemas debían además generar una explicación en lenguaje natural que justificase su elección. Este segundo requisito buscaba ir más allá de la selección de respuestas y evaluar si los sistemas eran capaces de generar un razonamiento coherente sobre el contenido del texto, lo que supone un reto adicional respecto a otras tareas de comprensión lectora más convencionales.

El conjunto de datos de la tarea se construyó a partir de exámenes de acceso a la universidad de instituciones peruanas, lo que garantizaba que las preguntas eran complejas y requerían una comprensión real del texto, por lo que no podían resolverse únicamente mediante coincidencia léxica. En la figura 2.1 se muestra un ejemplo de un ejercicio del *dataset*, donde puede verse cómo cada pregunta exige justificar la elección además de seleccionar la opción correcta.

Las soluciones presentadas por los equipos participantes se basaron principalmente en realizar *fine-tuning* sobre modelos *encoder-only*, siendo el mejor sistema el que alcanzó un 75,91 % de *accuracy* en la subtarea de selección múltiple mediante *fine-tuning* de un modelo BERT (BETO) especializado en español. ReCoRES constituye, junto con QA4MRE, el antecedente más directo de PROFE en el panorama de las competiciones de comprensión lectora en español, y su conjunto de datos ha sido utilizado como recurso de entrenamiento y evaluación en una primera fase de aproximación a la tarea durante el desarrollo de este trabajo, tal y como se describe en la sección 3.1.

2.3.3. PROFE 2025 (IberLEF 2025)

PROFE 2025⁷ (*Language Proficiency Evaluation for Spanish*) (Sergio Moreno-Álvarez y Alberto Pérez y Anselmo Peñas y Rodrigo Agerri y Javier Fruns-Jiménez y Inés Soria-Pastor 2025) es una tarea compartida propuesta en el marco de IberLEF 2025⁸ (J. Á. González-Barba, Luis Chiruzzo y Jiménez-Zafra 2025) que sigue con la idea de utilizar exámenes como método de evaluación para los sistemas de comprensión lectora automática. A diferencia de ReCoRES, cuyos textos procedían de exámenes universitarios, PROFE 2025 utiliza exámenes oficiales del Instituto Cervantes para la certificación del español como lengua extranjera, lo que garantiza que los ejercicios han sido diseñados y validados por expertos siguiendo una serie de criterios y cubren todos los niveles del Marco Común Europeo de Referencia (MCER), desde A1 hasta C2. Además, la tarea no proporciona datos de entrenamiento específicos, de forma que los sistemas deben

⁵<https://sites.google.com/view/iberlef2022>

⁶<https://codalab.lisn.upsaclay.fr/competitions/16969>

⁷<https://sites.google.com/view/profe2026>

⁸<https://sites.google.com/view/iberlef-2025>

TEXTO:

La aptitud para iniciar el aprendizaje de la lectura se caracteriza por una madurez suficiente —mental, física y emotiva—, experiencias apropiadas y un vocabulario idóneo, todo lo cual permite al niño reconocer las palabras en letras de imprenta, pronunciarlas con corrección y asignarles un significado. La primera fase consiste en leer, pero entendiendo, ciertos materiales impresos como los que figuran en las cartillas o en tarjetas con dos o tres renglones. Nótese que esto se refiere a lectura para principiantes, que corresponde Por lo común a los comienzos del primer grado. Conseguir que los alumnos sepan leer una selección particular o un libro supone una tarea importante no sólo en el ámbito de la escuela primaria sino también de la secundaria. En cualquier grado un alumno puede reclamar ayuda para entender el significado de un párrafo, cuando el maestro procura que domine la estructura de oraciones complejas y los modismos capte los conceptos que exige una interpretación adecuada, y comprenda los motivos que llevaron a su autor a escribirlo. Cuando prepara a sus discípulos para la lectura, el docente necesita evaluar sus características en cuanto a la madurez y experiencia y organizar las actividades de aprendizaje de tal modo que, a través de ellas la mayoría logre: captar el significado exacto de palabras, elaborar un vocabulario oral adecuado desarrollar las capacidades básicas de un buen oyente, adquirir la discriminación auditiva y perfeccionar la discriminación visual.

KLAUSMEIER, Herbert. La enseñanza en la escuela primaria.

PREGUNTA: La idea central del texto es

- A) Capacidad humana para la lectura.
- B) Madurez y experiencia en la lectura.
- C) Criterios para la enseñanza de la lectura.
- D) Lectura y aprendizaje de los contenidos.
- E) Selección de materiales para la lectura.

RESPUESTA CORRECTA: C

RAZONAMIENTO: La idea central del texto: criterios para la enseñanza de la lectura. Las ideas del autor giran en torno a un conjunto de pautas que siguen los maestros para enseñar a leer a los alumnos. El autor señala que el aprendizaje de la lectura implica cierto grado de madurez y la puesta en práctica de un conjunto de experiencias y aptitudes adquiridas por el estudiante durante su desarrollo.

Figura 2.1.: Ejemplo del *dataset* de la tarea ReCoRES con una pregunta de comprensión lectora con su correspondiente texto, opciones y justificación.

afrontar los ejercicios en las mismas condiciones que los humanos que se presentan a este tipo de exámenes, lo que obliga a los sistemas a tener que generalizar a partir del conocimiento adquirido durante el preentrenamiento, sin posibilidad de ajustarse a los

2. Estado de la Cuestión

patrones específicos de la tarea.

Teniendo en cuenta que el desarrollo de este trabajo se enmarca dentro de la edición 2026 de esta misma tarea y, por tanto, comparte con ella el dataset, el formato de evaluación y las subtareas abordadas, se describe con más detalle que las tareas anteriores, ya que el análisis de las soluciones presentadas ha servido como punto de partida para el trabajo.

2.3.3.1. Tareas propuestas

La competición se estructura en torno a tres subtareas que reproducen los tipos de ejercicios habituales en los exámenes oficiales de certificación de idiomas. Cada subtarea evalúa la comprensión lectora desde una perspectiva distinta, lo que permite medir de la forma más completa posible la capacidad de los sistemas para entender y razonar sobre textos en español:

- **Multiple choice (selección múltiple)**: dado un texto y una serie de preguntas con varias opciones, el sistema debe seleccionar la respuesta correcta para cada una. La figura 2.2 muestra un ejemplo de este tipo de ejercicio.

TEXTO:

Para: lorenzoz@micso.it

Hola María:

¿Qué tal estás? Te escribo este correo para contarte una buena noticia. Mi jefa me ha ofrecido un viaje al extranjero para hacer un curso de español y estoy muy contenta.

El próximo mes de enero voy a viajar a Fortuna. Iré con una compañera de trabajo que se llama Sara. El curso comienza el día once y tiene una duración de diez días.

El vuelo de ida es dos días antes del inicio del curso para acostumbrarnos al cambio horario. Todavía no sé nada del alojamiento. Esta semana me van a informar de si nos quedamos en un hotel, en un apartamento o nos alquilan una casa, pero a mí me gustan los hoteles.

Es mi primera vez en ese país, pero estoy tranquila porque Sara ya ha ido varias veces y es muy amable conmigo. Mi jefa dice que la gente de allí es muy simpática y trabajadora. Allí es verano en enero y la ciudad es muy tranquila y está en la costa.

Espero tener tiempo libre para bañarme en la playa, que dicen que es bonita y de arena blanca. Hablamos pronto.

Un beso,

Lourdes

PREGUNTA: El viaje es...

- A) en enero.
- B) el día diez.
- C) esta semana.
- D) hasta el día once.

Figura 2.2.: Ejemplo de ejercicio de la subtarea de *multiple choice* extraído del corpus IC-UNED-RC-ES (Peñas, Rodrigo, Fruns-Jiménez, Soria-Pastor, Moreno-Álvarez, Pérez et al. 2026), correspondiente a un examen de nivel A1.

- **Matching (emparejamiento)**: se proporcionan dos conjuntos de textos y el sistema debe determinar qué elemento del segundo conjunto se corresponde con cada

2. Estado de la Cuestión

elemento del primero. Dentro de esta subtaska pueden distinguirse dos tipos de ejercicio según la relación que se establece entre ambos conjuntos: por un lado, aquellos en los que un mismo elemento del primer conjunto puede emparejarse con varios elementos del segundo, como en el ejemplo de la figura 2.3, donde cada persona puede responder a más de una pregunta; y por otro, aquellos en los que la asignación es uno a uno y el primer conjunto incluye elementos adicionales que actúan como distractores y no deben emparejarse con ningún elemento del segundo, como en el ejemplo de la figura 2.4.

TEXTO A (Alberto):

Los negocios son mi vida. No podría dedicarme a otra cosa, y estoy seguro de que es por mi padre porque siempre ha vivido con pasión todos sus proyectos. Mucha gente piensa que como mi papá ya era un importante empresario, para mí fueron muy fáciles las cosas, y para nada. A los 18 empecé la carrera de Administración de Empresas, y en ese tiempo hice de todo: de mesero, de teleoperador, de repartidor... Nada relacionado con mi carrera. Ahorita trabajo como empleado con mi padre, pero mis planes son instalarme fuera de México y abrir mi propia empresa de ropa.

TEXTO B (Daniel):

Mi carrera, Arquitectura, me encantaba, y soñaba con construir grandes rascacielos, aunque mis padres, que tenían una famosa bodega, querían verme dirigiéndola. Al terminar la universidad una amiga me llamó para preguntarme si quería trabajar en una revista para llevar paquetes por México D.F. y, como no tenía nada mejor, acepté. De ahí, pasé a administrativo y luego a comercial. Hace tres años el presidente se jubiló, hablamos, y le sugerí crear un canal de televisión, le pareció bien, y hoy soy el director general. Pienso que hacer lo que te gusta es felicidad, y el dinero al final llega, por eso me gustaría crear una empresa para ayudar a los jóvenes con buenas ideas.

TEXTO C (Martín):

Mi empresa de productos naturales de belleza es mi vida y a ella le he dedicado todo mi tiempo, Al principio no fue nada fácil e incluso estuvimos a punto de cerrar, pero pasados los primeros años, fuimos ganando fuerza e importancia en el sector y veintitrés años después, aquí estamos. Ha sido un gran esfuerzo, y todo esto sería imposible sin mi mujer, la directora del departamento comercial y de ventas. Dicen que soy una persona de éxito, pero para mí la mejor recompensa es cuando los clientes nos escriben y dicen que están contentos con los resultados. La verdad es que vendemos calidad a un precio económico por todo el mundo.

PREGUNTAS: Relacione las preguntas (13-18) con los textos (A, B o C).

- 13) ¿Quién tiene la intención de trabajar en el extranjero?
- 14) ¿Quién dice que el interés por los negocios le viene de su familia?
- 15) ¿Quién cuenta que los inicios de la empresa fueron complicados?
- 16) ¿Quién dice que trabaja ahora en algo que no tiene relación con sus estudios?
- 17) ¿Quién ha rechazado seguir con el negocio familiar?
- 18) ¿Quién ha trabajado siempre en lo mismo?

Figura 2.3.: Ejemplo de ejercicio de la subtaska de *matching* extraído del corpus IC-UNED-RC-ES (Peñas, Rodrigo, Fruns-Jiménez, Soria-Pastor, Moreno-Álvarez, Pérez et al. 2026), correspondiente a un examen de nivel B1, en el que un mismo elemento del primer conjunto puede emparejarse con varios elementos del segundo.

2. Estado de la Cuestión

ANUNCIOS DE EMPLEO:

A) Gesprotrad, empresa líder en el campo de la traducción, ofrece en su sede de Vitoria-Gasteiz un puesto para licenciados en Traducción con alemán. Se requieren conocimientos informáticos y disponibilidad horaria. No es necesaria experiencia previa. Se valorará positivamente el conocimiento de otros idiomas.

B) Si te interesan las nuevas tecnologías, y además eres traductor, este es tu sitio. GlobalQuest, el gran gigante de internet, ofrece un contrato de un año para traducción y maquetación de contenidos web. Requisitos: licenciatura en Traducción, alto nivel de inglés.

C) Somos una empresa de fabricación de botellas de plástico que necesita un traductor de español a francés y alemán para nuestra página web. No es necesaria formación específica ni experiencia previa. Precio fijo por el trabajo: 800 €. Posibilidad de futuras colaboraciones.

D) Seleccionamos traductores autónomos especializados en chino y japonés. Los pagos de los encargos se realizan a fin de mes, siempre puntuales. Formación gratuita a cargo de la empresa sobre las nuevas tecnologías. Trabaja con nosotros desde donde te encuentres.

E) Nuestra empresa selecciona para el departamento de Marketing un traductor de alemán e inglés. Funciones: traducción de documentos y asistencia como intérprete a reuniones comerciales. Requisitos: experiencia previa, licenciado en Traducción, niveles muy altos de inglés y alemán. Horario: lunes a viernes. 10:00-17:00.

F) Empresa de venta online selecciona un traductor español-inglés. Imprescindible que el inglés sea la lengua materna. El contrato es para la traducción de una web. No se requiere experiencia previa ni especialización. Trabajo en oficina de lunes a jueves de 9:00 a 14:00 y de 15:00 a 18:00 y viernes de 8:30 a 14:30.

G) Adecco TT necesita incorporar un traductor con un nivel alto de inglés o alemán para una nueva empresa. Necesaria experiencia mínima de dos años. Se ofrece: contrato temporal, salario: 14,64 €/hora. Trabajo en turno partido: de 9:00 a 13:00 y de 16:00 a 19:00. Incorporación inmediata.

H) Trabaja desde donde quieras realizando labores de búsqueda y contacto con clientes internacionales. Se necesita tener horario flexible, alto nivel de inglés hablado y escrito y ordenador con conexión a internet. No es necesario demostrar experiencia. Se valorará el conocimiento de otros idiomas.

I) Buscamos un profesional que hable alemán y francés para hacer traducciones de temas tecnológicos. Se ofrece la posibilidad de trabajar desde casa, aunque será necesario asistir una vez al mes a reuniones en nuestro centro en Madrid. Se ofrece contrato indefinido. Se necesitan conocimientos informáticos avanzados.

J) Importante empresa en el sector químico necesita traductor con experiencia en traducción de textos en inglés. Horario partido, imprescindible tener experiencia en la traducción de textos similares y tener vehículo propio.

PERSONAS QUE BUSCAN TRABAJO:

1) MARÍA

Estudié Traducción e Interpretación y me especialicé en lenguas orientales. Acabo de ser madre y necesito un trabajo que tenga horarios flexibles o, incluso, que me permita trabajar desde casa.

2) RAFAEL

Después de acabar Traducción e Interpretación en EE.UU. empecé a estudiar informática, mi otra gran pasión. Estoy buscando un trabajo para ganar algo de dinero mientras acabo mis estudios.

3) JOHN

En Escocia, mi país natal, estudié Traducción e Interpretación y trabajé un año como traductor en una empresa de publicidad. Ahora acabo de instalarme en Madrid y, por motivos personales, mi futuro trabajo tiene que tener horario continuado. Tengo muy buen nivel de alemán y hablo un poco de francés.

2. Estado de la Cuestión

4) PILAR

Estoy en el último año de carrera y estoy buscando trabajo para ganar algo de dinero mientras acabo mis estudios. Hablo francés y alemán.

5) ALFONSO

Estoy buscando un trabajo fijo en el que no tenga que ir todos los días a la oficina. Tengo carné de conducir y coche propio y conozco muy bien varios programas informáticos. Hablo alemán, francés e inglés a nivel bilingüe.

6) BELÉN

Hace poco terminé mis estudios de Traducción y quiero trabajar. He hecho varios cursos de informática y no me asusta el trabajo duro. Hablo alemán e inglés.

7) MIGUEL

Después de trabajar cinco años en Inglaterra, he vuelto a instalarme en Madrid. Por motivos familiares no puedo moverme de casa, pero tengo un buen equipo informático y wifi. No tengo problemas de horarios. Hablo inglés y alemán.

PREGUNTA: Relacione las personas (1-7) con los anuncios (A-J). HAY TRES ANUNCIOS QUE NO DEBE RELACIONAR.

Figura 2.4.: Ejemplo de ejercicio de la subtask de *matching* extraído del corpus IC-UNED-RC-ES (Peñas, Rodrigo, Fruns-Jiménez, Soria-Pastor, Moreno-Álvarez, Pérez et al. 2026), correspondiente a un examen de nivel B1, con asignación uno a uno y presencia de distractores.

- **Fill-the-gaps (rellenar huecos):** dado un texto con una serie de huecos, el sistema debe determinar la posición correcta para cada fragmento proporcionado como posible opción de respuesta, pudiendo tener más fragmentos que huecos disponibles. Un ejemplo de este tipo de ejercicio puede verse en la figura 2.5.

TEXTO:

Internet y la ortografía

Los avances tecnológicos en el campo de las comunicaciones han creado una serie de recursos de gran eficacia.

Un ejemplo significativo de esa nueva realidad es el caso de los ordenadores, incorporados de manera dominante a la vida contemporánea. [17]. Esto ha motivado, como respuesta adecuada a las necesidades actuales, el aprendizaje de su uso en la escuela.

Pero el empleo en la vida actual de unos medios tan importantes no está exento de efectos negativos.

[18]. Es alarmante que haya, en la mayoría de los mensajes, una cantidad tan alta de faltas de ortografía y de errores de redacción, lo que llega a oscurecer el contenido para los ojos de los no iniciados en mensajes crípticos. Este es el motivo de que algunos educadores hayan planteado que Internet está acabando con la ortografía, lo que ha originado un interesante debate sobre dicho tema.

[19]. El argumento principal es que no se cometen más errores ortográficos que antes, sino que ahora «se ven con más facilidad». También insisten en que habría que distinguir entre las faltas de ortografía y las abreviaturas, que suelen ser muy frecuentes, por razones de espacio, en todas las redes sociales.

[20]. Otro argumento, este bastante curioso, es que hay jóvenes que sí saben escribir correctamente, pero que en internet se niegan a hacerlo «porque si lo hiciesen, quedarían excluidos de su entorno». [21]

Por último, conviene recordar que los ordenadores ofrecen un recurso muy útil para escribir sin faltas: la corrección ortográfica. En cuanto se comete un error, el ordenador avisa, y el aviso debería servir para que el usuario consultara un medio tan «antiguo» como maravilloso, pero a menudo marginado por los adolescentes.

[22]

Así como casi nadie olvida los principios básicos matemáticos aprendidos en la escuela, nadie debería olvidar las normas de ortografía y de redacción, igualmente enseñadas en esa etapa básica de educación, porque, como señalan todos los expertos consultados, escribir mal conlleva a la larga una condena social.

FRAGMENTOS PROPUESTOS:

- A) En general, todos estos argumentos defienden que los errores ortográficos se deben a una enseñanza deficitaria y no a Internet.
- B) Pero también hay autores de prestigio que opinan que las nuevas tecnologías no van a producir «una catástrofe» en el idioma.
- C) Las primeras son fruto de la ignorancia, mientras que las segundas sirven para abreviar el texto y condensar el pensamiento.
- D) No obstante, son muchos los que sostienen que los avances tecnológicos ofrecen posibilidades ilimitadas.
- E) Por ejemplo, el uso de las nuevas tecnologías por parte de los adolescentes está provocando problemas con la expresión escrita.
- F) Se han vuelto imprescindibles en el trabajo, en el estudio, en las relaciones sociales y, también, en sus inagotables ofertas de juegos.
- G) Por ejemplo, se han analizado los efectos negativos que pueden resultar del empleo de esos medios.
- H) Se trata del diccionario, una herramienta de empleo indispensable y que tiene que estar siempre a mano.

PREGUNTA: Decida en qué lugar del texto (17-22) hay que colocar cada uno de los fragmentos propuestos (A-H). HAY DOS FRAGMENTOS QUE NO TIENE QUE ELEGIR.

Figura 2.5.: Ejemplo de ejercicio de la subtask de *fill-the-gaps* extraído del corpus IC-UNED-RC-ES (Peñas, Rodrigo, Fruns-Jiménez, Soria-Pastor, Moreno-Álvarez, Pérez et al. 2026), correspondiente a un examen de nivel B2.

Cabe destacar que este trabajo se ha centrado exclusivamente en las dos primeras subtasks, selección múltiple y emparejamiento, sin abordar la subtask de *fill-the-gaps*. Las soluciones propuestas para ambas se describen en detalle a lo largo del capítulo 3.

2.3.3.2. Evaluación y conjunto de datos

Para evaluar las soluciones presentadas por los participantes se utilizó el corpus IC-UNED-RC-ES⁹ (Peñas, Rodrigo, Fruns-Jiménez, Soria-Pastor, Moreno-Álvarez, Pérez et al. 2026), creado por el Instituto Cervantes a partir de exámenes oficiales y adaptado por la UNED para su uso en la evaluación de sistemas de inteligencia artificial. El conjunto de datos abarca todos los niveles del Marco Común Europeo de Referencia (MCER), desde A1 hasta C2, y comprende un total de 6.146 ejercicios de evaluación distribuidos entre las tres subtasks, tal como se muestra en la tabla 2.1. Con el objetivo de evitar la contaminación en el entrenamiento de los LLMs y preservar la validez de futuras evaluaciones, los organizadores decidieron no publicar el conjunto de datos, lo que supone una restricción adicional para los participantes al impedir cualquier tipo de ajuste supervisado sobre datos de la tarea.

⁹<https://zenodo.org/records/15790139>

2. Estado de la Cuestión

Tipo de Ejercicio	Número de Respuestas
Selección múltiple (<i>Multiple-choice</i>)	3544
Emparejamiento (<i>Matching</i>)	2309
Rellenar huecos (<i>Fill-in-the-gap</i>)	293
Total	6146

Tabla 2.1.: Distribución de número de respuestas del corpus IC-UNED-RC-ES por tipo de ejercicio.

La métrica de evaluación empleada es la misma que se utiliza con los alumnos que se examinan en este tipo de exámenes, concretamente el porcentaje de aciertos (*accuracy*) sobre el total de preguntas. Además, para esta edición se utilizó aproximadamente el 50 % de datos del corpus, reservando el resto para la edición de 2026, tal y como se detalla en la sección 3.3.

2.3.3.3. Soluciones propuestas para la subtask de selección múltiple

Antes de pasar a explicar las soluciones desarrolladas en el presente trabajo para PRO-FE 2026 (capítulo 3), resulta útil hacer un repaso de los diferentes enfoques propuestos por los equipos participantes en la edición anterior, con el objetivo de contextualizar el problema e identificar qué estrategias resultaron más efectivas. Como punto de partida, los organizadores establecieron un *baseline* en el que realizaron un *fine-tuning* de XLM-RoBERTa-Large (Conneau et al. 2019) sobre el corpus RACE, que obtuvo un 64,4 % de *accuracy* sobre el conjunto de *test*.

En total, cuatro equipos presentaron soluciones para esta subtask, con enfoques bastante diversos basados en *prompt engineering*, ajustar modelos *encoder-only* o construir un sistema multi-agente. Esta variedad de aproximaciones permite extraer conclusiones sobre qué estrategias pueden ser más efectivas a la hora de resolver la tarea.

En primer lugar, el equipo SINAI (Cantero-Romero y Jiménez-Zafra 2025) centró su propuesta en utilizar *prompt engineering* sobre el modelo comercial Gemini 2.0 Flash¹⁰, sin proporcionar al modelo ningún ejemplo previo ni realizar ningún tipo de ajuste adicional. El *prompt zero-shot* diseñado incluía instrucciones detalladas sobre el rol que debía asumir el modelo, los aspectos relevantes a considerar al leer el texto y el formato de salida esperado. Con esta aproximación alcanzaron un 91,14 % de *accuracy*, demostrando que un *prompt* bien diseñado puede explotar eficazmente la capacidad de comprensión inherente de los LLMs comerciales sin necesidad de ningún tipo de entrenamiento específico para la tarea.

El equipo JFra-Team (Fraile-Hernández y Peñas 2025) presentó un sistema más complejo basado en una arquitectura multi-agente implementada sobre el modelo Gemini 2.5 Flash¹¹. El sistema estaba compuesto por cuatro agentes con roles complementarios: un *responder agent* que seleccionaba la opción más probable dados el texto y la pregunta, un *blind responder agent* que generaba una respuesta libre sin ver las opciones disponibles, un conjunto de evaluadores que valoraban las opciones no seleccionadas por

¹⁰<https://docs.cloud.google.com/gemini-enterprise-agent-platform/models/gemini/2-0-flash?hl=es-419>

¹¹<https://docs.cloud.google.com/gemini-enterprise-agent-platform/models/gemini/2-5-flash?hl=es-419>

2. Estado de la Cuestión

el *responder*, y un *moderator agent* que arbitraba los desacuerdos y emitía la respuesta final. Este sistema alcanzó un 92,90 % de *accuracy*, siendo uno de los mejores resultados de la competición.

El equipo VICOMTECH (Platas et al. 2025) se centró en analizar si los modelos de lenguaje más pequeños podían alcanzar un rendimiento similar al de modelos comerciales de mayor tamaño. Para ello, evaluaron diferentes LLMs bajo una configuración *zero-shot*, desde DeepSeek R1 (D. Guo et al. 2025) (685B parámetros, 95,54 % de *accuracy*) hasta modelos de tamaño intermedio como Qwen 2.5 14B (Qwen et al. 2025) (90,90 %) y Gemma 3 12B (Team et al. 2025) (87,32 %), pasando por modelos más pequeños con entre 3 y 4 billones de parámetros que superaron el 80 % pese a su tamaño reducido. Una de sus conclusiones más relevantes fue que la ganancia en rendimiento relativa al incremento de tamaño no es tan grande como se podría esperar, ya que los modelos de entre 12 y 14B parámetros se situaron apenas 2 y 3 puntos por debajo de un modelo como DeepSeek R1, lo que los convierte en una alternativa competitiva con un coste computacional muy inferior. También exploraron el *fine-tuning* de un LLM con datos traducidos al español mediante traducción automática, pero los resultados no lograron superar los de las versiones base con *zero-shot prompting*, posiblemente porque los errores de traducción introdujeron ruido que perjudicó el aprendizaje. Por último, un *ensemble* de tres LLMs por mayoría de votos alcanzó el 89,67 %, ofreciendo una alternativa robusta a los modelos individuales más grandes. En contraste, los modelos de similitud semántica que evaluaron se quedaron lejos de los LLMs generativos, incluso de los más pequeños, evidenciando que la selección múltiple requiere un razonamiento que va más allá de la similitud léxica o semántica.

En esta misma línea, el equipo NIL-UCM (Winkler y Díaz 2025) llegó a una conclusión similar, aunque desde un enfoque distinto. Tras evaluar modelos de tipo *encoder-only* como BERT-large, RoBERTa-base y RoBERTa-large, preentrenados para tareas de extracción de respuestas (*extractive QA*) y adaptados mediante coincidencia de *tokens* al formato de opción múltiple, concluyeron que utilizar este tipo de arquitecturas no es el enfoque más adecuado para resolver tareas que requieren una comprensión profunda del texto, ya que la extracción de fragmentos literales no permite resolver preguntas cuya respuesta no aparece de forma explícita o exige inferencia.

A partir de este resultado, Anna-Maria Winkler continuó esta línea de investigación en su trabajo de fin de máster (Winkler 2026), explorando estrategias basadas en LLMs que permitieron alcanzar un rendimiento notablemente más alto y competitivo en esta misma subtask. Para ello, utilizó el modelo Mistral 7B Instruct (Mistral AI 2023) con un *prompt* que combinaba las técnicas de *role prompting* y *chain-of-thought* descritas en la sección 2.2.1. En ellas, asignaba al modelo el rol de examinador experto del Instituto Cervantes y le indicaba que siguiera un proceso de razonamiento estructurado, leyendo primero la pregunta, analizando después cada opción frente al contenido del texto, descartando las incorrectas con argumentos concretos y justificando finalmente su elección con la evidencia textual correspondiente.

2.3.3.4. Soluciones propuestas para la subtask de emparejamiento

En el caso de la subtask de emparejamiento, dos equipos presentaron soluciones basadas en diferentes enfoques. Por un lado, el equipo VICOMTECH (Platas et al. 2025)

2. Estado de la Cuestión

repitió la estrategia de evaluación de LLMs de diferentes tamaños y familias bajo una estrategia de *prompting zero-shot* que ya había aplicado en selección múltiple, obteniendo muy similares. DeepSeek R1 alcanzó un 98,23 % de *accuracy*, seguido de Gemini 2.0 Flash (98,11 %) y Claude Sonnet 3.7 (Anthropic 2025) (94,25 %), mientras que los modelos de tamaño intermedio se situaron en el rango del 88 % al 93 % y el *ensemble* por mayoría de votos alcanzó un 92,48 %. Estos resultados muestran que el emparejamiento es una tarea en la que los LLMs pueden aplicar un razonamiento global sobre todas las opciones que les permite identificar correspondencias incluso en presencia de distractores, sin necesidad de ningún tipo de ajuste específico para la tarea.

Por otro lado, los modelos basados en similitud semántica obtuvieron resultados notablemente peores. La estrategia que siguieron consistía en representar cada texto de ambos conjuntos como un *embedding* y seleccionar el emparejamiento más similar mediante la similitud del coseno. El mejor modelo de este tipo fue Ada (text-embedding-ada-002), con un 68,14 % de *accuracy* global, mientras que el resto de modelos de *embeddings* evaluados se situaron entre el 58 % y el 63 %. El *ensemble* de modelos de *embeddings*, pese a mejorar ligeramente los resultados individuales, alcanzó solo el 71,93 %, quedándose lejos de los resultados obtenidos utilizando técnicas de *prompting* con LLMs. Estos resultados reflejan que utilizar este enfoque para este tipo de tarea no es el más óptimo, ya que al calcular la similitud de forma independiente para cada par de textos, el sistema no tiene en cuenta que la asignación de una respuesta a una pregunta condiciona las opciones disponibles para el resto, lo que introduce errores que no pueden corregirse más adelante. Además, los modelos de *embeddings* mostraron dificultades crecientes en los niveles de competencia más avanzados, donde las relaciones semánticas entre textos son más sutiles y la presencia de distractores bien diseñados resulta más confusa para un sistema basado únicamente en similitud semántica.

En una línea similar, el equipo URJC (Rodríguez-García et al. 2025) también recurrió a la similitud semántica, aunque mediante *fine-tuning* supervisado de modelos *encoder-only* (RoBERTa, BETO y BERT) para estimar la similitud entre pares de textos, combinando sus predicciones mediante votación mayoritaria. Igual que sucedió con las aproximaciones de VICOMTECH que seguían esta misma idea, los resultados fueron bastante inferiores a los obtenidos con estrategias de *prompting* y se quedaron lejos de alcanzar un buen rendimiento en la tarea, lo que lleva a pensar que el ajuste de este tipo de modelos sobre datos externos no transfiere con suficiente precisión a los patrones específicos de los exámenes del Instituto Cervantes.

2.3.3.5. Síntesis y aprendizajes

El análisis de las soluciones presentadas en PROFE 2025 permite extraer varias conclusiones que han orientado directamente el desarrollo de este trabajo. En primer lugar, los LLMs bajo una configuración *zero-shot* demostraron ser una solución muy eficaz en ambas subtareas, superando notablemente tanto a los modelos *encoder-only* como a las estrategias basadas en similitud semántica o en *fine-tuning* sobre diferentes conjuntos de datos, que mostraron limitaciones importantes ante ejercicios que exigen un razonamiento global y coherente sobre los textos. En segundo lugar, los resultados de VICOMTECH evidenciaron que modelos de código abierto y tamaño moderado pueden ofrecer un rendimiento muy competitivo frente a los modelos comerciales de mayor tamaño, lo que

2. Estado de la Cuestión

abre la puerta a soluciones más accesibles desde el punto de vista computacional. Estas observaciones constituyen el punto de partida sobre el que se han diseñado las estrategias descritas en el capítulo 3.

3. Metodología y desarrollo

Este capítulo describe el proceso de desarrollo seguido a lo largo de todo el trabajo, que puede dividirse en tres etapas. En primer lugar, una primera fase exploratoria en la que se realizaron las primeras aproximaciones al problema de la comprensión lectora automática sin estar aún orientadas a ninguna competición concreta (sección 3.1). Esta etapa permitió identificar qué enfoques funcionaban mejor y sentar las bases de las decisiones posteriores en el desarrollo.

A partir de este primer acercamiento con la tarea, se presenta la competición PROFE 2026 en la que se pretendía participar (sección 3.2) y el conjunto de desarrollo construido para evaluar las distintas soluciones antes de los envíos oficiales (sección 3.3). El trabajo se centró completamente en esta tarea, desarrollando soluciones basadas en *prompting*, *fine-tuning* y sistemas multi-agente para tratar de resolver los ejercicios de la mejor forma posible. La sección 3.4 recoge en detalle todo este proceso de experimentación, comenzando por el entorno de ejecución y los modelos utilizados (sección 3.4.1) y continuando con las estrategias implementadas para cada una de las dos sub tareas abordadas: selección múltiple (sección 3.4.2) y emparejamiento (sección 3.4.3).

Finalmente, en la sección 3.5 se describe la participación en PROFE 2026, donde se seleccionaron algunas de las soluciones que mejores resultados habían dado durante la fase de experimentación y se enviaron para ser evaluadas con el conjunto de *test* oficial.

3.1. Primera aproximación al problema

Esta sección recoge el trabajo desarrollado como paso previo a la participación en PROFE 2026. El objetivo en esta fase no era aún competir, sino explorar qué técnicas podían funcionar mejor a la hora de resolver tareas de comprensión lectora en español. Para ello, se evaluaron dos aproximaciones principales: el *fine-tuning* de un modelo *encoder-only* y distintas estrategias de *prompt engineering* sobre LLMs de tamaño reducido. Los aprendizajes obtenidos resultaron determinantes para orientar las decisiones metodológicas del desarrollo posterior.

3.1.1. Tarea de referencia: ReCoRES 2022

Como marco de referencia para esta primera aproximación al problema se tomó la tarea ReCoRES¹ (*Reading Comprehension and Reasoning Explanation for Spanish*) (Diego Diestra y Rodrigo López y Erasmo Gómez y Arturo Oncevay y Fernando Alva-Manchego 2022), presentada en IberLEF 2022² (Gonzalo, Montes-y-Gómez y Rangel 2022), cuyo

¹<https://codalab.lisn.upsaclay.fr/competitions/1696>

²<https://sites.google.com/view/iberlef2022>

3. Metodología y desarrollo

dataset y resultados oficiales estaban disponibles públicamente. Esto permitió comparar los resultados obtenidos con los de los equipos participantes en aquella edición y, de esta forma, tener un punto de referencia sobre el que contextualizar el funcionamiento de las soluciones desarrolladas.

Tal y como se describe en la sección 2.3.2, la tarea ReCoRES plantea dos subtareas complementarias. Por un lado, dado un texto se debe seleccionar la respuesta correcta para una pregunta planteada, de forma análoga a los ejercicios de selección múltiple descritos en la sección 2.3.3.1 y, por otro, se pide generar una explicación que justifique la elección (figura 2.1).

Para poder evaluar los resultados de las distintas técnicas, se han tomado como referencia algunas de las métricas utilizadas en la tarea original. En ella, se utiliza *accuracy* para la tarea de seleccionar una respuesta para la pregunta, midiendo el porcentaje de preguntas acertadas y, para la segunda (explicación del razonamiento), se usa BERTScore (T. Zhang et al. 2019), que determina la similitud entre la explicación proporcionada en el *dataset* y la generada por el modelo.

Para medir los resultados de la segunda tarea se planteó el uso de otras métricas como BLEU (Papineni et al. 2002) o ROUGE (Lin 2004), que se basan en la coincidencia de palabras, por lo que los resultados podrían ser bastante bajos y poco representativos. Sin embargo, BERTScore, al utilizar un modelo tipo BERT preentrenado para generar *embeddings* y calcular la similitud entre el correspondiente a la explicación proporcionada y el de la explicación generada, es capaz de relacionar palabras sinónimas o que puedan utilizarse en contextos similares, de forma que la métrica es mucho más representativa y permite evaluar mejor la calidad de la explicación.

3.1.2. Fine-tuning con mDeBERTa

La primera aproximación para resolver la subtarea de selección múltiple consistió en aplicar *fine-tuning* sobre un modelo de tipo *encoder-only*. Como este tipo de arquitecturas no son capaces de generar texto, la estrategia se centró exclusivamente en la primera subtarea, de forma que dado un texto y una pregunta, el modelo debía estimar la probabilidad de que cada opción fuese la correcta y seleccionar aquella con mayor puntuación. Siguiendo esta idea, se ajustaron los pesos de un modelo de este tipo para que se especializase en responder a preguntas de comprensión lectora con varias opciones posibles y solo una respuesta correcta.

El modelo elegido fue mDeBERTa-v3-base (He, Gao y Chen 2021; He, X. Liu et al. 2021), perteneciente a la familia de modelos BERT y que destaca por ser más moderno y eficiente que otros predecesores más conocidos como XLM-RoBERTa (Conneau et al. 2019). La característica principal de mDeBERTa (*Multilingual Decoding-enhanced BERT with disentangled attention*) es que ha sido preentrenado con un corpus que incluye 100 idiomas diferentes, lo que le permite aprender representaciones semánticas compartidas entre el inglés y el español, por ejemplo, gracias a una arquitectura mejorada en el mecanismo de atención. Esto es muy necesario para el problema que se quiere resolver, pues el dataset ReCoRES³ cuenta con un número relativamente limitado de ejemplos en español, lo que dificulta que el modelo aprenda la tarea de razonamiento y comprensión

³<https://github.com/ddiestra/mrc-dataset>

3. Metodología y desarrollo

lectora si se entrena únicamente con ellos, pudiendo dar lugar a *overfitting* o a una incapacidad para generalizar bien ante nuevos textos.

Por este motivo, se ha optado por hacer uso también del dataset RACE (Lai et al. 2017), que contiene más de 28.000 textos con preguntas y varias opciones de respuesta extraídos de exámenes de inglés de educación secundaria y bachillerato en China. De esta forma, se puede proporcionar al modelo una gran cantidad de ejemplos de comprensión lectora en inglés, permitiéndole aprender patrones generales de razonamiento e inferencia que luego podrán transferirse al español.

Para aprovechar esta capacidad de transferencia entre idiomas, el proceso de *fine-tuning* se dividió en dos fases:

1. **Fine-tuning con el dataset RACE (Inglés):** Durante esta primera fase, se entrenó el modelo con 20.000 ejemplos del dataset RACE durante 2 *epochs*, llegando a alcanzar un *accuracy* del 64.66 % sobre el conjunto de validación.

Al evaluarlo sobre el conjunto de *test* de ReCoRES, sin haber visto aún ningún ejemplo en español, el modelo obtuvo un *accuracy* de tan solo el 27.72 %, lo que indica que la primera fase de entrenamiento no fue suficiente por sí sola para transferir la capacidad de razonamiento a este idioma.

2. **Fine-tuning con el dataset ReCoRES (Español):** En la segunda fase, el modelo se especializó con los ejemplos del propio dataset ReCoRES, con el objetivo de adaptar los pesos aprendidos en inglés a la tarea concreta en español. A pesar de esta especialización, los resultados finales no fueron muy prometedores, ya que tan solo se acertaron un 42.49 % de las preguntas sobre el conjunto de validación y un 40.93 % sobre el de *test*.

Fase	Conjunto de evaluación	Accuracy
Fine-tuning con RACE (inglés)	Validación RACE	64.68 %
Fine-tuning con RACE (inglés)	Test ReCoRES	27.72 %
Fine-tuning con ReCoRES (español)	Validación ReCoRES	42.69 %
Fine-tuning con ReCoRES (español)	Test ReCoRES	40.93 %

Tabla 3.1.: Resultados del *fine-tuning* de *mDeBERTa-v3-base* para cada fase del entrenamiento.

En la tabla 3.1 pueden verse los resultados obtenidos con esta estrategia, de la que se concluye que, con los modelos de lenguaje que existen actualmente, hacer un *fine-tuning* sobre un modelo *encoder-only* puede no ser la mejor aproximación, ya que es muy dependiente de la capacidad de cómputo disponible y de la calidad y cantidad de los datos necesarios para realizar el entrenamiento, siendo mucho más escasos en el idioma español para esta tarea específica. Es por ello que en el siguiente paso se decidió explorar otras aproximaciones basadas en *prompt engineering* que no tienen estas limitaciones.

3.1.3. Aproximaciones basadas en *prompting*

Tras comprobar las limitaciones del *fine-tuning*, se decidió probar con distintas técnicas de *prompt engineering* sobre modelos *decoder-only*. Este enfoque no requiere datos de entrenamiento etiquetados ni un proceso de ajuste de pesos, lo que lo convierte en una alternativa mucho más accesible y menos costosa desde el punto de vista computacional.

Para llevar a cabo todas estas pruebas, los modelos utilizados fueron Qwen2.5-7B-Instruct (Qwen et al. 2025) y Llama-3.1-8B-Instruct (Dubey et al. 2024), dos de los modelos *open source* más utilizados dentro del rango de 7 a 9 billones de parámetros. En ambos casos se utilizaron las versiones *instruct*, que incorporan una fase de ajuste supervisado y aprendizaje por refuerzo con retroalimentación humana, que les permite seguir instrucciones con mayor precisión y ajustarse mejor al formato de salida esperado.

3.1.3.1. Técnicas evaluadas

Durante esta fase del proyecto se probaron cuatro estrategias de *prompting* distintas, ordenadas de menor a mayor complejidad. En todas ellas, el modelo recibía el texto de referencia, la pregunta y las posibles opciones de respuesta, y se le pedía que generase su salida en un formato JSON estructurado, facilitando así el procesamiento automático de las respuestas. Los *prompts* completos utilizados en cada estrategia se recogen en el apéndice A.

La primera estrategia, *zero-shot* (figura A.1), enviaba directamente el texto y la pregunta al modelo, sin ningún ejemplo previo ni instrucciones adicionales sobre cómo razonar, con el objetivo de establecer una línea base que permitiese medir la capacidad de comprensión inherente de cada modelo para la tarea.

La segunda, *few-shot* (figura A.2), incorporaba en el *prompt* varios ejemplos simplificados que ya estaban resueltos, de forma que el modelo pudiese conocer cómo debía generar la explicación y cuál debía ser exactamente el formato de salida.

La tercera aproximación, cuyo *prompt* se muestra en la figura A.3, añadía *role prompting* a la estrategia *zero-shot*. En este caso, el modelo recibía una instrucción que le asignaba el rol de profesor experto en comprensión lectora, con el fin de orientar su comportamiento hacia un razonamiento más cuidadoso y contextualizado.

Por último, se decidió combinar el *role prompting* anterior con la técnica de *chain-of-thought* (figura A.4), obligando al modelo a generar explícitamente un razonamiento paso a paso antes de dar una respuesta definitiva. En este caso, se incluía un campo de razonamiento adicional en el formato de salida, donde el modelo debía descartar las opciones una a una basándose en la información del texto.

3.1.3.2. Resultados y análisis

La Tabla 3.2 recoge los resultados de *accuracy* obtenidos por cada modelo en las distintas estrategias probadas sobre el conjunto de validación de ReCoRES. En ella puede verse que los mejores resultados se han obtenido con el modelo Qwen2.5-7B-Instruct utilizando *zero-shot* con *role prompting*, seguido muy de cerca por la estrategia que utilizaba únicamente *zero-shot* con el mismo modelo.

3. Metodología y desarrollo

Estrategia	Qwen2.5-7B	Llama-3.1-8B
<i>Zero-shot</i>	77.13 %	69.97 %
<i>Few-shot</i>	76.31 %	68.60 %
<i>Zero-shot + role prompting</i>	77.50 %	69.10 %
<i>Zero-shot + role + CoT</i>	72.40 %	64.80 %

Tabla 3.2.: Resultados de *accuracy* en la tarea 1 (selección múltiple) sobre el conjunto de validación de ReCoRES según modelo y estrategia de *prompting*.

Comparando ambos LLMs, se aprecia una diferencia considerable entre ellos, alrededor de un 8 %. Observando las pruebas realizadas, Llama-3.1-8B-Instruct tenía más dificultades para ajustarse al formato de salida esperado independientemente de la estrategia utilizada, mientras que el modelo Qwen2.5-7B-Instruct no cometía este tipo de fallos, lo que podría ser una de las razones por las que existe esta diferencia entre ambos. La principal causa de este problema está relacionada con su entrenamiento, ya que Qwen destaca por su buen rendimiento en matemáticas y código, de forma que seguramente esté mucho más familiarizado que Llama con el formato JSON y, por ello, apenas comete errores a la hora de generar una respuesta con ese formato.

Dejando aparte esta diferencia, ambos modelos siguen un patrón de comportamiento muy similar en todas las estrategias, obteniendo los porcentajes de acierto más altos con *zero-shot* y *zero-shot* con *role prompting*, disminuyendo un 1 % al incluir ejemplos en el *prompt* (*few-shot*) y alrededor de un 5 % al pedir al modelo que razone paso a paso descartando una a una las opciones (*chain of thought*). Por ello, al contrario de lo que se puede pensar en un principio, utilizar un *prompt* más complejo puede no ser la mejor aproximación para la tarea con estas versiones cuantizadas de los modelos que se han utilizado.

Esto último puede deberse a que, al obligar al modelo a analizar el texto y realizar un razonamiento sobre el mismo, en algún punto del proceso cometa un error que arrastre en pasos posteriores y le lleve a una conclusión errónea, mientras que limitando este pensamiento, el modelo da una respuesta más directa y la probabilidad de que cometa un error durante el proceso de generación de la respuesta se reduce considerablemente. Además, utilizar una técnica como *chain of thought* hace que el modelo tenga que procesar y generar muchos más *tokens* y, por tanto, el tiempo que tarda en responder es mayor que al utilizar una estrategia *zero-shot*. Por ello, obligar a razonar a modelos tan pequeños parece no ser la estrategia más óptima para resolver esta tarea.

Comparando estos resultados con los obtenidos en el *fine-tuning* de *mDeBERTa-v3-base*, se observa que todas estas aproximaciones basadas en *prompt engineering* alcanzan unos resultados mucho mejores con una cantidad de datos mucho menor.

Por otro lado, para la segunda tarea, puede verse que ambos tienen una capacidad de razonamiento similar, ya que los resultados son prácticamente iguales (tabla 3.3). Además, entre las distintas estrategias de *prompting* utilizadas, apenas hay una diferencia de un 1 %, por lo que, igual que sucedía con la tarea anterior, pedir al modelo que razone más detenidamente tampoco supuso ninguna mejora en la calidad de las explicaciones generadas.

3. Metodología y desarrollo

Estrategia	Qwen2.5-7B	Llama-3.1-8B
<i>Zero-shot</i>	72.38 %	72.29 %
<i>Few-shot</i>	72.86 %	72.43 %
<i>Zero-shot + role prompting</i>	72.14 %	72.32 %
<i>Zero-shot + role + CoT</i>	71.60 %	71.88 %

Tabla 3.3.: Resultados de BERTScore F1 en la tarea 2 (explicación de la opción elegida) sobre el conjunto de validación de ReCoRES según modelo y estrategia de *prompting*.

Finalmente, al evaluar la mejor configuración (Qwen2.5-7B-Instruct con *zero-shot* y *role prompting*) sobre el conjunto de *test* de ReCoRES, se obtuvo un *accuracy* del 73.83 % en la tarea 1 y un F1 de *BERTScore* de 0.7238 en la tarea 2. Comparando estos resultados con los del mejor equipo participante en ReCoRES 2022, que alcanzó el 75.91 % mediante *fine-tuning* de un modelo BERT especializado en español, la diferencia se reduce a menos de 2 puntos porcentuales. Esta proximidad resulta especialmente significativa si se tiene en cuenta que la aproximación basada en *prompting* no requirió construir ningún *dataset* ni realizar ningún proceso de ajuste de pesos ni entrenamiento, lo que supone una reducción notable tanto en el coste computacional como en el tiempo de desarrollo.

Tras analizar todos los resultados, de esta primera fase exploratoria se extrajeron algunas conclusiones que ayudaron a orientar la siguiente fase del trabajo. La primera de ellas fue que el *prompting* sobre modelos *decoder-only* superaba al *fine-tuning* de modelos *encoder-only* cuando los datos de entrenamiento son escasos y los recursos computacionales están limitados, no solo en rendimiento sino también en versatilidad, ya que un mismo modelo puede resolver varias subtarefas simultáneamente. También quedó reflejado que en modelos de tamaño reducido, diseñar *prompts* más complejos no garantiza mejores resultados, ya que técnicas como *chain-of-thought* o *few-shot* no aportaron mejoras significativas e incluso perjudicaron el rendimiento en algunos casos, lo que apunta a que la capacidad de razonamiento de estos modelos tiene un techo claro con estas estrategias. Por último, cabe destacar que, si bien el *role prompting* no supuso una mejora significativa en esta tarea de dominio general, sí podría resultar útil en contextos más especializados, como la comprensión lectora en español con textos de niveles de competencia definidos.

3.2. Competición PROFE 2026

Antes de profundizar en las soluciones que se han explorado durante el desarrollo del proyecto, conviene explicar todo el contexto de la edición de la tarea PROFE que se ha propuesto para este año, explicando las novedades que se han introducido, las tareas concretas en las que se ha participado y el conjunto de datos utilizado para evaluarlas.

En primer lugar, la tarea PROFE 2026⁴ (Rodrigo et al. 2026), organizada dentro de la conferencia IberLEF 2026⁵ (Bonet-Jover, J. A. González-Barba y L. Chiruzzo 2026),

⁴<https://sites.google.com/view/profe2026>

⁵<https://sites.google.com/view/iberlef-2026/home>

3. Metodología y desarrollo

tiene el mismo objetivo que su predecesora (sección 2.3.3), que era evaluar la capacidad de comprensión lectora en español que tienen los sistemas automáticos al ser evaluados bajo las mismas condiciones que los humanos.

Igual que en los exámenes oficiales de idiomas en español, este año se han incluido imágenes en algunos de los ejercicios, de forma que los modelos deben ser capaces de procesar entradas multimodales. Además, estas nuevas imágenes no tienen por qué corresponderse siempre con una posible respuesta a los ejercicios planteados, sino que también pueden no aportar ninguna información útil para resolverlos e incluso servir como distractores. Esto supone una dificultad añadida respecto a la edición anterior, ya que las soluciones propuestas deben ser capaces de decidir si la imagen es útil para resolver el ejercicio y, por tanto, deben tenerla en cuenta. En el Apéndice B puede consultarse, para cada una de las dos subtareas abordadas, un ejemplo de ejercicio con imágenes tal y como lo vería una persona presentándose al examen (figuras B.1 y B.5), junto con el archivo JSON asociado a cada ejercicio (figuras B.2 y B.6), que es el formato que reciben y procesan los sistemas para resolverlo y con el que posteriormente se evalúan las respuestas generadas.

Con el objetivo de evaluar las soluciones propuestas por los participantes, los organizadores desarrollaron el *dataset* IC-UNED-RC-ES⁶ (Peñas, Rodrigo, Fruns-Jiménez, Soria-Pastor, Moreno-Álvarez, Pérez García-Plaza et al. 2026), descrito en la subsección 2.3.3.2, que no han hecho público, reservándose además el 50 % de los datos para poder evaluar las soluciones presentadas a la tarea de este año. De esta forma, se consigue evitar la posible contaminación durante el entrenamiento de los modelos de lenguaje y evitar el *overfitting* de las soluciones presentadas a la tarea, pudiendo así medir las capacidades reales de razonamiento y comprensión de estos sistemas al resolver este tipo de tareas.

De la misma forma que en la edición anterior, los organizadores propusieron tres subtareas dentro de la competición (sección 2.3.3.1), cada una correspondiente a un tipo distinto de ejercicio: *multiple choice*, *matching* y *fill the gaps*. El desarrollo de este trabajo se ha enfocado en las siguientes dos subtareas:

- **Selección Múltiple (*Multiple-choice*):** Dado un texto y una pregunta sobre él con varias opciones de respuesta, el sistema debe elegir la respuesta correcta. Debido al enfoque multimodal que incluyen algunos ejercicios en esta edición, algunas preguntas contienen imágenes como opciones de respuesta en lugar de texto, por lo que el sistema debe identificar la imagen que responde a la pregunta.
- **Emparejamiento (*Matching*):** En la tarea de emparejamiento para cada ejercicio se proporcionan dos conjuntos de textos y el sistema debe encontrar el texto del segundo conjunto que mejor encaja con cada elemento del primero. Solo hay una opción correcta por texto, pero el primer conjunto puede tener textos adicionales que sirven como distractores. Estos textos también pueden ir acompañados de imágenes que dan contexto visual o actúan como distractores, por lo que los sistemas deberán aprender a discernir correctamente.

En la tabla 3.4 puede verse la distribución de ejercicios que presenta el conjunto de *test* proporcionado para evaluar los sistemas para cada una de las tareas en las que se

⁶<https://zenodo.org/records/15790139>

ha participado.

Nivel	<i>Multiple Choice</i>		<i>Matching</i>
	Ejercicios	Preguntas	Ejercicios
A1	39	201	56
A1E	14	85	13
A2	245	488	54
A2B1E	4	24	12
B1	215	504	26
B1E	45	100	0
B2	97	306	4
C1	8	48	4
C2	54	162	20
Total	721	1918	189

Tabla 3.4.: Distribución de ejercicios y preguntas por nivel en las subtarefas de ejercicios de *multiple choice* y *matching*.

Para medir el rendimiento de los sistemas propuestos, se utiliza *accuracy* como métrica principal, pudiendo así comparar directamente cómo de buenos son esos sistemas respecto a los estudiantes humanos a la hora de resolver este tipo de exámenes en español. En el caso de la tarea de *multiple choice*, el *accuracy* se calcula como el porcentaje de preguntas respondidas correctamente y para la tarea de *matching*, como el porcentaje de textos que se han unido con la pareja adecuada.

Además de utilizar *accuracy*, los organizadores de la tarea también incentivaron a los participantes a registrar el consumo energético y la huella de carbono de las distintas soluciones mediante el uso de la librería Code Carbon⁷ (Courty, Schmidt, Goyal-Y et al. 2021). El objetivo es poder ver cómo aproximaciones con un rendimiento similar pueden conllevar costes computacionales y medioambientales muy diferentes, promoviendo de esta forma una comparativa más justa entre ellas y fomentando el desarrollo de soluciones más sostenibles y respetuosas con el medioambiente. Por ello, durante la ejecución de las distintas estrategias se han medido las emisiones totales en kilogramos de CO₂ equivalente (kgCO₂eq), junto con el *hardware* utilizado, detallando la GPU y la configuración de los entornos de ejecución.

El CO₂eq es una unidad de medida estandarizada que permite expresar el impacto climático de distintos gases de efecto invernadero (como el metano o el óxido nitroso, además del propio dióxido de carbono) en términos de la cantidad de CO₂ que produciría un calentamiento equivalente. En el contexto del consumo eléctrico asociado a la ejecución de modelos de lenguaje, esta equivalencia se calcula a partir de la energía consumida por el *hardware* y de la intensidad de carbono de la red eléctrica de la región donde se ejecuta el proceso, lo que permite comparar de forma homogénea el impacto medioambiental de soluciones ejecutadas en entornos o ubicaciones distintas.

Por otro lado, cabe destacar que el proceso de evaluación oficial se realizó a través

⁷<https://codecarbon.io/>

de la plataforma *CodaBench*⁸, donde la competición establecía un límite de cinco envíos para cada subtarea. Por este motivo, aunque durante la fase de desarrollo se ha evaluado el rendimiento de diferentes estrategias utilizando distintos modelos, para la fase final se seleccionaron las soluciones más representativas y diversas para poder comparar y obtener unos resultados y conclusiones útiles.

3.3. Conjunto de desarrollo para la tarea PROFE 2026

Como se explicó en la sección 2.3.3.2, los organizadores de la tarea PROFE 2026 han decidido seguir la misma política que en la edición anterior y no publicar el conjunto de datos oficial, con el objetivo de prevenir el sobreajuste y evitar la posible contaminación de los datos durante el entrenamiento de los LLMs, ya que podría dar lugar a métricas de evaluación engañosas. Por ello, la única información de la que se dispone son algunos ejemplos que aclaran la estructura de los ejercicios (apéndice B) y permiten que cada participante tenga una referencia para construir su propio conjunto de evaluación.

Para abordar este problema, se ha tomado como punto de partida el *dataset* construido manualmente por Anna-Maria Winkler como parte de su participación en la misma tarea durante la pasada edición (Winkler y Díaz 2025) y de su trabajo de fin de máster (Winkler 2026), que sirve como referencia para comparar las distintas soluciones desarrolladas a lo largo del proyecto.

El conjunto de datos se compone de 135 preguntas correspondientes a la tarea de *multiple choice*, que fueron extraídas del corpus IC-UNED-RC-ES (Peñas, Rodrigo, Fruns-Jiménez, Soria-Pastor, Moreno-Álvarez, Pérez García-Plaza et al. 2026). Sobre todo el conjunto de *test* utilizado durante la pasada edición de PROFE, Anna-Maria Winkler seleccionó un total de 100 preguntas repartidas en los niveles A1, A2, B1 y B2 del Marco Común Europeo de Referencia (MCER) y las resolvió manualmente para tener datos suficientes con los que poder comparar. Adicionalmente, dado que la edición de PROFE 2026 incluye ejercicios multimodales, el conjunto original de 100 preguntas se amplió con otras 35 procedentes de exámenes que incluyen imágenes como opciones de respuesta. En estos ejercicios, el sistema debe identificar cuál de las opciones (representadas por imágenes) responde correctamente a la pregunta planteada sobre el texto de lectura. Estos ejercicios adicionales se obtuvieron de las siguientes fuentes: ejemplo proporcionado por los organizadores de PROFE 2026⁹, exámenes publicados por el Instituto Cervantes¹⁰ y ejercicios publicados en la página web Profesores de ELE¹¹.

Como puede verse en la tabla 3.5, que recoge la distribución de exámenes, ejercicios y preguntas por nivel, el conjunto presenta un reparto heterogéneo entre niveles, con una representación mayor del nivel A1, que agrupa más de la mitad de las preguntas totales y todos los ejercicios que contienen imágenes. Esta desproporción refleja la disponibilidad de material en el corpus de origen, no una decisión de diseño del conjunto de datos.

En cuanto al número de opciones por pregunta, la tabla 3.6 muestra que existe una variación notable tanto entre niveles como dentro de un mismo nivel. El nivel A1 combina

⁸<https://www.codabench.org/competitions/15902/>

⁹<https://sites.google.com/view/profe2026/submission-and-dev-data>

¹⁰<https://exámenes.cervantes.es/es/dele/exámenes/a1>

¹¹<https://profesoresdeele.org/2020/05/28/examen-dele-a1/>

3. Metodología y desarrollo

preguntas de tres y cuatro opciones, con predominio de las de cuatro; los niveles A2 y B1 utilizan exclusivamente tres opciones; y el nivel B2 presenta en su mayor parte preguntas de tres opciones, aunque incluye tres preguntas con únicamente dos. Esta heterogeneidad, inherente al diseño de los exámenes originales del Instituto Cervantes, tiene implicaciones directas sobre la dificultad de cada nivel.

Nivel	Exámenes	Ejercicios	Preguntas	Preg. con img.
A1	16	16	71	7
A2	3	11	23	0
B1	4	4	21	0
B2	2	7	20	0
TOTAL	25	38	135	7

Tabla 3.5.: Distribución por nivel del MCER de los exámenes, ejercicios, preguntas y preguntas con imagen que componen el conjunto de desarrollo para la sub-tarea de selección múltiple.

Nivel	2 opciones	3 opciones	4 opciones
A1	0	20	51
A2	0	23	0
B1	0	21	0
B2	3	17	0

Tabla 3.6.: Número de opciones de respuesta por pregunta en el conjunto de desarrollo de la sub-tarea de selección múltiple, desglosado por nivel del MCER.

A nivel técnico, para poder evaluar los sistemas desarrollados, cada ejercicio del conjunto está representado en formato JSON y se identifica mediante un *id* único que incorpora el nivel, la fecha del examen y un índice de ejercicio (p. ej., A1_2010-11-19_E1). Cada ejercicio incluye el texto y las instrucciones correspondientes, asociados a una o varias preguntas, cada una con su propio identificador, su enunciado y un conjunto de opciones de respuesta. En los ejercicios multimodales, las opciones se representan mediante referencias a ficheros de imagen en lugar de texto, siguiendo la convención `img/{examId}_E{n}_Q{n}_{optionId}.png`. La figura B.2 muestra un ejemplo concreto de este formato.

Para la sub-tarea de *matching*, se construyó un conjunto reducido de 10 ejercicios con el objetivo de obtener una primera estimación del rendimiento de las soluciones antes de la evaluación oficial. Los ejercicios proceden de tres fuentes: los ejemplos publicados por los organizadores de PROFE 2026¹², exámenes oficiales del Instituto Cervantes¹³ y modelos de examen disponibles en el blog Tía Tula¹⁴. A diferencia del subconjunto de selección múltiple, este material abarca seis niveles de competencia (A1–C2), como puede verse en la tabla 3.7, que recoge la distribución por nivel los ejercicios del conjunto.

¹²<https://sites.google.com/view/profe2026/submission-and-dev-data>

¹³<https://exámenes.cervantes.es/es/dele/exámenes/a1>

¹⁴<https://blog.tiatula.com/2010/03/modelos-de-examen-dele.html>

3. Metodología y desarrollo

Nivel	Ejercicios	Textos a emparejar
A1	2	14
A2	1	6
B1	1	6
B2	4	37
C1	1	8
C2	1	8
Total	10	79

Tabla 3.7.: Distribución por nivel del MCER de los ejercicios y textos a emparejar que componen el conjunto de desarrollo para la subtask de emparejamiento.

En el Apéndice B puede consultarse un ejemplo representativo de cada subtask con su estructura completa.

3.4. Experimentación y desarrollo de soluciones

Esta sección describe el proceso de desarrollo y evaluación de las soluciones propuestas para las dos subtasks que se han tratado de resolver en este trabajo (*multiple choice* y *matching*). Los aprendizajes obtenidos durante la primera fase exploratoria (sección 3.1), permitieron orientar tanto la elección de los modelos con los que trabajar como las estrategias a seguir para resolver las tareas de la mejor forma posible. A partir de ahí, se siguió un proceso iterativo en el que cada aproximación se evaluó sobre el conjunto de desarrollo descrito en la sección 3.3, permitiendo comparar su rendimiento e identificar posibles mejoras antes de los envíos oficiales.

A continuación se explican detalladamente el entorno de ejecución y los modelos utilizados durante el proyecto, así como las estrategias que se han implementado para abordar las tareas propuestas en la competición PROFE 2026.

3.4.1. Entorno de ejecución y modelos utilizados

A lo largo de la fase de experimentación se han utilizado distintos modelos y entornos de ejecución en función de las necesidades de cada estrategia. En términos generales, las soluciones basadas en *prompting* y *fine-tuning* se ejecutaron en entornos de Google Colab, aprovechando tarjetas gráficas NVIDIA T4 y NVIDIA A100 según la disponibilidad. Para optimizar el uso de los recursos y no superar los límites gratuitos de la plataforma, todos los modelos locales se cargaron aplicando cuantización en 4 bits mediante la librería *Unsloth* (Unsloth Team 2026). Este es un *framework* de código abierto pensado para optimizar y acelerar los procesos de inferencia y *fine-tuning* de los LLMs, logrando reducir notablemente el consumo de memoria y multiplicando la velocidad de procesamiento al reescribir matemáticamente las operaciones internas que realizan estos modelos para hacerlas más eficientes. Además de facilitar el uso de un *hardware* más limitado, la librería garantiza la misma precisión que otros *frameworks* de entrenamiento

3. Metodología y desarrollo

como *Transformers* de Hugging Face (Hugging Face 2026), por lo que todo este proceso de desarrollo puede hacerse de una forma más ágil y rápida.

Por otro lado, como las tareas y los requisitos concretos de la tarea PROFE 2026 (entre ellos la inclusión de imágenes en algunos ejercicios), fueron concretándose según avanzaba el proyecto, los modelos utilizados en muchas de las estrategias fueron cambiando. Principalmente, se han utilizado modelos de código abierto de entre 7 y 9 billones de parámetros, algunos de ellos en sus versiones cuantizadas para ajustarse a los recursos disponibles. Los modelos concretos empleados en cada estrategia se detallan en las secciones correspondientes. No obstante, la decisión de utilizar modelos *open source* frente a modelos privados se debe, por un lado, a que ofrecen la libertad necesaria para ajustar todos los parámetros a las herramientas de cómputo a las que se tenía acceso, además de permitir un control total sobre el proceso de inferencia y entrenamiento.

Por su parte, para desarrollar el sistema multi-agente para la subtaska de emparejamiento (*matching*), no fue posible seguir esta idea, ya que eran necesarias muchas llamadas al modelo por cada ejercicio y el tiempo de respuesta con modelos locales era demasiado elevado como para desarrollar una solución correctamente y presentarla a la competición. Por ello, se decidió utilizar un modelo propietario a través de una API, concretamente Gemini 2.5 Flash Lite (Google Cloud 2025), que ofrece una combinación de velocidad, baja latencia y capacidad de razonamiento a un coste reducido, además de integrarse fácilmente con LangChain (LangChain, Inc. 2026), que fue el *framework* utilizado para construir esta solución. En la sección 3.4.3.2 se detalla el uso concreto que hace de este modelo cada uno de los agentes del sistema.

Por último, con el objetivo de medir no solo el rendimiento sino también la eficiencia de cada estrategia, se registró el consumo energético y la huella de carbono de las ejecuciones mediante la librería CodeCarbon¹⁵ (Courty, Schmidt, Goyal-Y et al. 2021), midiendo las emisiones en kilogramos de CO₂ equivalente (kgCO₂eq). Esto permite comparar soluciones con un rendimiento similar desde una perspectiva más amplia, que tiene en cuenta el coste computacional y medioambiental de cada una de ellas.

3.4.2. Selección múltiple

Con el objetivo de resolver la subtaska de *multiple choice* de la mejor forma posible, se exploraron distintas estrategias de forma progresiva, partiendo de aproximaciones sencillas basadas en *prompting* hasta llegar a soluciones más complejas. De esta forma, se podía establecer un *baseline* que permitiese medir la capacidad inherente de los modelos para resolver este tipo de ejercicios sin ningún tipo de adaptación, y además, que sirviese de referencia para comprobar si las estrategias más complejas suponían una mejora notable. En el Apéndice B puede consultarse un ejemplo de ejercicio real de esta subtaska, junto con su archivo JSON asociado (figuras B.1 y B.2).

3.4.2.1. *Zero-shot prompting*

Tomando como punto de partida las conclusiones de la primera aproximación a la tarea con el conjunto ReCoRES (sección 3.1), donde las estrategias de *prompting zero-shot*

¹⁵<https://codecarbon.io/>

3. Metodología y desarrollo

habían sido las que mejor habían funcionado, se decidió explorar una primera solución siguiendo la misma idea enfocada a PROFE 2026. Para ello, se diseñaron dos variantes:

- **Zero-shot con respuesta directa:** el *system prompt* de la figura 3.1 asigna al modelo el rol de profesor experto en comprensión lectora en español, le indica que base su respuesta exclusivamente en la información del texto y le obliga a devolver únicamente la letra de la opción correcta, sin ningún texto adicional.
- **Zero-shot con justificación breve** (figura 3.2): se añade un campo de justificación breve en formato JSON, de forma que el modelo debe explicar de forma concisa por qué ha elegido esa opción antes de emitir su respuesta, siguiendo el mismo esquema empleado en la tarea ReCoRES. El objetivo era comprobar si el simple hecho de tener que escribir un porqué sobre la elección mejoraba la precisión del modelo. Cabe destacar que se le pide generar primero este breve razonamiento para reducir las probabilidades de que responda una opción aleatoria y después trate de justificarla.

System prompt: “Eres un profesor experto en resolver de exámenes de comprensión lectora en español. Tu tarea es leer atentamente el texto y responder ÚNICAMENTE con la letra de la opción correcta. Las ÚNICAS opciones de respuesta válidas son: {letras_validas}

Responde a la pregunta basándote EXCLUSIVAMENTE en la información del texto, sin utilizar conocimiento externo.

No escribas explicaciones, ni introducciones, ni repitas la pregunta. SOLO la letra de la opción elegida.”

Figura 3.1.: *System prompt* definido para obtener directamente la respuesta a una pregunta de selección múltiple siguiendo una estrategia *zero-shot*.

Inicialmente, esta estrategia se probó con los modelos Mistral 7B Instruct (Mistral AI 2023), Qwen 2.5 7B Instruct (Qwen et al. 2025) y Qwen 3.5 9B (Qwen Team 2026). Una vez que los organizadores incorporaron imágenes a los ejercicios, esta estrategia también se evaluó sobre Gemma 4 E4B (Google DeepMind 2026) en sus versiones cuantizadas en 4 bits y sin cuantizar, para comprobar si esta compresión afectaba notablemente al rendimiento.

La tabla 3.8 muestra los resultados desglosados por nivel obtenidos sobre el conjunto de desarrollo (sección 3.3) con los diferentes modelos. En ellos, puede verse una clara diferencia entre Mistral y las otras dos familias de modelos, que consiguen alcanzar entre un 10 % y un 15 % más de *accuracy* global con esta estrategia. Entre los modelos multimodales, Qwen 3.5 9B sin cuantizar alcanza el mejor resultado global con un 91.85 %, mientras que su versión cuantizada baja hasta el 85.93 %, lo que indica que la reducción de precisión numérica tiene un impacto notable sobre este modelo a la hora de resolver esta tarea de comprensión lectora. En cambio, Gemma 4 E4B obtiene exactamente el mismo resultado en *zero-shot* con y sin cuantizar (86.67 %), lo que sugiere que su arquitectura puede ser menos sensible frente a este tipo de compresión.

System prompt: “Eres un profesor experto en resolver de exámenes de comprensión lectora en español. Tu tarea es leer el texto y responder ÚNICAMENTE con la letra de la opción correcta. Las ÚNICAS opciones de respuesta válidas son: {letras_validas}

Responde a la pregunta basándote EXCLUSIVAMENTE en la información del texto, sin utilizar conocimiento externo.

No escribas explicaciones, ni introducciones, ni repitas la pregunta. Debes responder EXCLUSIVAMENTE con un objeto JSON válido, sin incluir explicaciones previas ni posteriores. El formato debe ser ESTRICTAMENTE este:

```
{
  “razonamiento”: “Aquí escribes una breve explicación de la respuesta elegida basándote en el texto.”,
  “respuesta”: “Aquí escribes SOLAMENTE la letra de la opción correcta (A, B, C, D...)”
}
```

Figura 3.2.: *System prompt* definido para obtener directamente la respuesta a una pregunta de selección múltiple junto a un razonamiento breve en formato JSON

Respecto a la variante del *system prompt* donde se le pide a los modelos que generen una breve justificación antes de responder, el patrón de comportamiento varía según el modelo. En los casos de Mistral y Qwen, añadir la explicación no mejora el resultado global e incluso lo empeora ligeramente, lo que refleja que forzarles a escribir el motivo de su elección no les ayuda a tener más aciertos. Sin embargo, con Gemma sí hay una ligera mejora, que es especialmente notable en las preguntas que contienen imágenes, lo que puede indicar que en estos casos la breve explicación sí puede ser útil, aunque al tener solo 7 preguntas dentro de ese grupo no pueden sacarse conclusiones claras sobre si realmente supone una mejora en el rendimiento de los modelos.

3.4.2.2. *Few-shot prompting*

Con el objetivo de comprobar si proporcionar al modelo ejemplos concretos de resolución mejoraba su rendimiento respecto al *zero-shot*, se evaluó una estrategia de *few-shot prompting* sobre Gemma 4 E4B cuantizado. La estrategia mantiene el mismo *system prompt* que la aproximación basada en *zero-shot* (figura 3.1), añadiendo en el *user prompt* dos ejemplos completos (texto, pregunta, opciones y respuesta correcta) para que el modelo pudiese tomar como referencia antes de resolver a la pregunta real.

Dado que los dos ejemplos incluidos en el *prompt* forman parte del conjunto de desarrollo, fueron excluidos de la evaluación para evitar que el modelo los hubiese visto previamente, por lo que los resultados se obtienen sobre 133 preguntas en lugar de las 135 habituales. Los resultados, recogidos en la tabla 3.9, muestran una precisión global del 83.46 %, inferior a la obtenida por el mismo modelo con *zero-shot* (86.67 %) y con

3. Metodología y desarrollo

Modelo	Estrategia	A1	Img. (A1)	A2	B1	B2	Total
Mistral 7B	<i>Zero-shot</i>	77.78 %	-	65.22 %	76.19 %	70.00 %	73.00 %
	<i>Zero-shot + Exp.</i>	80.56 %	-	60.87 %	66.67 %	75.00 %	72.00 %
Qwen 2.5 7B	<i>Zero-shot</i>	86.11 %	-	78.26 %	85.71 %	80.00 %	83.00 %
	<i>Zero-shot + Exp.</i>	75.00 %	-	82.61 %	76.19 %	85.00 %	79.00 %
Qwen 3.5 9B (sin cuant.)	<i>Zero-shot</i>	94.37 %	71.43 %	91.30 %	90.48 %	85.00 %	91.85 %
	<i>Zero-shot + Exp.</i>	-	-	-	-	-	-
Qwen 3.5 9B (cuant.)	<i>Zero-shot</i>	88.73 %	71.43 %	78.26 %	85.71 %	85.00 %	85.93 %
	<i>Zero-shot + Exp.</i>	86.11 %	-	82.61 %	80.95 %	85.00 %	84.00 %
Gemma 4 E4B (sin cuant.)	<i>Zero-shot</i>	91.55 %	71.43 %	78.26 %	80.95 %	85.00 %	86.67 %
	<i>Zero-shot + Exp.</i>	-	-	-	-	-	-
Gemma 4 E4B (cuant.)	<i>Zero-shot</i>	91.55 %	71.43 %	78.26 %	80.95 %	85.00 %	86.67 %
	<i>Zero-shot + Exp.</i>	92.96 %	85.71 %	73.91 %	90.48 %	80.00 %	87.41 %

Tabla 3.8.: Comparativa de precisión (*accuracy*) entre las estrategias *Zero-shot* y *Zero-shot* con explicación para los diferentes modelos según el nivel de dificultad de los ejercicios.

CoT (88.15 %). El rendimiento desciende en todos los niveles respecto a las estrategias anteriores, con caídas especialmente pronunciadas en B1 (76.19 %) y A2 (78.26 %). Las preguntas con imagen también empeoran respecto al *zero-shot*, pasando del 71.43 % al 57.14 %, lo que sugiere que los ejemplos de texto incluidos en el *prompt* no aportan una referencia útil para razonar sobre opciones representadas visualmente y pueden introducir ruido en el proceso de inferencia. Como esta estrategia obtuvo el peor resultado global de todas las exploradas para esta subtask, no se continuó evaluando con otros modelos.

Modelo	Estrategia	A1	Img. (A1)	A2	B1	B2	Total
Gemma 4 E4B	Few-shot ^a	87.14 % (61/70)	57.14 % (4/7)	78.26 % (18/23)	76.19 % (16/21)	84.21 % (16/19)	83.46 % (111/133)

^a El conjunto total evaluado consta de 133 preguntas debido a que 2 ejercicios fueron incluidos de forma fija como ejemplos (*few-shot*) dentro del *user prompt*.

Tabla 3.9.: Desglose detallado de la precisión (*accuracy*) por niveles de dificultad y presencia de imágenes para el modelo Gemma 4 E4B utilizando una configuración *few-shot*.

3.4.2.3. Chain-of-Thought y autoconsistencia

Dado que algunos ejercicios contienen distractores o requieren realizar un razonamiento, ya que la respuesta no aparece de forma explícita en el texto, se exploró si forzar al modelo a razonar paso a paso antes de seleccionar una respuesta mejoraba los resultados obtenidos con *zero-shot*, siguiendo una estrategia *Chain-of-thought* (*CoT*). Para guiar al modelo se diseñó el *prompt* de la figura 3.3, que le asigna el rol de experto en resolver exámenes de comprensión lectora, igual que en estrategias anteriores, y establece las siguientes directrices a la hora de generar el razonamiento:

3. Metodología y desarrollo

- **Análisis global del texto:** Se le exige evaluar el texto como una unidad, prestando atención a elementos sintácticos y semánticos como los marcadores del discurso, los tiempos verbales y los pronombres. Haciendo hincapié en que la respuesta no tiene por qué aparecer explícitamente en el texto.
- **Descarte argumentado:** El modelo debe analizar todas las alternativas disponibles y descartar las incorrectas una a una. Cada opción descartada debe estar respaldada por argumentos claros basados exclusivamente en el texto.
- **Mitigación de sesgos:** Se instruye de forma explícita al modelo para que ignore la longitud de las opciones de respuesta, evitando la suposición de que una opción más larga es necesariamente la correcta.
- **Estructuración de salida:** Para garantizar un correcto procesamiento de la salida, se obliga al modelo a devolver su respuesta estrictamente en un formato JSON válido, dividida en dos campos: razonamiento (explicación paso a paso) y respuesta (letra final seleccionada).

Esta estrategia se ha evaluado sobre los modelos Mistral 7B, Qwen 3.5 9B y Gemma 4 E4B cuantizado. Los resultados, recogidos en la tabla 3.10, muestran un comportamiento heterogéneo entre modelos. En Mistral 7B, utilizar *CoT* empeora el rendimiento respecto al *zero-shot* (sección 3.4.2.1) en un 3 % (del 73 % al 70 %), lo que confirma las limitaciones de este modelo para mantener una cadena de razonamiento larga y coherente. Qwen 3.5 9B obtiene un 85 %, también por debajo de su mejor resultado en *zero-shot* sin cuantizar (91.85 %), aunque el caso más destacable es el de Gemma 4 E4B cuantizado, que con *CoT* alcanza un 88.15 %, superando su mejor resultado en *zero-shot* (86.67 %). Esto sugiere que, a diferencia otros modelos, Gemma 4 E4B tiene suficiente capacidad para beneficiarse del razonamiento, lo que le permite tener un mejor rendimiento en la tarea.

Por otro lado, también se hicieron pruebas con una evolución de esta estrategia llamada autoconsistencia (*self-consistency*) (Schulhoff et al. 2025), donde en lugar de generar una única respuesta, el modelo respondía a cada pregunta siguiendo tres cadenas de razonamiento independientes, seleccionando como respuesta final la opción más repetida. Para garantizar que cada razonamiento explorase un camino distinto, se fijó la temperatura en 0.7 y el parámetro *top-p* en 0.95. Es importante mencionar que en el punto del desarrollo en el que se realizaron estas pruebas, la inclusión de imágenes en los ejercicios aún no había sido confirmada por los organizadores y, por tanto, aún no se había utilizado Gemma 4 en ninguna de las estrategias. Por ello, esta aproximación se evaluó únicamente sobre Qwen 3.5 9B, que era el modelo que mejores resultados había obtenido hasta ese momento tanto en *zero-shot* como en *CoT*. Observando los resultados puede verse que la autoconsistencia mejoró ligeramente el resultado del *CoT* sobre este modelo, pasando del 85 % al 86 %, pero sin llegar a superar el *accuracy* obtenido en *zero-shot* sin cuantizar. Por tanto, la variabilidad entre razonamientos no aportó, información adicional suficiente como para compensar el mayor coste computacional que implica generar tres razonamientos y respuestas por pregunta.

3.4.2.4. Ensemble multi-agente (*LLM-as-a-Judge*)

La tercera estrategia propuesta surge como evolución de las dos anteriores, con el objetivo de combinar las fortalezas de distintos modelos y reducir los errores individuales

3. Metodología y desarrollo

System prompt: “Eres un profesor experto en resolver exámenes de comprensión lectora en español. Tu tarea es leer atentamente el texto, analizarlo y seleccionar la opción correcta para la pregunta planteada. Se te proporcionará un texto, una pregunta y sus opciones de respuesta.

Para analizar el texto y responder, ten en cuenta:

1. **LIMITATE AL CONTENIDO DEL TEXTO:** Ignora cualquier conocimiento externo o sesgo personal. La validez de una opción depende exclusivamente de la información (explícita o implícita) del texto.
2. **NO TE GUÍES POR LA EXTENSIÓN:** Una opción más larga no es necesariamente la correcta.
3. **ANÁLISIS GLOBAL:** Evalúa el texto como una unidad (apóyate en marcadores del discurso, tiempos verbales y pronombres). La respuesta correcta puede no estar escrita literalmente; busca equivalencias de significado.
4. **DESCARTE ARGUMENTADO:** Evalúa todas las alternativas y descarta las incorrectas una a una, aportando argumentos claros de por qué el texto las contradice o no las respalda.

Responde **EXCLUSIVAMENTE** con un objeto JSON válido, sin texto adicional antes ni después, y sin bloques de código markdown.

El formato debe ser **ESTRICTAMENTE** este:

```
{
  "razonamiento": "Razonamiento completo, descartando cada opción incorrecta con argumentos del texto.",
  "respuesta": "Escribe ÚNICAMENTE la letra de la opción correcta entre las siguientes: {letras_validas}"
}
```

Figura 3.3.: *System prompt* de la estrategia *chain-of-thought* para la subtarea de selección múltiple, que obliga al modelo a descartar las opciones incorrectas una a una antes de emitir su respuesta final en formato JSON.

que cada uno de ellos podría cometer de forma aislada. La idea principal es que la diversidad de respuestas entre modelos puede compensar los casos en que un único modelo falla, ya sea por no detectar un distractor o por no captar información implícita en los textos o preguntas más complejos.

El flujo de trabajo que sigue esta solución es el que se muestra en la figura 3.4 y se divide en dos etapas principales:

- **Fase 1: Generación de respuestas independientes.** En esta primera fase, tres modelos multimodales (Qwen 3.5 9B, Gemma 4 E4B y Ministral 3 8B), responden de forma independiente a cada pregunta bajo la misma configuración *zero-shot*

3. Metodología y desarrollo

Modelo	Estrategia	A1	Img. (A1)	A2	B1	B2	Total
Mistral 7B	<i>CoT</i>	69.44 %	-	69.57 %	66.67 %	75.00 %	70.00 %
Qwen 3.5 9B	<i>CoT</i>	86.11 %	-	82.61 %	85.71 %	85.00 %	85.00 %
	<i>Autoconsistencia</i>	86.11 %	-	86.96 %	85.71 %	85.00 %	86.00 %
Gemma 4 E4B (cuant.)	<i>CoT</i>	91.55 %	85.71 %	86.96 %	85.71 %	80.00 %	88.15 %

Tabla 3.10.: Comparativa de precisión (*accuracy*) bajo las estrategias de *Chain of Thought* (CoT) y Autoconsistencia, desglosada por nivel de dificultad y rendimiento global para cada modelo.




Figura 3.4.: Arquitectura del sistema *ensemble* multi-agente para la subtask de selección múltiple, donde tres modelos responden de forma independiente y un agente juez (*LLM-as-a-Judge*) arbitra en caso de discrepancia.

3. Metodología y desarrollo

descrita en la sección 3.4.2.1, aportando así variedad en la toma de decisiones inicial.

- **Fase 2: Consenso y veredicto del Juez (*LLM-as-a-Judge*).** Durante la segunda fase, el sistema evalúa el nivel de acuerdo entre las tres respuestas, comprobando si hay unanimidad para aceptar esa opción como respuesta final, o si hay algún desacuerdo, caso en el que el modelo Gemma 4 E4B asume el rol de juez y debe tomar una decisión teniendo en cuenta las opciones en conflicto.

Para guiar el comportamiento de este modelo, se diseñó un *system prompt* (figura 3.5) específico que le asigna el rol de un profesor que debe resolver discrepancias entre alumnos que han dado respuestas distintas para una misma pregunta. Para ello, se le indica que debe analizar de forma crítica las opciones, basándose exclusivamente en el texto y devolviendo únicamente la letra de la opción correcta.

Además de las instrucciones de sistema, el *user prompt* se construye de forma dinámica, pasándole al modelo el texto base, la pregunta, todas las opciones posibles y un aviso explícito que detalla la distribución de los votos previos emitidos por el *ensemble* en la fase anterior, lo que permite que el juez tenga en cuenta la tendencia general antes de tomar su decisión definitiva.

Debido al poco tiempo disponible entre la confirmación oficial de la inclusión de imágenes en los ejercicios y el cierre del plazo para los envíos, esta estrategia no llegó a evaluarse sobre el conjunto de desarrollo. Los resultados obtenidos en la competición oficial se discuten en el capítulo 4.

3.4.2.5. *Fine-tuning*

La última estrategia explorada para esta subtaska consistió en realizar un *fine-tuning* del modelo Gemma 4 E4B sobre datos de ejercicios con unas características similares. El objetivo era comprobar si adaptar los pesos del modelo a este tipo de ejercicios mejoraba su rendimiento respecto a los enfoques basados en *prompting*, especialmente en los niveles de dificultad más altos donde los resultados anteriores habían sido más irregulares.

El conjunto de datos utilizado para realizar este entrenamiento fue el de la tarea ReCoRES, descrito en la sección 3.1, compuesto por 439 textos y 1 822 preguntas extraídas de exámenes de acceso a universidades peruanas. Dado que este conjunto no incluye imágenes, durante el entrenamiento se congelaron los pesos de las capas encargadas de procesar entradas visuales, limitando la actualización de gradientes a las capas de lenguaje y los módulos de atención. Antes del entrenamiento, los datos se preprocesaron para adaptarlos a la tarea, eliminando la subtaska de generación de explicaciones, ajustando el modelo para devolver únicamente la letra correcta, y se mantuvo la variabilidad original en el número de opciones por pregunta (entre 2 y 7) para evitar que el modelo se sobreajustase a una longitud de salida concreta.

El *fine-tuning* se realizó mediante QLoRA (Dettmers et al. 2023) sobre los 1.047 textos de entrenamiento del dataset ReCoRES. Este ajuste de pesos se realizó durante 3 *epochs* sobre una GPU NVIDIA A100, llegando a un tiempo total de entrenamiento de unos 15 minutos, lo que era razonablemente rápido. Los hiperparámetros principales fueron un tamaño de lote de 16, una tasa de aprendizaje de 2×10^{-4} con un planificador lineal

3. Metodología y desarrollo

System prompt: “Eres un profesor experto en resolver exámenes de comprensión lectora en español. Tu tarea es resolver las discrepancias entre alumnos que han dado respuestas distintas a una misma pregunta. Para ello debes leer atentamente el texto y responder ÚNICAMENTE con la letra de la opción correcta.

Instrucciones:

1. Lee atentamente el texto, la pregunta, las opciones y el aviso con las respuestas de los alumnos.
2. Analiza críticamente las opciones en disputa de forma clara, lógica y concisa. Ve directo al grano: argumenta qué evidencia del texto apoya a la opción correcta y qué cosas invalidan a las demás, sin divagar.
3. Basa tu análisis EXCLUSIVAMENTE en la información proporcionada, sin utilizar ningún tipo de conocimiento externo.
4. Tras finalizar tu razonamiento interno, debes responder ÚNICAMENTE con la letra de la opción correcta.

Las ÚNICAS opciones de respuesta válidas son: {letras_validas}

IMPORTANTE: Fuera de tu bloque de pensamiento, no escribas texto adicional, justificaciones, puntos ni introducciones. Tu salida final debe ser estrictamente UNA sola letra.”

Figura 3.5.: *System prompt* del agente juez en la estrategia *ensemble* multi-agente, encargado de arbitrar entre las opciones en conflicto cuando los tres modelos no alcanzan un acuerdo unánime.

y 12 pasos de calentamiento, un optimizador AdamW en 8 bits y una penalización por peso (*weight decay*) de 0.01. El rango de adaptación se fijó en $r = 16$ con un valor de escala $\alpha = 16$. La figura 3.6 muestra el formato con el que se estructuraron los datos para realizar este entrenamiento.

A lo largo de las tres épocas, la pérdida de entrenamiento descendió progresivamente (0.272, 0.258 y 0.243), mientras que la pérdida de validación mostró un ligero repunte en la segunda época antes de recuperarse en la tercera (0.935, 0.929 y 0.942), algo normal teniendo en cuenta que el conjunto de validación tan solo incluía unos 300 textos, por lo que no puede concluirse que hubiese un sobreajuste claro.

Al igual que ocurrió con la estrategia de *ensemble* (sección 3.4.2.4), el tiempo disponible entre la confirmación oficial de la inclusión de imágenes y el cierre del plazo de envíos no permitió evaluar esta solución sobre el conjunto de desarrollo, por lo que los resultados obtenidos se discuten directamente en el capítulo 4.

3. Metodología y desarrollo

Formato de entrada de datos:

<|turn>system

Eres un profesor experto en resolver exámenes de comprensión lectora en español. Tu tarea es leer atentamente el texto y responder ÚNICAMENTE con la letra de la opción correcta. Las ÚNICAS opciones de respuesta válidas son: A, B, C

Responde a la pregunta basándote EXCLUSIVAMENTE en la información del texto, sin utilizar conocimiento externo.

No escribas explicaciones, ni introducciones, ni repitas la pregunta. SOLO la letra de la opción elegida.

<turn|>

<|turn>user

Texto: Los sectores conservadores aman reprimir. Es la forma de conservar su poder. Reprimir y embrutecer. Mucha bala poca escuela. De ahí todo este rollo sobre la inseguridad. Millones salen y vuelven cada día a sus hogares sin ver, incluso, otra violencia que no sea la que genera la injusticia. Es decir, aquello que los medios no llaman violencia: niños mendigando, colas interminables para una cita médica, maestros peor pagados... imposible. Tuberculosis, mucha tuberculosis, con una “clase media” que accedió a esa privilegiada posición acompañada por el miserable bacilo de Koch, universidades privadas que enseñan a vivir fuera de la realidad, etc. Estar mejor, para un enfermo, no es estar sano. Suscriban, sin triunfalismos, el “hermanos hay muchísimo por hacer” de César Vallejo. Entiendan que sin inclusión social cualquier proyecto es ilusión.

Pregunta: Según lo leído la injusticia

Opciones:

A) Es denunciada y debatida por los medios

B) Constituye el principal problema del país

C) Resulta mas tolerante que la enfermedad

<turn|>

<|turn>model

B

<turn|>

Figura 3.6.: Formato de los datos de entrenamiento utilizados en el *fine-tuning* de Gemma 4 E4B sobre el *dataset* ReCoRES.

3.4.3. Emparejamiento

La subtarea de *matching* presenta una mayor complejidad que la de selección múltiple, ya que en lugar de tener que resolver cada pregunta de forma independiente, los ejercicios de emparejamiento exigen mantener una coherencia global entre todos los pares de textos. Algunos ejemplos serían las situaciones donde una vez se asigna una respuesta con una pregunta, esta deja de estar disponible para el resto, o los ejercicios donde aparecen distractores, obligando a los sistemas a descartar aquellas opciones que no encajan con ningún elemento. Para tratar de resolver esta tarea de la mejor forma posible, se ha seguido una metodología similar a la de la subtarea de *multiple choice* (sección 3.4.2), planteando un *baseline* de referencia con una estrategia *zero-shot* y evolucionando hasta un sistema multi-agente diseñado para resolver esta tarea de forma estructurada.

3.4.3.1. Zero-shot prompting

El objetivo de esta primera estrategia es establecer una línea base que permita medir la capacidad inherente de los modelos para resolver ejercicios de emparejamiento sin ningún tipo de entrenamiento específico, sirviendo como punto de partida para hacer una comparación con las mejoras posteriores.

A diferencia de la selección múltiple, donde la salida esperada era una única letra, esta tarea requiere que el sistema genere un diccionario en formato JSON que asocie los identificadores de las preguntas (*set2*) con las opciones de respuesta correspondientes (*set1*). Además, dentro de esta subtarea puede haber dos tipos diferentes de ejercicios, por lo que para facilitar la labor a los modelos y poder guiarles mejor a la hora de resolverla, antes de realizar la inferencia, el sistema identifica el tipo de ejercicio comparando el número de preguntas y respuestas disponibles, aplicando automáticamente uno de los dos *prompts* que se muestran en la figura 3.7.

- **Caso 1, respuestas repetibles** (figura 2.3): Este *prompt* se aplica cuando el número de preguntas (*set2*) es superior al número de opciones (*set1*). En él, se instruye al modelo para que tenga en cuenta que una misma opción del primer conjunto puede asociarse a múltiples elementos del segundo, es decir, que pueden repetirse las opciones de respuesta.
- **Caso 2, presencia de distractores** (figura 2.4): El segundo *prompt* se utiliza cuando hay más opciones de respuesta que preguntas. En este caso, se advierte al modelo de forma explícita sobre la existencia de opciones adicionales que actúan como distractores, forzando un mapeo estricto de uno a uno para las respuestas válidas, de manera que una vez que un elemento del primer conjunto se ha asociado con uno del segundo, no puede volver a utilizarse.

En el Apéndice B pueden consultarse ejemplos de exámenes reales para ambos casos, junto con su archivo JSON asociado, lo que permite ver con mayor claridad la estructura concreta de cada tipo de ejercicio (figuras B.3, B.4, B.5 y B.6).

Esta estrategia se evaluó con los modelos Qwen 3.5 9B y Gemma 4 E4B sobre el conjunto de desarrollo de 10 ejercicios descrito en la sección 3.3. Los resultados, recogidos en la tabla 3.11, muestran que Qwen 3.5 9B obtiene un rendimiento global del 92.41 %,

3. Metodología y desarrollo

superando a Gemma 4 E4B en algo menos de 3 puntos (89.87%). Ambos modelos resuelven correctamente la totalidad de los ejercicios en los niveles A2, B1 y C1, mientras que el nivel B2, el más representado en el conjunto con 30 pares en total, concentra los errores principales: Qwen 3.5 9B obtiene un 83.78% y Gemma 4 E4B un 81.08%. Estos resultados son prometedores, aunque el reducido tamaño del conjunto de desarrollo (10 ejercicios y 79 pares en total) limita la solidez de las conclusiones que pueden extraerse.

Modelo	A1	A2	B1	B2	C1	C2	Acc. Ejerc.	Acc. Global
Qwen 3.5 9B	100.00%	100.00%	100.00%	83.78%	100.00%	100.00%	70.00%	92.41%
Gemma 4 E4B	92.86%	100.00%	100.00%	81.08%	100.00%	100.00%	60.00%	89.87%

Tabla 3.11.: Resultados de precisión (*accuracy*) en la subtask de *matching* bajo la estrategia *zero-shot*, detallando el rendimiento por niveles de cada modelo.

3.4.3.2. Sistema multi-agente

La segunda estrategia surge con el objetivo de gestionar la complejidad que tienen los ejercicios de emparejamiento de una forma más robusta que las soluciones basadas únicamente en *prompting*. En lugar de pedir a un único modelo que resuelva el ejercicio completo de una vez, la idea era desarrollar un sistema que lo descomponga en tareas más pequeñas y asigne cada una a un agente especializado.

Recursos y Herramientas de Desarrollo

Antes de pasar a explicar la implementación del sistema y detallar los agentes que lo componen, conviene presentar el marco tecnológico sobre el que se ha construido.

Para la orquestación del flujo de ejecución, la definición del grafo de agentes y la gestión del estado compartido se utilizaron las librerías LangChain y LangGraph (LangChain, Inc. 2026). LangChain proporciona una capa de abstracción sobre los modelos de lenguaje que simplifica la gestión de *prompts* y la integración con herramientas externas. Por su parte, LangGraph extiende esta idea permitiendo definir flujos agénticos como grafos dirigidos, donde cada nodo representa un agente o una operación y las aristas codifican las transiciones entre ellos. Esta abstracción encaja directamente con la arquitectura del sistema, donde los bucles de retroalimentación y el enrutamiento condicional son una parte fundamental del diseño.

Durante el desarrollo, las primeras pruebas se realizaron en local mediante Ollama (Ollama 2026), utilizando distintos modelos de unos 8 billones de parámetros. Sin embargo, al tener que hacer un razonamiento bastante detallado para resolver cada ejercicio, encadenando varias llamadas a los agentes para resolver cada uno de ellos, los tiempos de respuesta eran demasiado elevados como para trabajar con comodidad y probar una solución final sobre el conjunto de *test* de la competición. Por ello, se optó por utilizar un modelo propietario accesible a través de la API de Google AI Studio¹⁶, concretamente Gemini 2.5 Flash Lite, que combina velocidad, baja latencia y capacidad de razonamiento a un coste reducido, además de integrarse de forma directa con LangChain.

¹⁶<https://aistudio.google.com/welcome>

System prompt (Caso 1 - Respuestas repetibles):

“Eres un profesor experto en resolver exámenes de comprensión lectora en español. Tu tarea es leer atentamente el texto y emparejar cada elemento del set2 con su correspondiente opción del set1. Las ÚNICAS opciones válidas del set1 son: {valid_ids}

IMPORTANTE: Como hay más preguntas que opciones, una misma opción del set1 puede usarse más de una vez.

Responde EXCLUSIVAMENTE basándote en la información del texto, sin utilizar conocimiento externo.

No escribas explicaciones, ni introducciones, ni texto adicional. SOLO responde con un objeto JSON con el siguiente formato:

```
{“<id_elemento_set2>”: “<id_opcion_set1>”, ...}
```

Ejemplo de formato correcto:

```
{“13”: “A”, “14”: “C”, “15”: “B”}
```

System prompt (Caso 2 - Presencia de distractores):

“Eres un profesor experto en resolver exámenes de comprensión lectora en español. Tu tarea es leer atentamente el texto y emparejar cada elemento del set2 con su correspondiente opción del set1. Las ÚNICAS opciones válidas del set1 son: {valid_ids}

IMPORTANTE: Hay más opciones del set1 que elementos del set2. Algunas opciones son distractores y no deben usarse. Cada opción solo puede utilizarse una vez.

Responde EXCLUSIVAMENTE basándote en la información del texto, sin utilizar conocimiento externo.

```
{“<id_elemento_set2>”: “<id_opcion_set1>”, ...}
```

Ejemplo de formato correcto:

```
{“13”: “A”, “14”: “C”, “15”: “B”}
```

Figura 3.7.: *System prompts* de la estrategia *zero-shot* para la subtaska de emparejamiento: la variante para ejercicios con respuestas repetibles (arriba) y la variante para ejercicios con correspondencia uno a uno y posibles distractores (abajo).

Componentes del sistema y flujo de trabajo

La figura 3.8 muestra la arquitectura completa del sistema, que se organiza en torno a un agente orquestador y dos rutas de resolución diferenciadas según la estructura

3. Metodología y desarrollo




Figura 3.8.: Arquitectura del sistema multi-agente para la subtask de emparejamiento, con el agente orquestador que clasifica cada ejercicio y activa la Ruta A (*Proposer-Critic Collaboration*) para ejercicios con respuestas reutilizables o la Ruta B (*Bidirectional Consensus and Auditing*) para ejercicios con correspondencia uno a uno.

del ejercicio. A continuación se explica la función de cada uno de los componentes que forman parte de él.

Agente orquestador

El agente orquestador es el punto de entrada al sistema y se encarga de analizar el ejercicio para determinar qué ruta debe seguir el sistema para resolverlo. Para ello, analiza las instrucciones del ejercicio y compara el número de preguntas y respuestas proporcionadas, de forma que si hay más preguntas que respuestas, o las instrucciones indican que las respuestas pueden reutilizarse, el ejercicio se clasifica como tipo A (*muchos a pocos*) y se activa la ruta A. En caso contrario, es decir, cuando hay más respuestas que preguntas o debe haber una correspondencia uno a uno sin posibilidad de repetición, se clasifica como tipo B (*uno a uno*) y se activa la ruta B. Además, para garantizar una salida estructurada, el agente utiliza un esquema Pydantic (Pydantic, Inc. 2026) que

fuerza la respuesta a un objeto JSON con un único campo que toma el valor A o B. El *prompt* completo puede consultarse en la figura 3.9.

System prompt:

“Eres un Agente Clasificador experto en lógica de emparejamiento (Matching Tasks). Tu objetivo es determinar la estrategia de resolución basándote en la relación entre preguntas y respuestas.

Tipos de tarea:

- “A” (Muchos a Pocos / Repetición): Se selecciona cuando hay más preguntas que respuestas O cuando las instrucciones indican que las respuestas pueden reutilizarse.
- “B” (Uno a Uno / Descarte): Se selecciona cuando hay más respuestas que preguntas (sobran distractores) o igual número sin posibilidad de repetición.

Reglas de Salida:

1. Analiza primero las instrucciones.
2. Compara la cardinalidad proporcionada.
3. Devuelve EXCLUSIVAMENTE un objeto JSON. No añadas texto adicional ni explicaciones.”

User prompt (construido dinámicamente):

“Analiza el enunciado y clasifícalo:

- Instrucciones: {instructions}
- Cantidad de preguntas: {num_questions}
- Cantidad de respuestas: {num_answers}

Devuelve solo JSON con task_type igual a “A” o “B”.”

Figura 3.9.: *Prompts* del agente orquestador del sistema multi-agente para la subtask de emparejamiento, encargado de analizar la estructura del ejercicio y determinar si debe activarse la Ruta A o la Ruta B.

Ruta A: *Proposer-Critic Collaboration*

Cuando el orquestador determina que las respuestas pueden reutilizarse, el sistema resuelve el ejercicio mediante un proceso iterativo pregunta a pregunta, donde un agente propone una respuesta y otro se encarga de revisarla para ver si es correcta.

Agente *Resolver*

Este agente recibe una única pregunta, el conjunto completo de respuestas disponibles y, si los hay, los comentarios del agente *Reviewer* sobre intentos anteriores. Como se ve

3. Metodología y desarrollo

en el *prompt* de la figura 3.10, a partir de estos elementos, evalúa cada opción de forma individual, prioriza la más específica o semánticamente completa cuando dos opciones parecen igualmente válidas, y descarta directamente aquellas que el *Reviewer* haya invalidado en iteraciones previas. En la salida debe incluir siempre un razonamiento explícito junto a la respuesta seleccionada, lo que permite al *Reviewer* evaluar la propuesta de forma fundamentada y reduciendo así la posibilidad de que escoja una respuesta aleatoria o superficial.

System prompt:

“Eres un experto en resolución de ejercicios de comprensión lectora. Tu tarea es analizar una única pregunta y seleccionar la respuesta correcta de un conjunto que puede tener distractores, basándote en el texto y las imágenes (si las hay).

Pasos a seguir:

1. Evaluación de Candidatos: Compara la pregunta con CADA una de las posibles respuestas.
2. Si dos respuestas parecen correctas, elige la que sea más específica o semánticamente completa.
3. Si existe feedback de intentos previos, descarta las opciones que ya fueron invalidadas.

Reglas Críticas:

- No inventes información. Si consideras que ninguna respuesta es adecuada, elige la que menos se contradiga con la pregunta.
- El formato de salida debe ser exclusivamente JSON.”

User prompt (construido dinámicamente):

“Empareja la siguiente pregunta con la respuesta más adecuada:

{question}

Posibles respuestas:

{answer_list}

Feedback del revisor: {previous_feedback}

Devuelve un JSON con question_id, selected_answer_id y reasoning.”

Figura 3.10.: *Prompts* del agente *Resolver* en la Ruta A (*Proposer-Critic Collaboration*), encargado de proponer un candidato para cada pregunta evaluando las opciones disponibles e incorporando el *feedback* del agente *Reviewer* en caso de rechazo.

3. Metodología y desarrollo

Agente *Reviewer*

El agente *Reviewer* es el encargado de validar o rechazar la propuesta del *Resolver*. Su objetivo no es resolver el emparejamiento desde cero, sino servir como segunda opinión para confirmar si la opción seleccionada es la correcta. Para ello, recibe la pregunta, la respuesta propuesta y el resto de opciones disponibles, y determina si la elección es realmente la que mejor encaja teniendo en cuenta todas las alternativas.

En el *prompt* (figura 3.11) se instruye al agente para que descarte las opciones una a una prestando atención a posibles distractores o a palabras que hayan podido confundir al agente anterior, recordándole que el emparejamiento no siempre es literal, sino que a menudo conecta necesidades con soluciones afines.

Si la propuesta es correcta, emite un veredicto *pass* y el emparejamiento queda aceptado; si no lo es, emite un *fail* acompañado de un *feedback* que explica el motivo del rechazo y, si es posible, señala cuál sería la opción correcta. Este *feedback* alimenta directamente la siguiente iteración del *Resolver*, cerrando el bucle de retroalimentación entre los dos agentes que forman parte de esta ruta. Si tras tres intentos no se alcanza un acuerdo, el sistema acepta el último candidato propuesto.

Ruta B: *Bidirectional Consensus and Auditing*

Cuando el ejercicio presenta una correspondencia uno a uno entre preguntas y respuestas, donde puede haber elementos distractores, el agente orquestador deriva el flujo del sistema hacia la ruta B. A diferencia de la ruta A, donde un único agente propone y otro valida de forma iterativa, aquí el sistema trata de resolver el ejercicio completo mediante dos agentes que trabajan en paralelo desde perspectivas complementarias, tal y como se puede ver en la figura 3.8.

Agente *Direct Resolver*

El agente *Direct Resolver* se encarga de resolver el ejercicio en una dirección natural, es decir, dada una pregunta (set 2), selecciona la respuesta que mejor encaja entre todas las disponibles (set 1). Para mantener la restricción uno a uno que impone el ejercicio, el agente itera sobre las preguntas de forma secuencial y, para cada una, selecciona la respuesta que mejor encaja entre las todavía disponibles. Una vez asignada una respuesta, esta se elimina del conjunto, garantizando así el cumplimiento de esta restricción.

Siguiendo la misma idea que en el resto de agentes, se le pide generar un razonamiento donde descarte las opciones una a una para limitar lo máximo posible las confusiones o respuestas aleatorias, como puede verse en el *prompt* de la figura 3.12.

Agente *Inverse Resolver*

El agente *Inverse Resolver* opera en sentido contrario, es decir, parte de cada respuesta e intenta identificar a qué pregunta pertenece. Esta perspectiva inversa es especialmente útil para detectar distractores, ya que el agente está instruido para reconocer cuándo

System prompt:

“Eres un experto en corregir ejercicios de comprensión lectora. Debes analizar la pareja pregunta-respuesta propuesta y compararla con el resto de opciones disponibles para asegurar que no haya una mejor alternativa.

Revisa la pregunta, la respuesta seleccionada y el resto de opciones posibles para descartarlas una a una. Fíjate en que el alumno no haya caído en alguna trampa de palabras clave o se haya confundido con un distractor. Recuerda que en estos ejercicios el emparejamiento puede no ser literal: a menudo se conectan necesidades o intereses con soluciones afines.

Tu trabajo no es juzgar si la respuesta es perfecta en el mundo real, sino determinar si es la MEJOR entre las opciones disponibles, basándote en el texto y las imágenes (si las hay).

Criterios de Decisión: - PASS: Si la respuesta escogida es la mejor disponible.
- FAIL: Si la respuesta es incorrecta o si existe otra opción que encaja mejor.

Si es FAIL, explica por qué la respuesta seleccionada no es adecuada y, si es posible, señala cuál de las otras opciones sería mejor. Devuelve estrictamente un JSON.”

User prompt (construido dinámicamente):

“Comprueba si la respuesta seleccionada es la mejor opción para la pregunta dada, comparándola con el resto de respuestas posibles.

- Pregunta: {question}
- Respuesta seleccionada: {selected_answer}
- Otras posibles respuestas: {other_answers}

Devuelve JSON con status ('pass'—'fail') y feedback.”

Figura 3.11.: *Prompts* del agente *Reviewer* en la Ruta A (*Proposer-Critic Collaboration*), encargado de validar o rechazar la propuesta del agente *Resolver* comparándola con el resto de opciones disponibles y emitiendo un *feedback* explicado en caso de discrepancia.

una respuesta no tiene una conexión lógica clara con ninguna pregunta y, por tanto, no asociarla con ningún elemento.

En el *prompt* de la figura 3.13 se le indica al agente que primero debe analizar cada pregunta una a una y, si la respuesta encaja parcialmente en varias, priorizar aquella donde el encaje sea más específico. Al operar sobre todas las respuestas disponibles, incluidos los distractores, genera un borrador inverso completo que se cruzará con el del agente *Direct Resolver* en el siguiente paso del flujo para determinar cuáles son las respuestas correctas.

System prompt:

“Eres un experto en resolver ejercicios de comprensión lectora. Tu objetivo es seleccionar la respuesta que mejor encaje o responda a la pregunta dada, entre un conjunto de opciones que pueden incluir distractores.

Criterios de Selección:

1. Selecciona la respuesta que complete, defina o responda de forma más precisa a la pregunta.
2. No asumas información que no esté explícitamente en el texto.

Reglas de Salida:

- Razona brevemente sobre por qué esa respuesta es la mejor.
- Devuelve exclusivamente JSON válido.”

User prompt (construido dinámicamente):

“Pregunta:

{question}

Respuestas disponibles:

{answer_list}

Selecciona la mejor respuesta para la pregunta planteada.”

Figura 3.12.: *Prompts* del agente *Direct Resolver* en la Ruta B (*Bidirectional Consensus and Auditing*), encargado de recorrer las preguntas de forma secuencial y asignar a cada una la respuesta más adecuada entre las todavía disponibles, garantizando la restricción de correspondencia uno a uno.

Fase de Cross-validation

Una vez que ambos agentes han generado sus borradores de forma independiente, el sistema los cruza en una fase de *cross-validation* para obtener un primer conjunto de emparejamientos confirmados y detectar los casos que requieren una revisión adicional. Para cada pregunta, el sistema comprueba qué respuesta propuso el *Direct Resolver* y qué respuestas reclamó el *Inverse Resolver* para esa misma pregunta, clasificando el resultado en uno de estos tres casos:

- **Acuerdo:** Si ambos agentes coinciden en el mismo emparejamiento. Es el caso de mayor confianza y el emparejamiento se acepta directamente sin necesidad de intervención adicional.
- **Unilateral:** En el caso de que solo uno de los dos agentes haya propuesto un emparejamiento para esa pregunta, el par se acepta directamente, ya que no hay alternativa con la que contrastar.

System prompt:

“Eres un experto en resolver ejercicios de comprensión lectora. Tu objetivo es determinar a qué pregunta pertenece una respuesta específica o identificar si se trata de un distractor.

Protocolo de Decisión: 1. Analiza si la respuesta responde, define o completa alguna de las preguntas. 2. Si la respuesta encaja parcialmente en varias, elige la pregunta donde el encaje sea más fuerte y específico. 3. Si la respuesta es irrelevante, falsa o no tiene una conexión lógica clara con ninguna pregunta, clasifícala como distractor (sin asociarla con ninguna pregunta).

Reglas de Salida: - Si hay emparejamiento: `question_id` debe ser el ID exacto de la pregunta. - Si es un distractor: `question_id` debe ser `null`. - El razonamiento debe explicar brevemente por qué responde a una pregunta o por qué se considera un distractor. - Devuelve exclusivamente JSON válido.”

User prompt (construido dinámicamente):

“Respuesta de referencia:
{answer}

Preguntas originales:
{question.list}

Determina a qué pregunta pertenece esta respuesta. Si es un distractor que no encaja en ninguna, devuelve `question_id` como `null`.”

Figura 3.13.: *Prompts* del agente *Inverse Resolver* en la Ruta B (*Bidirectional Consensus and Auditing*), encargado de recorrer las respuestas en sentido inverso e identificar a qué pregunta pertenece cada una, devolviendo `null` cuando detecta que una respuesta actúa como distractor.

- **Conflicto:** Si los agentes discrepan y se acumulan dos o más respuestas candidatas para la misma pregunta, el caso se envía al agente *Auditor* para que decida cuál es la respuesta correcta.

Agente *Auditor*

El agente *Auditor* entra en juego cuando la fase de *cross-validation* no ha podido resolver un emparejamiento de forma automática, es decir, cuando hay varios candidatos en conflicto para una misma pregunta. En este caso, el agente recibe únicamente los candidatos en disputa para una pregunta concreta, lo que reduce el ruido y le permite centrarse en determinar cuál de ellos es un distractor diseñado para confundir. Al operar sobre un conjunto reducido de opciones preseleccionadas, el agente puede tomar decisiones más precisas que si tuviese que evaluar el conjunto completo de respuestas. Las instrucciones seguidas por este agente se muestran en la figura 3.14.

System prompt:

“Eres un experto en resolver ejercicios de comprensión lectora. Tu especialidad es la resolución de ambigüedades en ejercicios de emparejamiento complejos.

Tu tarea es resolver un conflicto de opciones evaluando **SIMULTÁNEAMENTE** múltiples respuestas candidatas para una misma pregunta.

Instrucciones:

1. Compara la pregunta con las posibles respuestas para ver cuál es la que mejor encaja o responde a la pregunta.
2. Identifica si alguna opción ha sido diseñada para confundir.
3. Penaliza los distractores o respuestas genéricas si hay una opción más específica.

Debes generar un razonamiento breve explicando por qué has elegido esa opción. Devuelve exclusivamente un JSON válido con la decisión final.”

Figura 3.14.: *Prompts* del agente *Auditor* en la Ruta B (*Bidirectional Consensus and Auditing*), encargado de arbitrar entre los candidatos en conflicto tras la fase de *cross-validation*, determinando cuál de las opciones en disputa es un distractor y cuál es la respuesta correcta.

Fase Sweeper

Una vez superada la fase del agente *Auditor*, pueden quedar preguntas huérfanas en aquellos casos para las que ninguno de los dos primeros agentes propuso candidato alguno y que, por tanto, no han podido resolverse por ninguna de las vías anteriores. En estos casos, el sistema ejecuta una fase de barrido (*Sweeper*) que reutiliza el agente *Direct Resolver* sobre las respuestas todavía disponibles. Si la respuesta seleccionada sigue libre, se asigna directamente y, en caso contrario, el sistema recurre a la primera respuesta disponible como *fallback*, garantizando que el sistema devuelva siempre un emparejamiento completo, sin dejar preguntas sin respuesta, asumiendo que una asignación imperfecta es preferible a ninguna asignación.

Casos de uso

A continuación se ilustra el comportamiento del sistema mediante un ejemplo representativo de cada ruta.

Ruta A

El primer ejemplo (figura 3.15) corresponde a un ejercicio de nivel B2 en el que se presentan cuatro textos con el testimonio de distintas emprendedoras (identificadas como A, B, C y D) y diez preguntas que deben relacionarse con ellos. Al haber más preguntas

3. Metodología y desarrollo

que textos, una misma respuesta puede reutilizarse, y el orquestador clasifica el ejercicio como tipo A activando esa misma ruta.

TEXTO A (Eva):

La idea de emprender me rondaba por la cabeza desde mi etapa universitaria, cuando estuve a punto de crear una empresa de diseño de joyas con un compañero. Al terminar mis estudios, encontré trabajo en el sector de la comunicación. Aunque seguía con mi sueño en mente, no me atrevía a dar el salto y montar mi agencia. Pero varios años después, con un dinero que me prestó un familiar, monté Pidel a luna, una agencia especializada en el diseño, la producción y la gestión de eventos empresariales e institucionales. Como me daba miedo que la agencia no funcionara bien, durante un año estuve compaginando mi actividad como autónoma con la de relaciones públicas en un hotel. Montar un negocio sin disponer de muchos recursos es un poco temerario, pero te empuja a pelear por sacar adelante tu proyecto, a estar siempre alerta buscando acuerdos de intercambios, colaboraciones...

TEXTO B (Ana):

Empecé en este negocio hace 5 años, y ya he decorado 200 restaurantes. Tres son las claves de mi trayectoria: la producción y montaje integral de todos los complementos relacionados con un local, el hecho de terminar los proyectos a tiempo (una obviedad que no se suele cumplir en este sector), y unos diseños novedosos, inspirados en viajes y libros. Cuando surge un nuevo proyecto, lo que hago es contratar yo misma a los carpinteros, escultores y otros profesionales artísticos; y es que, cuando subcontratas, sufres mucho, ya que no sabes si hacen bien el trabajo hasta el final. Además, gasto poco en publicidad, puesto que nuestro trabajo se lo ofrecen a los restaurantes las propias marcas que los abastecen. Si un día lo que hago dejara de funcionar, tengo pensada una alternativa: una empresa online, Lafabricadeideas.com, centrada en el diseño de decorados teatrales.

TEXTO C (Luz):

Mi empresa es el fruto de una idea surgida en una reunión de compañeros de clase, en la cafetería de la facultad, cuando uno de ellos se quejó de que para traducir los prospectos los laboratorios farmacéuticos no contrataban médicos especialistas. Con uno de esos amigos fundé Lexus, una empresa de traducción médica, y a los tres meses ya trabajábamos para algunos laboratorios farmacéuticos. Pero mi espíritu luchador hizo que no me conformara con la simple traducción técnica, y decidí también ofrecer a nuestros clientes estrategias de marketing de impacto. Me había dado cuenta de que los proveedores del sector farmacéutico promocionaban un fármaco, pero no se preocupaban por rentabilizar al máximo la inversión de los clientes. Ante este problema, comenzamos a proponer a los clientes estrategias: tras una primera reunión con ellos para analizar sus objetivos y los mensajes que quieren transmitir, elaboramos propuestas concretas como, por ejemplo, un evento internacional avalado por sociedades médicas de prestigio.

TEXTO D (Mar):

Aunque estudié Ingeniería informática, me dedico al mundo de la moda. Hace dos años estaba en paro y un día se me ocurrió crear un blog de moda y belleza en el que colgué un vídeo sobre cómo personalizar camisetas, un pequeño atrevimiento que solo confesé a mi marido. Este vídeo, al que siguieron muchos más, marcó mi futuro. Me gasté mis pequeños ahorros en una cámara y, gracias al apoyo de mis incondicionales seguidores, me he convertido en una bloguera famosa. Ahora me cuesta creer que mis vídeos lleven más de 40 millones de reproducciones en la red. No llamé a ninguna puerta, pero enseguida me ofrecieron colaborar en un programa de televisión y ser la imagen de distintas promociones. Sin embargo, soy consciente de que la fama es algo efímero, así que no he dejado de grabar mis vídeos caseros.

PREGUNTAS: Relacione las preguntas (7-16) con los textos (A, B, C o D).

- 7) ¿Quién dice que ahorra en promocionar su producto?
- 8) ¿Quién dice que la escasez de dinero es un estímulo?
- 9) ¿Quién dice que controla todas las fases de la creación del producto?
- 10) ¿Quién dice que invirtió poco dinero cuando montó su empresa?
- 11) ¿Quién se muestra asombrada ante el éxito obtenido?

3. Metodología y desarrollo

- 12) ¿Quién dice que le costó decidirse a trabajar por cuenta propia?
- 13) ¿Quién dice que se le ocurrió montar su actual empresa en su etapa universitaria?
- 14) ¿Quién dice que en su negocio se respetan los plazos de entrega?
- 15) ¿Quién dice que gracias a su forma de ser amplió el negocio?
- 16) ¿Quién dice que un pariente la ayudó a crear su empresa?

Figura 3.15.: Ejemplo de ejercicio de *matching* extraído del corpus IC-UNED-RC-ES (Peñas, Rodrigo, Fruns-Jiménez, Soria-Pastor, Moreno-Álvarez, Pérez et al. 2026), correspondiente a un examen de nivel B1, en el que un mismo texto puede ser la respuesta correcta de varias preguntas (respuestas repetibles).

Como se muestra en el diagrama de la figura 3.16, el sistema procesa las preguntas de forma secuencial. Para cada una, el agente *Resolver* recibe la pregunta y el conjunto completo de textos disponibles, los evalúa uno a uno y propone el que considera más adecuado, acompañando siempre su elección de un razonamiento explícito. Ante la pregunta «¿Quién dice que ahorra en promocionar su producto?», por ejemplo, el agente identifica que el texto B menciona de forma específica que la emprendedora gasta poco en publicidad porque son las propias marcas las que se ponen en contacto con su negocio, y lo propone como candidato.

Tras recibir la propuesta, el agente *Reviewer* compara la opción seleccionada con el resto de textos para comprobar si existe alguna alternativa que encaje mejor. En este caso, al no encontrar ningún texto que describa con mayor precisión esa situación, emite un veredicto *pass* y el emparejamiento queda aceptado en la primera iteración. En cambio, si el *Resolver* cometiese un error (por ejemplo, confundiendo la pregunta «¿Quién dice que un pariente la ayudó a crear su empresa?» con un texto que menciona a un compañero en lugar de a un familiar), el *Reviewer* emitiría un *fail* explicando por qué la opción seleccionada no es válida y señalando cuál sería la correcta. Este *feedback* alimenta la siguiente iteración del *Resolver*, que descarta directamente la opción invalidada y reorienta su búsqueda. Si tras tres iteraciones no se alcanza un acuerdo, el sistema acepta el último candidato propuesto y avanza a la siguiente pregunta.

Ruta B

El segundo ejemplo (figura 3.17) corresponde a un ejercicio de nivel B1 con seis enunciados y diez textos del horóscopo, de los cuales tres actúan como distractores y no deben asociarse a ningún enunciado del primer conjunto. Al recibir este ejercicio, el agente orquestador se encargará de analizarlo y detectará que hay más respuestas que preguntas, algunas de las cuales actúan como distractores. Por ello, clasificará el ejercicio como tipo B y derivará el flujo a los agentes *Direct Resolver* e *Inverse Resolver*, como se muestra en la figura 3.18.

TEXTO A (Aries):

Esta semana tiene que cuidarse, se va a sentir mal: un poco cansado, ligeros dolores de cabeza, pequeñas molestias en el estómago. Necesita relajarse, beber mucho líquido y dormir ocho horas. Mejor día de la semana: domingo. Número de la suerte: 8.

3. Metodología y desarrollo




Figura 3.16.: Diagrama de secuencia de la Ruta A (*Proposer-Critic Collaboration*), donde el *Resolver* propone un emparejamiento para cada pregunta y el *Reviewer* lo valida o rechaza de forma iterativa hasta alcanzar un acuerdo.

TEXTO B (Tauro):

Usted está pasando una época baja emocionalmente y eso se nota en su aspecto físico. Debería ir a un gimnasio, el ejercicio ayuda a mejorar la salud y a estar en forma. Si no es capaz de ir solo/a, llame a algún amigo/a y se sentirá mucho mejor.

Mejor día de la semana: sábado. Número de la suerte: 7.

TEXTO C (Géminis):

¡Enhorabuena! Usted va a tener una buena semana en la salud, en el trabajo, en la economía y en las relaciones con su familia. Con su pareja puede llegar a tener pequeñas discusiones. Si no tiene pareja todavía, no es el momento para una relación estable.

Mejor día de la semana: jueves. Número de la suerte: 5.

TEXTO D (Cáncer):

¡Felicidades! Usted va a recibir toda la energía positiva del sol y a vivir una semana increíble en la salud, el dinero, el trabajo y, especialmente, el amor. Esta semana alguien puede entrar en su vida y despertarle nuevas emociones.

3. Metodología y desarrollo

Mejor día de la semana: viernes. Número de la suerte: 2.

TEXTO E (Leo):

La suerte está cerca de usted. Si no juega a la lotería, es el momento de intentarlo. Su futuro profesional puede mejorar si dirige un buen equipo de trabajo. Buen momento para hacer un viaje de negocios.

Mejor día de la semana: lunes. Número de la suerte: 0.

TEXTO F (Virgo):

¿Está aburrido y no sabe qué hacer? Esta semana debería relajarse, leer ese libro que ha comprado y todavía no ha leído por falta de tiempo, escuchar su música favorita, preparar esa receta que tanto le gusta, llamar a sus amigos...

Mejor día de la semana: viernes. Número de la suerte: 1.

TEXTO G (Piscis):

Últimamente está muy estresado/a y ha pensado dejar su empleo. Estudie con mucha atención esas ofertas que ha recibido porque es lo mejor en este momento. Tiene que ser optimista y no ponerse nervioso/a.

Mejor día de la semana: domingo. Número de la suerte: 3.

TEXTO H (Escorpio):

Semana un poco complicada. Usted va a sentirse nervioso, debe tomar una de las decisiones más importantes de su vida. Es importante escuchar la opinión de los padres y los consejos de las personas que están cerca de usted. ¡No está solo!

Mejor día de la semana: martes. Número de la suerte: 1.

TEXTO I (Sagitario):

¡Enhorabuena! Va a recibir una cantidad de dinero extra que usted no esperaba. Es el momento de realizar ese viaje maravilloso que usted siempre ha soñado, cambiar de coche o hacer una reforma en su casa.

Mejor día de la semana: miércoles. Número de la suerte: 4.

TEXTO J (Acuario):

Buena semana en lo profesional, va a tener éxito en sus negocios. En la salud, la familia o el amor, la situación es la habitual, sin grandes cambios. Tiene que intentar evitar las compras innecesarias y no usar de forma exagerada las tarjetas de crédito.

Mejor día de la semana: sábado. Número de la suerte: 3.

ENUNCIADOS: Relacione los enunciados (0-6) con los textos del horóscopo (A-J). **HAY TRES TEXTOS QUE NO DEBE RELACIONAR.**

- 0) Esta semana va a tener problemas de salud.
- 1) Es un buen momento para cambiar de trabajo.
- 2) Es bueno para usted hacer un poco de deporte.
- 3) Debería escuchar a su familia con atención.
- 4) Le recomiendan controlar sus gastos.
- 5) Puede conocer a una persona muy especial.
- 6) Le dan consejos para pasar su tiempo libre.

Figura 3.17.: Ejemplo de ejercicio de *matching* extraído del corpus IC-UNED-RC-ES (Peñas, Rodrigo, Fruns-Jiménez, Soria-Pastor, Moreno-Álvarez, Pérez et al. 2026), correspondiente a un examen de nivel B1, en el que se incluyen textos que no corresponden a ningún enunciado y que actúan como distractores.

El *Direct Resolver* recorre los enunciados de forma secuencial. Ante el enunciado «*Esta semana va a tener problemas de salud*», evalúa los diez textos disponibles y selecciona el que habla explícitamente de cansancio y molestias físicas, eliminándolo del conjunto

3. Metodología y desarrollo

para que no pueda asignarse a ningún otro enunciado. El *Inverse Resolver*, en cambio, parte de cada texto e intenta identificar a qué enunciado pertenece. Al procesar el texto C, el agente determina que no encaja de forma clara con ninguno de los seis enunciados y lo marca como distractor devolviendo `null` en el campo correspondiente.

Una vez que ambos agentes han generado sus borradores de forma independiente, la fase de *cross-validation* los cruza enunciado a enunciado. Para cada uno, el sistema comprueba si ambos agentes coinciden en la misma respuesta, si solo uno de ellos ha propuesto un candidato, o si los dos proponen opciones distintas. Los dos primeros casos se aceptan directamente, mientras que el tercero se delega al agente *Auditor*, que recibe únicamente los candidatos en conflicto y arbitra entre ellos prestando especial atención a posibles distractores diseñados para confundir. Finalmente, si algún enunciado quedase sin respuesta asignada tras este proceso, en la fase *sweeper* realiza un barrido sobre las respuestas todavía disponibles para cerrar el emparejamiento definitivo.

Resultados sobre el conjunto de desarrollo

Los resultados del sistema multi-agente sobre el conjunto de desarrollo se recogen en la tabla 3.12. En ellos puede verse que el sistema alcanza una precisión global del 86.08 %, por debajo del 92.41 % obtenido por Qwen 3.5 9B con *zero-shot* y del 89.87 % de Gemma 4 E4B. Sin embargo, esta diferencia no es del todo representativa, debido a que el conjunto de desarrollo cuenta con tan solo 10 ejercicios y 79 pares de enunciados en total. Además, el rendimiento por ejercicio completo, donde el sistema multi-agente obtiene un 40.00 % frente al 70.00 % de Qwen 3.5 9B, refleja que el sistema comete errores dispersos en distintos ejercicios en lugar de fallar de forma sistemática en alguno concreto.

Por niveles, el sistema resuelve correctamente la totalidad de los pares en B1 y C1, mientras que A1 y B2 concentran los errores principales, con un 85.71 % y un 76.67 % respectivamente. En A1, los dos ejercicios disponibles corresponden ambos a la ruta B, lo que sugiere que la fase de *cross-validation* puede tener dificultades cuando el número de pares por ejercicio es reducido y los distractores son semánticamente próximos a las opciones correctas. En B2, el nivel más representado en el conjunto con 30 pares repartidos en tres ejercicios, tanto las estrategias *zero-shot* como el sistema multi-agente muestran un rendimiento inferior al resto de niveles, por lo que parece que estos ejercicios resultan algo más complicados que el resto.

En conjunto, estos resultados sugieren que, sobre un conjunto de desarrollo tan reducido, el *zero-shot* con Qwen 3.5 9B constituye una aproximación más sólida. No obstante, el sistema multi-agente incorpora mecanismos de validación y resolución de conflictos que pueden resultar más robustos ante ejercicios de mayor complejidad o con un número mayor de distractores.

3. Metodología y desarrollo




Figura 3.18.: Diagrama de secuencia de la Ruta B (*Bidirectional Consensus and Auditing*), donde el *Direct Resolver* y el *Inverse Resolver* abordan el ejercicio en paralelo y los conflictos entre sus propuestas se delegan al *Auditor* para su resolución.

3. Metodología y desarrollo

Estrategia	A1	A2	B1	B2	C1	C2	Acc. Ejerc.	Acc. Global
<i>Zero-shot</i> (Qwen 3.5 9B)	100.00 %	100.00 %	100.00 %	83.78 %	100.00 %	100.00 %	70.00 %	92.41 %
<i>Zero-shot</i> (Gemma 4 E4B)	92.86 %	100.00 %	100.00 %	81.08 %	100.00 %	100.00 %	60.00 %	89.87 %
<i>Multi-agente</i>	85.71 %	83.33 %	100.00 %	76.67 %	100.00 %	87.50 %	40.00 %	86.08 %

Tabla 3.12.: Resultados de precisión (*accuracy*) en la subtask de *matching* bajo las estrategias *zero-shot* y el sistema multi-agente, desglosados por nivel del MCER y global.

3.5. Participación en PROFE 2026

Una vez completada la fase de experimentación, se seleccionaron las estrategias que se enviarían a la competición a través de la plataforma CodaBench¹⁷, que establecía un límite de cinco envíos por subtask. Para seleccionarlás, se priorizó la diversidad de enfoques, de forma que en lugar de enviar únicamente las configuraciones que habían tenido un mejor rendimiento sobre el conjunto de desarrollo, se decidió incluir un representante de cada estrategia explorada, lo que permitiría extraer más conclusiones sobre el comportamiento de cada solución ante este tipo de tareas al ser evaluadas con el conjunto de test oficial.

Concretamente, para la subtask de selección múltiple se realizaron cinco envíos, cubriendo todas las estrategias que se habían explorado durante la fase de experimentación:

- **Qwen 3.5 9B *zero-shot***: seleccionado por ser la configuración que mejor rendimiento demostró sobre el conjunto de desarrollo dentro de esta estrategia.
- **Gemma 4 E4B *zero-shot***: incorporado como variante adicional para establecer una comparación directa entre los dos modelos multimodales utilizados.
- **Gemma 4 E4B CoT**: representante de la estrategia *chain-of-thought*, que en el conjunto de desarrollo había mostrado una mejora respecto al *zero-shot* con este mismo modelo.
- **Ensemble multi-agente**: representante del enfoque basado en la combinación de modelos y resolución de discrepancias mediante un agente juez.
- **Gemma 4 E4B *fine-tuning***: configuración correspondiente al modelo con *fine-tuning* sobre el dataset ReCoRES.

Para la subtask de emparejamiento se enviaron las tres configuraciones desarrolladas:

- **Qwen 3.5 9B *zero-shot***
- **Gemma 4 E4B *zero-shot***
- **Sistema multi-agente**

Para poder realizar los envíos oficiales, los organizadores proporcionaron el conjunto de test con las preguntas y los enunciados, pero sin las respuestas correctas, de forma que cada participante debía ejecutar sus soluciones en su propio entorno (en el caso de este proyecto el descrito en la sección 3.4.1) y generar un archivo JSON con las predicciones. Este fichero se subía directamente a la plataforma CodaBench, que se encargaba

¹⁷<https://www.codabench.org/competitions/15902/>

3. Metodología y desarrollo

de comparar las predicciones con las respuestas oficiales y devolver las métricas de evaluación correspondientes. Sin embargo, al no haber publicado el *dataset*, únicamente se tiene acceso al resultado global de cada propuesta y no es posible hacer un análisis del rendimiento de cada una de ellas según el nivel de los ejercicios.

Además, con el objetivo de evaluar la eficiencia de las soluciones más allá del rendimiento en la tarea, se ha medido el consumo energético y la huella de carbono generados durante la ejecución de los envíos oficiales mediante la librería CodeCarbon, tal y como se describió en la sección 3.4.1. Esta medición no forma parte de la evaluación oficial de la competición, sino que constituye un análisis adicional propio de este trabajo, cuyos resultados se discuten en el capítulo 4.

Por último, cabe destacar que como fruto del trabajo desarrollado durante toda la competición, se redactó un artículo científico que describe las soluciones propuestas y los resultados obtenidos (Folgueira, Conde y Díaz 2026), el cual fue enviado y aceptado por los organizadores de la tarea PROFE 2026.

4. Discusión y resultados

Este capítulo recoge y analiza los resultados alcanzados tras el desarrollo del proyecto. En primer lugar, se presentan los resultados oficiales obtenidos en la evaluación de la competición PROFE 2026 para cada una de las subtareas (sección 4.1). A continuación, se realiza un análisis comparativo entre las distintas estrategias propuestas, contrastando tanto el rendimiento sobre el conjunto de desarrollo como los resultados oficiales (sección 4.2). Por último, la sección 4.3 discute la eficiencia energética de cada solución a partir de los datos de consumo recogidos durante la evaluación de las soluciones propuestas para la tarea.

4.1. Resultados oficiales en PROFE 2026

Los resultados que se presentan en esta sección fueron calculados por la plataforma CodaBench de la competición, que evaluó cada envío sobre el conjunto de *test* oficial no publicado, compuesto por 1.918 preguntas de *multiple choice* repartidas en 721 ejercicios y 1.394 pares de emparejamiento dentro de 189 ejercicios, según la distribución detallada en la tabla 3.4. Como punto de referencia para todos los resultados presentados, los organizadores publicaron un *baseline* utilizando ChatGPT, con el que obtuvieron un *accuracy* del 64 % para la subtarea de selección múltiple y del 51 % para la de emparejamiento (Rodrigo et al. 2026).

4.1.1. Selección múltiple

Como se mencionó en la sección 3.5, para la subtarea de *multiple-choice* se realizaron cinco envíos tratando de cubrir todas las estrategias que se habían desarrollado durante la fase de experimentación. La tabla 4.1 recoge los resultados obtenidos en el conjunto de *test* oficial, ordenados de mayor a menor *accuracy*.

El mejor resultado lo obtuvo el *ensemble* con diferentes LLMs, que alcanzó un *accuracy* del 90,55 %, seguido de cerca por la estrategia *zero-shot* con Qwen 3.5 9B (88,85 %) y por la estrategia *chain-of-thought* con Gemma 4 E4B (88,42 %). Los dos envíos con menor rendimiento corresponden a las configuraciones *zero-shot* de Gemma 4 E4B (85,63 %) y a ese mismo modelo con los pesos ajustados tras la fase de *fine-tuning* (85,46 %). En cualquier caso, todas las estrategias superan ampliamente la referencia de los organizadores, con una mejora de más de un 20 %.

4.1.2. Emparejamiento

Para la subtarea de emparejamiento se enviaron las tres configuraciones desarrolladas, cuyos resultados sobre el conjunto de *test* oficial pueden verse en la tabla 4.2.

4. Discusión y resultados

Model / Approach	Accuracy (%)
Multi-Agent Ensemble	90.55
Qwen 3.5 9B (Zero-shot)	88.85
Gemma 4 E4B (Chain of Thought)	88.42
Gemma 4 E4B (Zero-shot)	85.63
Gemma 4 E4B (Fine-tuned)	85.46
Organizers Baseline (ChatGPT)	64.00

Tabla 4.1.: Resultados oficiales obtenidos en la subtask de selección múltiple de PROFE 2026, ordenados por *accuracy* descendente. Se incluye la línea de base publicada por los organizadores como referencia.

Model / Approach	Accuracy (%)
Multi-Agent System	86.51
Qwen 3.5 9B (Zero-shot)	86.11
Gemma 4 E4B (Zero-shot)	83.57
Organizer Baseline (ChatGPT)	51.00

Tabla 4.2.: Resultados oficiales obtenidos en la subtask de emparejamiento de PROFE 2026, ordenados por *accuracy* descendente. Se incluye la línea de base publicada por los organizadores como referencia.

En esta subtask, el sistema multi-agente obtuvo el mejor resultado con un 86,51 %, aunque la diferencia respecto a la estrategia *zero-shot* con Qwen 3.5 9B (86,11 %) es muy pequeña. La configuración *zero-shot* con Gemma 4 E4B se quedó algo más alejada, con un 83,57 %. No obstante, las tres estrategias propuestas superan notablemente el *baseline* de los organizadores, con mejoras de entre 32 y 35 puntos porcentuales.

4.2. Análisis comparativo entre estrategias

A continuación se analiza el rendimiento de las distintas estrategias presentadas para cada una de las subtasks, atendiendo a la correspondencia entre los resultados obtenidos sobre el conjunto de desarrollo (sección 3.3) y los resultados oficiales, y las diferencias de rendimiento entre estrategias dentro de cada subtask.

4.2.1. Selección múltiple

Observando los resultados de la tabla 4.3, que para cada configuración enviada a la competición, muestra el *accuracy* obtenido sobre el conjunto de desarrollo y en la evaluación oficial, vemos que, hay una clara correlación entre los resultados de ambos conjuntos para las estrategias probadas sobre ambos. En términos generales, los experimentos sobre el conjunto de desarrollo anticiparon razonablemente bien el rendimiento en el *test* oficial para las estrategias que se probaron sobre ambos.

4. Discusión y resultados

Estrategia	Accuracy (Desarrollo)	Accuracy (Test Oficial)
Ensemble multi-agente ^a	—	90.55 %
Qwen 3.5 9B Zero-shot	91.85 %	88.85 %
Gemma 4 E4B CoT	88.15 %	88.42 %
Gemma 4 E4B Zero-shot	86.67 %	85.63 %
Gemma 4 E4B Fine-tuning ^a	—	85.46 %

^a No se dispone del dato de precisión exacto para esta configuración en la fase de desarrollo.

Tabla 4.3.: Comparativa de precisión (*accuracy*) para la tarea de *multiple-choice* entre el conjunto de datos de desarrollo y el test oficial.

Respecto a los resultados finales, el *ensemble* multi-agente fue el sistema que consiguió un *accuracy* más alto (90.55 %) y, aunque no se evaluó sobre el conjunto de desarrollo, esta arquitectura de resolución de discrepancias con un LLM haciendo de juez parece aportar robustez ante preguntas donde los modelos individuales difieren, lo que puede ser de gran ayuda especialmente en los exámenes de un nivel más alto, donde la ambigüedad de las opciones es mayor.

A nivel de rendimiento en la tarea, la configuración *zero-shot* con Qwen 3.5 9B alcanzó un 88.85 % de *accuracy*, quedándose bastante cerca de la estrategia anterior. Esta estrategia ya había mostrado un gran rendimiento durante la fase de desarrollo y demuestra la capacidad que tienen de base los modelos de lenguaje más recientes para resolver este tipo de tareas sin necesidad de hacer una adaptación más específica. Por ello, en términos de la relación entre rendimiento y coste computacionales, esta es una de las aproximaciones más eficientes, como se discute en la sección 4.3.

Por su parte, Gemma 4 E4B, otro modelo lanzado este mismo año, no alcanzó unos resultados tan altos pero sí se mantuvo bastante cerca, alcanzando un 85.63 % de *accuracy* al utilizar *zero-shot prompting*. Además, al seguir una estrategia con *Chain-of-Thought*, su capacidad de razonamiento mejoró, logrando un rendimiento muy similar al de Qwen 3.5 9B. Esto confirma que forzar a los modelos a generar un razonamiento explícito paso a paso reforzándolo con argumentos claros basándose en el texto, puede ayudarles a mejorar su rendimiento en la tarea. Este proceso de pensamiento paso a paso ayuda a los modelos a prestar más atención a los distractores o a detalles específicos de los textos en los que pueden no llegar a fijarse si deben responder directamente, por lo que también puede ser un enfoque útil especialmente en aquellos niveles y exámenes más complejos.

Por el contrario, el *fine-tuning* de Gemma 4 E4B sobre el *dataset* ReCoRES obtuvo el resultado más bajo de todas las configuraciones enviadas (85.46 %). Este resultado, que puede resultar contraintuitivo dado que el *fine-tuning* suele mejorar el rendimiento de los modelos, puede explicarse por dos factores. En primer lugar, el dominio de entrenamiento (textos de ReCoRES, más complejos y con una distribución lingüística diferente) puede no ser el más adecuado para los ejercicios del Instituto Cervantes utilizados para evaluar en PROFE 2026. En segundo lugar, el proceso de ajuste de pesos podría haber restringido las capacidades de razonamiento generalizado del modelo, que son precisamente las que más se necesitan en esta tarea al no disponer de datos de entrenamiento específicos.

4. Discusión y resultados

4.2.2. Emparejamiento

Los resultados para la subtask de *matching*, que se muestran en la tabla 4.4, reflejan un comportamiento algo más diferente entre los resultados sobre el conjunto de desarrollo y los oficiales. En este caso, Qwen 3.5 9B al utilizar una estrategia *zero-shot* obtenía un 92,41 % en el conjunto de desarrollo, pero en el *test* oficial cae hasta el 86,11 %, igual que sucede con Gemma 4 pasando del 89,87 % en desarrollo al 83,57 % en la competición. Esta caída generalizada demuestra que el conjunto de desarrollo utilizado, compuesto únicamente por 10 ejercicios y 79 pares, no era lo suficientemente extenso como para sacar conclusiones claras, pero sí permitió hacerse una idea de que las soluciones propuestas podían obtener un rendimiento bastante bueno en la tarea, como ha ocurrido finalmente. Esto refleja que hasta los modelos de un tamaño considerablemente reducido, tienen una alta capacidad a la hora de resolver este tipo de tareas, llegando incluso a poder compararse con el nivel que alcanzan los humanos.

Estrategia	Accuracy (Desarrollo)	Accuracy (Test Oficial)
Sistema multi-agente	86.08 %	86.51 %
Qwen 3.5 9B Zero-shot	92.41 %	86.11 %
Gemma 4 E4B Zero-shot	89.87 %	83.57 %

Tabla 4.4.: Comparativa de precisión (*accuracy*) para la tarea de *matching* entre el conjunto de datos de desarrollo y el test oficial.

Más allá de las propuestas basadas en *zero-shot prompting*, el sistema multi-agente fue el que obtuvo un mejor rendimiento con un 86.51 % de *accuracy*. En este caso, el comportamiento sobre ambos conjuntos de datos fue muy similar, lo que apunta a que los mecanismos de validación cruzada y resolución de conflictos entre agentes aportan una mayor robustez ante ejercicios de mayor complejidad (distractores o respuestas implícitas), que es donde las estrategias *zero-shot* pueden tener más problemas y perder más rendimiento.

Otro aspecto destacable es que, tal y como anticipaban los resultados sobre el conjunto de desarrollo, la diferencia entre el sistema multi-agente y la estrategia *zero-shot* con Qwen 3.5 9B es mínima en el *test* oficial (86,51 % frente a 86,11 %), lo que hace que ambas aproximaciones sean prácticamente equivalentes. Este resultado lleva a reflexionar sobre el valor real de añadir complejidad arquitectónica en tareas donde los modelos de base ya alcanzan un rendimiento elevado, ya que cuando la capacidad del modelo es suficiente para resolver la mayor parte de los casos, el enfoque colaborativo del sistema multi-agente no parece traducirse en una mejora clara sobre el resultado final. No obstante, sería interesante poder analizar los resultados desglosados por nivel MCER para comprobar si, pese a alcanzar una precisión global similar, las estrategias *zero-shot* tienden a cometer más errores en los niveles avanzados mientras que el sistema multi-agente muestra mayor robustez ante los ejercicios más complejos. La diferencia en coste computacional entre ambos enfoques refuerza aún más esta reflexión, tal y como se analiza en la sección 4.3.

4.3. Análisis de eficiencia energética

Más allá de medir el rendimiento de las distintas estrategias propuestas a la hora de resolver la tarea, los organizadores incentivaron a los participantes a través de la web oficial¹ a registrar el consumo energético y la huella de carbono de sus sistemas mediante la librería CodeCarbon, con el objetivo de promover una comparativa más completa que tenga en cuenta el coste medioambiental de cada solución. Por ello, durante la fase de generación de las soluciones para los envíos oficiales se registraron las emisiones en kilogramos de CO₂ equivalente (kgCO₂eq), junto con el tiempo de ejecución y el *hardware* utilizado en cada caso.

4.3.1. Emisiones de las estrategias propuestas para la subtask de selección múltiple

Observando los resultados recogidos en la tabla 4.5 para los cinco envíos definitivos, puede verse un claro *trade-off* entre rendimiento a nivel de *accuracy* y eficiencia. Dos de las estrategias que mejores resultados obtuvieron, el *ensemble* multi-agente (90,55 %) y la estrategia *chain-of-thought* (88,42 %), son también las que mayor consumo energético implican, con tiempos de ejecución de más de 4 horas y emisiones que superan los 0,25 kgCO₂eq en ambos casos. En el caso del *ensemble*, el componente que más contribuye al coste es el agente que asume el rol de juez, responsable de 3,12 horas de ejecución y de 0,2131 kgCO₂eq del total, ya que debe analizar detenidamente las opciones propuestas por los demás agentes y elaborar un razonamiento minucioso para resolver las discrepancias entre ellas, lo que implica un tiempo de ejecución considerablemente mayor que el de otras estrategias *zero-shot*.

Enfoque	Hardware	Tiempo de ejecución	Emisiones (kg CO ₂ eq)
<i>Qwen 3.5 9B (Zero-shot)</i>	A100	8,7 min	0,0175
<i>Gemma 4 (Zero-shot)</i>	T4	25,2 min	0,0065
<i>Gemma 4 (Fine-tuned)</i> ^a	A100	21,5 min	0,0367
<i>Gemma 4 (Chain of Thought)</i>	A100	4,59 horas	0,3502
<i>Multi-Agent Ensemble</i> ^b	Mixto (A100 y T4)	~4,24 horas	0,2546

^a Incluye 15,5 min (0,0263 kg CO₂eq) de *fine-tuning* y 6 min (0,0104 kg CO₂eq) de inferencia.

^b Coste acumulado de los agentes *Qwen*, *Gemma*, *Ministral* (T4) y el agente juez *Gemma 4*.

Tabla 4.5.: Tiempo de ejecución, *hardware* utilizado y emisiones de CO₂ equivalente registradas con *CodeCarbon* para los cinco envíos oficiales de la subtask de selección múltiple.

Por el contrario, las estrategias *zero-shot* presentan un perfil de eficiencia mucho más favorable. Qwen 3.5 9B fue el modelo más destacado, al completar la inferencia en solo 8,7 minutos con unas emisiones de 0,0175 kgCO₂eq, obteniendo al mismo tiempo el segundo mejor resultado de todas las configuraciones (88,85 %). Esta combinación de rendimiento competitivo y coste muy reducido lo convierte en la opción más equilibrada del conjunto evaluado. Gemma 4 E4B *zero-shot*, por su parte, aunque es la estrategia con menor huella de carbono (0,0065 kgCO₂eq), requiere más tiempo de ejecución (25,2

¹<https://sites.google.com/view/profe2026>

4. Discusión y resultados

minutos) al ejecutarse sobre una GPU T4 en lugar de una A100, y su *accuracy* (85,63 %) es la segunda más baja del conjunto. Este contraste entre ambas estrategias *zero-shot* muestra que utilizar una GPU más potente reduce el tiempo de ejecución, pero al operar a mayor potencia también incrementa el consumo energético por unidad de tiempo. En este caso, como el volumen de datos con el que se está trabajando no es excesivamente grande, las diferencias a nivel de emisiones son asumibles, pero este factor puede volverse relevante en escenarios con conjuntos de datos de mayor tamaño.

La estrategia de *fine-tuning* ocupa una posición intermedia en términos de eficiencia, con unas emisiones de 0,0367 kgCO₂eq que incluyen tanto el entrenamiento como la inferencia. Dado que el conjunto de datos utilizado para el ajuste, ReCoRES, no es excesivamente grande, el proceso de entrenamiento fue bastante rápido. Sin embargo, esto no debe llevar a subestimar el coste real que implica esta estrategia en un escenario más realista, ya que entrenar un modelo sobre un volumen de datos suficiente para una tarea específica puede suponer un coste computacional y energético considerablemente mayor, especialmente si se requieren varias iteraciones para encontrar la configuración óptima. En este contexto, y dado que su rendimiento (85,46 %) es el más bajo de todas las configuraciones evaluadas, el coste adicional que implica el *fine-tuning* no queda justificado frente a las alternativas basadas en *prompting*.

4.3.2. Emisiones de las estrategias propuestas para la subtarea de emparejamiento

Respecto a la subtarea de *matching*, en la tabla 4.6 vemos que para las dos estrategias *zero-shot*, los resultados son bastante eficientes y muy similares entre sí. Qwen 3.5 9B completó la tarea en 13 minutos con unas emisiones de 0,0206 kgCO₂eq, mientras que Gemma 4 E4B necesitó 18,6 minutos y emitió 0,0216 kgCO₂eq. Teniendo en cuenta que Qwen 3.5 9B obtiene además un *accuracy* 2,54 puntos superior (86,11 % frente a 83,57 %), se confirma es una estrategia que funciona muy bien a todos los niveles también para esta subtarea.

Modelo (<i>zero-shot</i>)	Tiempo de ejecución	Emisiones (kg CO ₂ eq)
Qwen 3.5 9B	13,0 min	0,0206
Gemma 4 e4b-it	18,6 min	0,0216

Tabla 4.6.: Tiempo de ejecución, *hardware* utilizado y emisiones de CO₂ equivalente registradas con *CodeCarbon* para las estrategias *zero-shot* de la subtarea de emparejamiento.

Para el sistema multi-agente desarrollado para esta tarea no se dispone de mediciones, debido al uso de llamadas a modelos externos a través de la API de Gemini, cuyo consumo no es directamente medible desde el entorno de ejecución local. No obstante, teniendo en cuenta la naturaleza iterativa del sistema, que realiza múltiples llamadas al modelo por cada ejercicio y acumula los tiempos de comunicación con la API, es razonable pensar que su huella de carbono es considerablemente mayor que la de las estrategias *zero-shot*. Teniendo en cuenta que la diferencia de *accuracy* entre el sistema multi-agente y Qwen *zero-shot* es de apenas 0,40 puntos, el coste adicional que implica

4. *Discusión y resultados*

la arquitectura multi-agente no compensa desde una perspectiva de eficiencia.

En conjunto, los resultados de esta sección demuestran que es posible construir sistemas de comprensión lectora automática en español que superan ampliamente las líneas de base de la tarea con un consumo energético muy reducido. La elección del modelo y la estrategia de *prompting* tienen un impacto mucho mayor sobre la eficiencia que sobre el rendimiento, lo que refuerza la idea de que las soluciones más complejas, aunque puedan suponer una mejora marginal a nivel de *accuracy*, conllevan costes computacionales y medioambientales desproporcionadamente elevados para la ganancia obtenida.

5. Conclusiones y trabajo futuro

Este capítulo recoge las conclusiones extraídas a partir de todo el desarrollo del proyecto y propone posibles líneas de trabajo para continuar y ampliar los resultados obtenidos. En primer lugar, la sección 5.1 resume los principales hallazgos del proyecto y reflexiona sobre las implicaciones de los resultados obtenidos. Posteriormente, la sección 5.2 identifica las limitaciones más relevantes del trabajo y propone direcciones concretas para superarlas en el futuro.

5.1. Conclusiones

A lo largo de este trabajo se ha explorado la capacidad de los LLMs para resolver ejercicios de comprensión lectora en español, evaluando distintas estrategias y arquitecturas dentro del marco de la tarea PROFE 2026. Tal y como se planteó en la sección 1.2, el objetivo principal del proyecto era medir hasta qué punto estos sistemas son capaces de superar exámenes diseñados para evaluar a personas, bajo las mismas condiciones que se aplican a los propios candidatos y sin datos de entrenamiento específicos para la tarea. Los resultados obtenidos en la competición permiten afirmar que este objetivo se ha cumplido con éxito, ya que todas las soluciones desarrolladas superan ampliamente el *baseline* propuesto por los organizadores de la competición, y alcanzan un rendimiento muy bueno en las dos tareas que se han tratado de resolver durante el desarrollo del proyecto.

Más allá de los resultados globales, todas las pruebas y experimentos realizados han permitido extraer conclusiones relevantes sobre qué estrategias funcionan mejor y cuál es el coste de cada una de ellas. Una de las más claras es que los LLMs actuales, incluso en sus versiones pequeñas, ya poseen una capacidad de comprensión lectora en español lo suficientemente sólida como para resolver este tipo de ejercicios con una precisión muy cercana a la de los candidatos humanos. Por ejemplo, un modelo de 9 billones de parámetros como Qwen 3.5 9B, en una configuración *zero-shot* sin ningún tipo de adaptación específica, alcanzó un 88,85 % de *accuracy* en selección múltiple y un 86,11 % en emparejamiento, superando en ambos casos al *baseline* de los organizadores con un consumo energético muy reducido. Este resultado confirma que, con un *prompt* bien diseñado, las capacidades de razonamiento inherentes de estos modelos son suficientes para poder resolver notablemente bien tareas de comprensión lectora en español, lo que a su vez demuestra que es posible obtener resultados competitivos sin necesidad de recurrir a infraestructuras de alto coste ni a modelos comerciales de mayor tamaño.

Si bien es cierto que las estrategias más complejas fueron las que alcanzaron los mejores resultados en ambas tareas, también plantean importantes *trade-offs* entre rendimiento, complejidad arquitectónica y eficiencia. El *ensemble* multi-agente desarrollado para la

5. Conclusiones y trabajo futuro

tarea de selección múltiple obtuvo el mejor resultado de todas las configuraciones evaluadas (90,55 %), pero a un coste computacional y medioambiental mucho mayor que las aproximaciones más básicas (más de cuatro horas de ejecución y más de 0,25 kgCO₂eq de emisiones, frente a los ocho minutos y los 0,0175 kgCO₂eq de la estrategia *zero-shot* con Qwen 3.5 9B, que obtiene una precisión apenas un 1,7 % inferior). Algo similar se observa en la subtarea de *matching*, donde el sistema multi-agente implementado supera a la mejor estrategia *zero-shot* en apenas un 0,4 % (86,51 % frente a 86,11 %), pero con un coste considerablemente mayor debido a las numerosas llamadas a una API externa de un modelo mucho más grande y potente que requiere su funcionamiento.

Estos resultados llevan a reflexionar sobre el valor real de añadir complejidad arquitectónica en tareas donde un único modelo ya alcanza un rendimiento elevado por sí mismo. Cuando la capacidad inherente del modelo es suficiente para resolver correctamente la gran mayoría de los ejercicios, incorporar mecanismos de deliberación adicionales, como la validación cruzada entre agentes o la resolución de conflictos mediante un juez, no se traduce necesariamente en una mejora de rendimiento proporcional al coste y esfuerzo que implican. No obstante, este hecho no invalida el valor de las arquitecturas multi-agente en general, sino que refleja la necesidad de identificar con precisión en qué escenarios su uso es realmente útil y puede suponer una mejora significativa: probablemente no en tareas donde el modelo base ya opera cerca de su techo de rendimiento, sino en aquellos casos donde la dificultad intrínseca del ejercicio o la ambigüedad de las opciones supera lo que un único modelo puede resolver con fiabilidad.

En una línea similar, la estrategia *chain-of-thought* con Gemma 4 E4B mejoró ligeramente los resultados de la configuración *zero-shot* con el mismo modelo (88,42 % frente a 85,63 %), aunque requirió un mayor tiempo de inferencia. Por ello, forzar a los modelos a generar un razonamiento explícito cuando ya son capaces de resolver correctamente la gran mayoría de ejercicios de las tareas no aporta una ganancia significativa, pero sí puede ser útil en aquellos casos más difíciles donde pueda haber distractores o la respuesta no aparezca explícitamente en los textos.

Por el contrario, el *fine-tuning* que se llevó a cabo para tratar de ajustar los pesos del modelo a la tarea de *multiple choice* fue la estrategia que peor funcionó, obteniendo un 85,46 % de *accuracy*, el resultado más bajo de todas las configuraciones evaluadas. Este resultado sugiere que el desajuste de dominio entre los textos de entrenamiento utilizados, procedentes del conjunto de datos ReCoRES, y los exámenes del Instituto Cervantes pudo haber restringido la capacidad de razonamiento generalizado del modelo, precisamente la que más se necesita en una tarea donde no se dispone de datos de entrenamiento específicos. Además, el coste adicional que implica el proceso de ajuste de pesos, tanto en tiempo como en recursos computacionales, hace que este enfoque no sea el más adecuado para resolver la tarea cuando las aproximaciones basadas en *prompting* son capaces de superarla sin ningún tipo de entrenamiento previo.

Otra conclusión importante extraída a partir de la primera aproximación al problema con la tarea ReCoRES (sección 3.1) y de la experiencia de los participantes en la pasada edición de la competición (sección 2.3.3) es que estos modelos generativos superan notablemente a las arquitecturas *encoder-only* a la hora de resolver esta clase de tareas. Este tipo de modelos, más orientados a la representación semántica, no disponen de esa capacidad para razonar y generar texto que permite comprender el lenguaje y alcanzar un rendimiento competitivo en tareas de comprensión lectora automática. Por

5. Conclusiones y trabajo futuro

ello, independientemente del volumen de datos o del entrenamiento que se utilice, tienen un techo de rendimiento muy inferior al de los modelos generativos en tareas que exigen comprender el significado global de un texto y razonar sobre él para seleccionar la respuesta correcta entre opciones que pueden ser confusas y muy similares entre sí.

Por último, cabe destacar que todas las soluciones desarrolladas durante el trabajo se han evaluado únicamente sobre los exámenes en español del Instituto Cervantes, pero la metodología es completamente agnóstica al idioma. Esto permite que los mismos enfoques puedan utilizarse para abordar tareas de comprensión lectora automática en otros idiomas, abriendo una línea de trabajo para evaluar la capacidad de estos sistemas más allá del español.

5.2. Trabajo futuro

Los resultados y las conclusiones obtenidas en este trabajo abren varias líneas de investigación que podrían explorarse en el futuro para superar algunas de las limitaciones identificadas y ampliar el alcance de las soluciones desarrolladas.

En primer lugar, tener acceso a los resultados desglosados por nivel del Marco Común Europeo de Referencia (MCER) sería muy interesante, ya que permitiría profundizar considerablemente en el análisis de las soluciones desarrolladas. Al no haberse publicado el conjunto de datos oficial, únicamente se dispone de la precisión global de cada envío, lo que impide determinar si los errores se concentran en los niveles más avanzados (C1 y C2) o si, por el contrario, las estrategias más simples tienen dificultades en niveles concretos que las arquitecturas más complejas sí resuelven correctamente. Disponer de esta información permitiría diseñar soluciones mucho más orientadas, por ejemplo aplicando estrategias más sofisticadas solo en los ejercicios de mayor dificultad, y sacar conclusiones más sólidas sobre las capacidades reales de cada enfoque.

En esta misma línea, construir un conjunto de evaluación más amplio y representativo, que cubra todos los niveles MCER con un número suficiente y equilibrado de ejercicios, permitiría reducir la incertidumbre asociada al proceso de desarrollo y obtener estimaciones más fiables del rendimiento real de cada estrategia antes de los envíos oficiales. Aunque los resultados sobre el conjunto de desarrollo utilizado en este trabajo mostraron una correlación razonable con los oficiales, disponer de más ejemplos de los niveles menos representados, especialmente en la subtarea de *matching*, facilitaría tanto la comparación entre estrategias como la selección de los envíos definitivos con mayor confianza.

Otra línea de trabajo prometedora es la optimización de las arquitecturas multi-agente para reducir su coste computacional y medioambiental sin sacrificar rendimiento. Los resultados obtenidos muestran que estos sistemas aportan una pequeña mejora sobre los modelos base con una estrategia *zero-shot*, pero a un coste mucho más elevado. Una alternativa más eficiente sería adoptar un enfoque de enrutamiento dinámico, en el que un modelo pequeño resuelva por defecto la mayoría de los ejercicios y el sistema multi-agente se active únicamente ante los casos de menor confianza o mayor dificultad. Esta estrategia permitiría concentrar los recursos computacionales donde realmente aportan valor, encontrando un equilibrio más razonable entre precisión, latencia y huella de carbono.

5. Conclusiones y trabajo futuro

Evaluar las estrategias desarrolladas con modelos generativos de otros tamaños también podría ser una línea de trabajo futuro interesante. Durante el desarrollo del trabajo todas las pruebas se realizaron utilizando modelos de entre 8 y 9 billones de parámetros, por lo que quedan abiertas dos preguntas complementarias. Por un lado, evaluar modelos más pequeños permitiría determinar hasta qué punto las arquitecturas más compactas mantienen esa capacidad de comprensión lectora, lo que permitiría implementar sistemas de este tipo en entornos con recursos bastante limitados. Por otro, probar modelos de mayor tamaño ayudaría a establecer si el techo de rendimiento observado en este trabajo puede elevarse significativamente con más capacidad, o si una solución bien diseñada es suficiente para alcanzar un alto rendimiento en la tarea independientemente del tamaño del modelo.

Por otro lado, sería valioso extender el trabajo a la tercera subtarea propuesta en PROFE 2026, *fill-the-gaps*, que presenta una estructura diferente a las dos estudiadas en este trabajo y plantea nuevos desafíos, como la necesidad de razonar sobre la coherencia global del texto para colocar correctamente cada fragmento. Analizar hasta qué punto las estrategias desarrolladas para selección múltiple y emparejamiento son transferibles a este tipo de ejercicio, y qué adaptaciones requieren, sería una continuación natural del desarrollo de este trabajo.

Más allá del marco de la tarea PROFE 2026, los resultados obtenidos abren la puerta a aplicaciones de mayor alcance. Por un lado, aplicar el mismo enfoque a otras lenguas con exámenes de certificación basados en el MCER permitiría comparar el rendimiento de los LLMs en distintos idiomas y comprobar hasta qué punto sus capacidades de comprensión lectora son transferibles más allá del español. Por otro, aprovechar la capacidad demostrada por estos sistemas para comprender y razonar sobre textos complejos podría ser el punto de partida para el desarrollo de herramientas con aplicaciones directas en el ámbito educativo, desde asistentes capaces de apoyar el aprendizaje del idioma hasta sistemas de evaluación automática que alivien la carga de corrección en entornos de enseñanza, contribuyendo así a una integración de la inteligencia artificial en la educación que sea a la vez útil, eficiente y responsable.

6. Introduction

This chapter introduces the Master’s Thesis. First, section 6.1 presents the motivation behind the work and the reasons that have led to its development. Subsequently, section 6.2 details the objectives set out at the beginning of the project. Next, section 6.3 describes the work plan followed throughout the development, and finally, section 6.4 contains a description of the structure of the document, with a brief summary of each of the sections that compose it.

6.1. Motivation

The emergence of Large Language Models (LLMs) has profoundly transformed the field of Natural Language Processing (NLP). In recent years, these models have evolved from solving relatively simple linguistic tasks to successfully tackling problems that require a deep understanding of language, such as information extraction, logical reasoning, or answering questions about complex texts. However, determining whether these systems truly understand language or simply reproduce patterns learned during training is not trivial, since most current benchmarks and competitions use data that the models may have seen or inferred during their pre-training phase, which prevents a rigorous measurement of their true generalization and comprehension capabilities.

This general problem is compounded by a clear linguistic asymmetry in research on Machine Reading Comprehension (MRC), since the vast majority of resources, datasets, and benchmark competitions are designed for English. Spanish, despite being a language with hundreds of millions of speakers, remains clearly underrepresented in this line of work, which hinders the development and rigorous evaluation of systems adapted to its particular linguistic features.

It is in this context that the PROFE task¹ (*Language Proficiency Evaluation for Spanish*) emerges, organized within the framework of the *Iberian Languages Evaluation Forum*² (IberLEF). Its main goal is to evaluate reading comprehension in Spanish under controlled conditions, where systems must solve official Instituto Cervantes³ exams, originally designed to measure human language proficiency, without access to training data specific to the task. This restriction is precisely what makes it possible to measure the models’ real comprehension ability rather than merely their skill at fitting a dataset they may have already seen.

Understanding to what extent LLMs are capable of passing these evaluations has implications that go beyond the academic sphere. A system that demonstrates a high

¹<https://sites.google.com/view/profe2026>

²<https://sites.google.com/view/iberlef-2026/home>

³<https://examen.es/cervantes.es/es/dele/examen/es/a1>

6. Introduction

level of reading comprehension in Spanish could be the starting point for developing tools with a wide range of applications, from educational assistants capable of supporting language learning to automatic assessment systems that ease the grading workload in teaching environments. Being able to compare the performance of these systems against that of the students themselves, under exactly the same conditions, also constitutes a rigorous and meaningful evaluation framework that could prove highly useful in the future.

All of these open questions make Machine Reading Comprehension in Spanish a particularly interesting area of research within the field of artificial intelligence. Exploring which strategies and architectures allow the maximum performance to be extracted from current LLMs, identifying their real limitations, and attempting to overcome them with solutions that combine effectiveness and efficiency is, ultimately, the motivation behind this work.

6.2. Objectives

The overall goal of this project is to evaluate the real reading comprehension capability in Spanish of current LLMs, analyzing to what extent these systems are able to solve exercises originally designed to assess people, without access to training data specific to the task and under the same conditions applied to the students themselves.

To achieve this overall goal, the following specific objectives are proposed:

1. **Explore and compare different artificial intelligence strategies and techniques** applied to reading comprehension in Spanish, ranging from prompting-based approaches to multi-agent architectures and model *fine-tuning*, in order to identify which approaches prove most effective for this type of task.
2. **Develop solutions that not only perform well but are also efficient:** Beyond accuracy on the task, the aim is to find the right balance between performance and computational cost, avoiding solutions that are only competitive at a disproportionate cost in time or resources.
3. **Determine whether competitive results can be obtained with limited computational resources:** A central part of this work is demonstrating that it is not necessary to resort to large-scale commercial models or high-cost infrastructure to reliably address Spanish reading comprehension tasks, and to establish how high that performance ceiling can reach.
4. **Measure the environmental impact of the developed solutions:** Record the energy consumption and carbon footprint of each strategy in order to incorporate sustainability as an evaluation criterion, promoting a more responsible development of systems that is more aware of their real cost.

6.3. Work Plan

The development of this project has been organized into different phases, each with a set of specific objectives that allowed progress to be made gradually, from an initial

6. Introduction

approach to the problem to official participation in the PROFE 2026 competition.

The first phase took place between November 2025 and January 2026 and was used to study the problem and carry out an initial approach to it. During this period, the state of the art in Machine Reading Comprehension in Spanish was reviewed, along with the solutions presented in previous editions of the PROFE task. At the same time, initial tests were carried out with different models and strategies, with the aim of identifying possible problems and solutions before focusing on the main task.

From February 2026 onward, the work focused on developing the solutions for the PROFE 2026 competition (section 3.2). This phase included building the development set described in section 3.3, the iterative implementation and evaluation of the different strategies for the subtasks addressed during the work, and the selection of the final submissions before the official deadline closed on May 11, 2026. After receiving the official evaluation results, an analysis of the results was carried out, leading to a scientific paper presented and accepted at the competition, and, in parallel, to the writing of this Master’s Thesis, completed in June 2026.

Throughout the project, regular meetings were held with the tutor approximately every two weeks, with the aim of discussing progress, resolving questions that arose at each stage, and adjusting the planning when necessary. GitHub was used for code management and version control, which made it possible to maintain a complete development history and ease the tracking of changes throughout the project. All the solutions developed can be found in the following repository: <https://github.com/NILGroup/TFM2526-ExamenesComprensionLectora.git>

6.4. Document Structure

The content of this document is structured according to the chapters detailed below:

- **Chapter 1: Introducción.** Presents the main motivation behind the work, the objectives set out at the start of the project, the work plan followed throughout the development, and, finally, a description of the structure of the entire document.
- **Chapter 2: State of the Art.** Places the work within the context of the state of the art in Natural Language Processing (NLP), reviewing prior work in automatic reading comprehension, the main *prompting* and *fine-tuning* techniques for large language models, and multi-agent systems. It also includes a description of the PROFE 2025 task, the previous edition of the competition within which this project is framed, and of the solutions submitted by the participating teams.
- **Chapter 3: Methodology and Development.** Describes the process followed to develop the proposed solutions. It starts from an initial approach to the problem through the ReCoRES task, presents the PROFE 2026 competition within which the work is framed, and details the strategies implemented for the two subtasks addressed: multiple choice and matching. The chapter concludes with a description of the submissions made to the competition and the criteria followed for their selection.

6. Introduction

- **Chapter 4: Results.** Presents and analyzes the results obtained in the PROFE 2026 competition, for both the multiple-choice subtask and the matching subtask. It includes a comparison between the different strategies developed and an analysis of the energy efficiency of each of the solutions submitted to the official competition.
- **Chapter 5: Conclusions and Future Work.** Gathers the conclusions drawn from the work and proposes possible future lines of work to continue researching and to expand the scope of the project.
- **Chapter 6: Introduction.** English translation of the introduction chapter, including the motivation, objectives, work plan, and document structure.
- **Chapter 7: Conclusiones y Trabajo Futuro.** English translation of the conclusions chapter, gathering the main contributions of the work and the proposed future lines of work.

Finally, the document includes three appendices with supplementary material that may be useful for consulting specific details while reading the work: the *prompts* used during the first approach to the problem with the ReCoRES task (Appendix A), a selection of examples from official exams together with their correspondence in the dataset used throughout the work (Appendix B), and the link to the GitHub repository where all the developed solutions are available (Appendix C).

7. Conclusions and future work

This chapter gathers the conclusions drawn from the development of the project and proposes possible lines of work to continue and expand the results obtained. First, Section 7.1 summarizes the main findings of the project and reflects on the implications of the results obtained. Subsequently, Section 7.2 identifies the most relevant limitations of the work and proposes concrete directions to overcome them in the future.

7.1. Conclusions

Throughout this work, the capacity of LLMs to solve Spanish reading comprehension exercises has been explored, evaluating different strategies and architectures within the framework of the PROFE 2026 task. As stated in Section 6.2, the main objective of the project was to measure to what extent these systems are able to pass exams designed to assess people, under the same conditions applied to the candidates themselves and without any training data specific to the task. The results obtained in the competition allow us to state that this objective has been successfully met, since all the solutions developed comfortably outperform the baseline proposed by the organizers of the competition and achieve a very good performance on both tasks addressed during the development of the project.

Beyond the overall results, all the tests and experiments carried out have made it possible to draw relevant conclusions about which strategies work best and what the cost of each of them is. One of the clearest is that current LLMs, even in their smaller versions, already possess a reading comprehension capability in Spanish solid enough to solve this type of exercises with an accuracy very close to that of human candidates. For example, a 9-billion-parameter model such as Qwen 3.5 9B, in a *zero-shot* configuration without any specific adaptation, achieved 88.85 % accuracy in multiple choice and 86.11 % in matching, surpassing the organizers’ baseline in both cases with very low energy consumption. This result confirms that, with a well-designed *prompt*, the inherent reasoning capabilities of these models are sufficient to solve Spanish reading comprehension tasks remarkably well, which in turn demonstrates that it is possible to obtain competitive results without resorting to high-cost infrastructure or larger commercial models.

While it is true that the more complex strategies achieved the best results in both tasks, they also raise important trade-offs between performance, architectural complexity, and efficiency. The multi-agent ensemble developed for the multiple-choice task obtained the best result among all the configurations evaluated (90.55 %), but at a much higher computational and environmental cost than the simpler approaches (more than four hours of execution and more than 0.25 kgCO₂eq of emissions, compared to the eight minutes and 0.0175 kgCO₂eq of the *zero-shot* strategy with Qwen 3.5 9B, which achieves

7. Conclusions and future work

an accuracy only 1.7% lower). Something similar can be observed in the matching sub-task, where the implemented multi-agent system outperforms the best *zero-shot* strategy by barely 0.4% (86.51% versus 86.11%), but at a considerably higher cost due to the numerous calls required to an external API of a much larger and more powerful model.

These results invite reflection on the real value of adding architectural complexity to tasks where a single model already achieves a high level of performance on its own. When the model’s inherent capacity is sufficient to correctly solve the vast majority of exercises, incorporating additional deliberation mechanisms, such as cross-validation between agents or conflict resolution through a judge, does not necessarily translate into a performance improvement proportional to the cost and effort involved. However, this does not invalidate the value of multi-agent architectures in general; rather, it reflects the need to identify precisely in which scenarios their use is genuinely useful and can provide a meaningful improvement: probably not in tasks where the base model already operates close to its performance ceiling, but in those cases where the intrinsic difficulty of the exercise or the ambiguity of the options exceeds what a single model can reliably resolve.

Along similar lines, the *chain-of-thought* strategy with Gemma 4 E4B slightly improved the results of the *zero-shot* configuration with the same model (88.42% versus 85.63%), although it required a longer inference time. Therefore, forcing models to generate explicit reasoning when they are already able to correctly solve the vast majority of the task’s exercises does not provide a significant gain, but it can be useful in more difficult cases where distractors may be present or the answer does not appear explicitly in the texts.

By contrast, the *fine-tuning* carried out to adjust the model’s weights to the *multiple choice* task was the worst-performing strategy, achieving 85.46% accuracy, the lowest result among all the configurations evaluated. This result suggests that the domain mismatch between the training texts used, drawn from the ReCoRES dataset, and the Instituto Cervantes exams may have restricted the model’s generalized reasoning capability, precisely the capability most needed in a task where no task-specific training data is available. Furthermore, the additional cost involved in the weight-adjustment process, both in time and computational resources, makes this approach less suitable for solving the task when *prompting*-based approaches are already able to outperform it without any prior training.

Another important conclusion drawn from the initial approach to the problem with the ReCoRES task (Section 3.1) and from the experience of the participants in the previous edition of the competition (Section 2.3.3) is that these generative models notably outperform *encoder-only* architectures when solving this type of task. This kind of models, more oriented toward semantic representation, lacks the capacity for reasoning and text generation that enables language understanding and competitive performance on automatic reading comprehension tasks. Therefore, regardless of the volume of data or training used, they have a much lower performance ceiling than generative models on tasks that require understanding the overall meaning of a text and reasoning about it in order to select the correct answer among options that may be confusing and very similar to one another.

Finally, it is worth noting that all the solutions developed during this work have

been evaluated solely on the Spanish-language exams of the Instituto Cervantes, but the methodology is entirely language-agnostic. This means that the same approaches could be used to address automatic reading comprehension tasks in other languages, opening up a line of work to evaluate the capability of these systems beyond Spanish.

7.2. Future Work

The results and conclusions obtained in this work open up several lines of research that could be explored in the future to overcome some of the limitations identified and to expand the scope of the solutions developed.

First, having access to results broken down by level of the Common European Framework of Reference for Languages (CEFR) would be very valuable, as it would allow for a much deeper analysis of the solutions developed. Since the official dataset was not published, only the overall accuracy of each submission is available, which makes it impossible to determine whether errors are concentrated in the more advanced levels (C1 and C2) or, conversely, whether simpler strategies struggle at specific levels that more complex architectures are able to solve correctly. Having this information would make it possible to design much more targeted solutions, for example by applying more sophisticated strategies only to the most difficult exercises, and to draw more solid conclusions about the real capabilities of each approach.

Along the same lines, building a larger and more representative evaluation set, covering all CEFR levels with a sufficient and balanced number of exercises, would reduce the uncertainty associated with the development process and provide more reliable estimates of the actual performance of each strategy before the official submissions. Although the results on the development set used in this work showed a reasonable correlation with the official ones, having more examples of the less represented levels, especially in the matching subtask, would facilitate both the comparison between strategies and the selection of the final submissions with greater confidence.

Another promising line of work is the optimization of multi-agent architectures to reduce their computational and environmental cost without sacrificing performance. The results obtained show that these systems provide only a small improvement over the base models with a *zero-shot* strategy, but at a much higher cost. A more efficient alternative would be to adopt a dynamic routing approach, in which a small model resolves most of the exercises by default and the multi-agent system is activated only for cases of lower confidence or higher difficulty. This strategy would make it possible to concentrate computational resources where they really add value, achieving a more reasonable balance between accuracy, latency, and carbon footprint.

Evaluating the strategies developed with generative models of other sizes could also be an interesting line of future work. During the development of this work, all tests were carried out using models with between 8 and 9 billion parameters, which leaves two complementary questions open. On the one hand, evaluating smaller models would make it possible to determine to what extent more compact architectures retain this reading comprehension capability, which would allow this type of system to be deployed in environments with rather limited resources. On the other hand, testing larger models would help establish whether the performance ceiling observed in this work can be significantly

7. Conclusions and future work

raised with greater capacity, or whether a well-designed solution is sufficient to achieve high performance on the task regardless of model size.

Additionally, it would be worthwhile extending the work to the third subtask proposed in PROFE 2026, *fill-the-gaps*, which presents a different structure from the two studied in this work and poses new challenges, such as the need to reason about the overall coherence of the text in order to correctly place each fragment. Analyzing to what extent the strategies developed for multiple choice and matching are transferable to this type of exercise, and what adaptations they require, would be a natural continuation of the development of this work.

Beyond the framework of the PROFE 2026 task, the results obtained open the door to broader-reaching applications. On the one hand, applying the same approach to other languages with CEFR-based certification exams would make it possible to compare the performance of LLMs across different languages and to check to what extent their reading comprehension capabilities are transferable beyond Spanish. On the other hand, leveraging the demonstrated capacity of these systems to understand and reason about complex texts could be the starting point for developing tools with direct applications in education, ranging from assistants capable of supporting language learning to automatic assessment systems that ease the grading workload in teaching environments, thereby contributing to an integration of artificial intelligence into education that is at once useful, efficient, and responsible.

Bibliografía

- Anthropic (feb. de 2025). *Claude 3.7 Sonnet System Card*. Inf. téc. Anthropic. URL: <https://www-cdn.anthropic.com/9ff93dfa8f445c932415d335c88852ef47f1201e/claude-3-7-sonnet-system-card.pdf>.
- Artetxe, Mikel, Sebastian Ruder y Dani Yogatama (2019). «On the cross-lingual transferability of monolingual representations». En: *CoRR* abs/1910.11856. arXiv: 1910.11856.
- Bonet-Jover, A., J. A. González-Barba y L. Chiruzzo (2026). «Overview of IberLEF 2026: Natural Language Processing Challenges for Spanish and other Iberian Languages». En: *Proceedings of the Iberian Languages Evaluation Forum (IberLEF 2026), co-located with the 42nd Conference of the Spanish Society for Natural Language Processing (SEPLN 2026)*. CEUR-WS.org.
- Brown, Tom B. et al. (2020). «Language Models are Few-Shot Learners». En: *CoRR* abs/2005.14165. arXiv: 2005.14165. URL: <https://arxiv.org/abs/2005.14165>.
- Cantero-Romero, María Victoria y Salud María Jiménez-Zafra (2025). «SINAI at PROFE 2025: Evaluating Large Language Models for Spanish Language Proficiency». En: *Proceedings of the Iberian Languages Evaluation Forum (IberLEF 2025)*. Vol. 4098. CEUR Workshop Proceedings. URL: https://ceur-ws.org/Vol-4098/PROFE_paper4.pdf.
- Conneau, Alexis et al. (2019). «Unsupervised Cross-lingual Representation Learning at Scale». En: *CoRR* abs/1911.02116. arXiv: 1911.02116. URL: <http://arxiv.org/abs/1911.02116>.
- Courty, Benoit, Victor Schmidt, Aditya Goyal-Y et al. (2021). *CodeCarbon: Estimate and Track Carbon Emissions from Machine Learning Computing*. <https://github.com/mlco2/codecarbon>.
- Dettmers, Tim et al. (2023). *QLoRA: Efficient Finetuning of Quantized LLMs*. arXiv: 2305.14314 [cs.LG]. URL: <https://arxiv.org/abs/2305.14314>.
- Devlin, Jacob et al. (2018). «BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding». En: *CoRR* abs/1810.04805. arXiv: 1810.04805. URL: <http://arxiv.org/abs/1810.04805>.
- Diego Diestra y Rodrigo López y Erasmo Gómez y Arturo Oncevay y Fernando Alva-Manchego, Marco Antonio Sobrevilla Cabezudo y (2022). «Overview of ReCoRES at IberLEF 2022: Reading Comprehension and Reasoning Explanation for Spanish». En: *Procesamiento del Lenguaje Natural* 69.0, págs. 281-287. ISSN: 1989-7553. URL: <http://journal.sepln.org/sepln/ojs/ojs/index.php/pln/article/view/6448>.
- Du, Yilun et al. (2023). *Improving Factuality and Reasoning in Language Models through Multiagent Debate*. arXiv: 2305.14325 [cs.CL]. URL: <https://arxiv.org/abs/2305.14325>.
- Dubey, Abhimanyu et al. (2024). «The Llama 3 Herd of Models». En: URL: <https://api.semanticscholar.org/CorpusID:271571434>.

- Folgueira, Pablo, Sandra Conde y Alberto Díaz (sep. de 2026). «NIL-UCM at PROFE 2026: Prompting, Fine-Tuning and Multi-Agent Strategies for Reading Comprehension». En: *Proceedings of the Iberian Languages Evaluation Forum (IberLEF 2026)*. León, Spain.
- Fraile-Hernández, Jesús M. y Anselmo Peñas (2025). «JFra-Team at PROFE 2025: A Multi-Agent Zero-Shot System for Spanish Language Proficiency Question Answering». En: *Proceedings of the Iberian Languages Evaluation Forum (IberLEF 2025)*. Vol. 4098. CEUR Workshop Proceedings. URL: https://ceur-ws.org/Vol-4098/PROFE_paper1.pdf.
- González-Barba, José Ángel, Luis Chiruzzo y Salud María Jiménez-Zafra (2025). «Overview of IberLEF 2025: Natural Language Processing Challenges for Spanish and other Iberian Languages». En: *Proceedings of the Iberian Languages Evaluation Forum (IberLEF 2025), co-located with the 41st Conference of the Spanish Society for Natural Language Processing (SEPLN 2025)*. CEUR-WS.org. URL: <https://ceur-ws.org/Vol-4098/overview.pdf>.
- Gonzalo, Julio, Manuel Montes-y-Gómez y Francisco Rangel (2022). «Overview of IberLEF 2022: Natural Language Processing Challenges for Spanish and other Iberian Languages». En: *Proceedings of the IberLEF 2022*. Vol. 3202. CEUR Workshop Proceedings. CEUR-WS.org.
- Google Cloud (2025). *Gemini 2.5 Flash-Lite Documentation*. <https://docs.cloud.google.com/gemini-enterprise-agent-platform/models/gemini/2-5-flash-lite?hl=es-419>.
- Google DeepMind (2026). *Gemma 4*. <https://deepmind.google/models/gemma/gemma-4/>.
- Guo, Daya et al. (sep. de 2025). «DeepSeek-R1 incentivizes reasoning in LLMs through reinforcement learning». En: *Nature* 645.8081, págs. 633-638. ISSN: 1476-4687. DOI: 10.1038/s41586-025-09422-z. URL: <http://dx.doi.org/10.1038/s41586-025-09422-z>.
- Guo, Taicheng et al. (2024). *Large Language Model based Multi-Agents: A Survey of Progress and Challenges*. arXiv: 2402.01680 [cs.CL]. URL: <https://arxiv.org/abs/2402.01680>.
- Gutiérrez-Fandiño, Asier et al. (2022). «MarIA: Spanish Language Models». En: *Procesamiento del Lenguaje Natural* 68.0, págs. 39-60. ISSN: 1989-7553. URL: <http://journal.sepln.org/sepln/ojs/ojs/index.php/pln/article/view/6405>.
- He, Pengcheng, Jianfeng Gao y Weizhu Chen (2021). *DeBERTaV3: Improving DeBERTa using ELECTRA-Style Pre-Training with Gradient-Disentangled Embedding Sharing*. arXiv: 2111.09543 [cs.CL].
- He, Pengcheng, Xiaodong Liu et al. (2021). «DeBERTa: Decoding-Enhanced BERT with disentangled attention». En: *International Conference on Learning Representations*. URL: <https://openreview.net/forum?id=XPZiaotutsD>.
- Hendrycks, Dan, Collin Burns, Steven Basart, Andrew Critch et al. (2021). «Aligning AI With Shared Human Values». En: *Proceedings of the International Conference on Learning Representations (ICLR)*.
- Hendrycks, Dan, Collin Burns, Steven Basart, Andy Zou et al. (2021). «Measuring Massive Multitask Language Understanding». En: *Proceedings of the International Conference on Learning Representations (ICLR)*.

- Hermann, Karl Moritz et al. (2015). «Teaching Machines to Read and Comprehend». En: *CoRR* abs/1506.03340. arXiv: 1506.03340. URL: <http://arxiv.org/abs/1506.03340>.
- Hirschman, Lynette et al. (jun. de 1999). «Deep Read: A Reading Comprehension System». En: *Proceedings of the 37th Annual Meeting of the Association for Computational Linguistics*. College Park, Maryland, USA: Association for Computational Linguistics, págs. 325-332. DOI: 10.3115/1034678.1034731. URL: <https://aclanthology.org/P99-1042/>.
- Hu, Edward J. et al. (2021). «LoRA: Low-Rank Adaptation of Large Language Models». En: *CoRR* abs/2106.09685. arXiv: 2106.09685. URL: <https://arxiv.org/abs/2106.09685>.
- Hugging Face (2026). *Documentación de Transformers*. URL: <https://huggingface.co/docs/transformers/es/index> (visitado 05-06-2026).
- Lai, Guokun et al. (sep. de 2017). «RACE: Large-scale ReAding Comprehension Dataset From Examinations». En: *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing*. Ed. por Martha Palmer, Rebecca Hwa y Sebastian Riedel. Copenhagen, Denmark: Association for Computational Linguistics, págs. 785-794. DOI: 10.18653/v1/D17-1082. URL: <https://aclanthology.org/D17-1082/>.
- LangChain, Inc. (2026). *LangChain Documentation*. <https://docs.langchain.com/>.
- Lewis, Patrick et al. (2019). «MLQA: Evaluating Cross-lingual Extractive Question Answering». En: *CoRR* abs/1910.07475. arXiv: 1910.07475. URL: <http://arxiv.org/abs/1910.07475>.
- Lin, Chin-Yew (jul. de 2004). «ROUGE: A Package for Automatic Evaluation of Summaries». En: *Text Summarization Branches Out*. Barcelona, Spain: Association for Computational Linguistics, págs. 74-81. URL: <https://aclanthology.org/W04-1013/>.
- Liu, Yinhan et al. (2019). «RoBERTa: A Robustly Optimized BERT Pretraining Approach». En: *CoRR* abs/1907.11692. arXiv: 1907.11692. URL: <http://arxiv.org/abs/1907.11692>.
- Madaan, Aman et al. (2023). *Self-Refine: Iterative Refinement with Self-Feedback*. arXiv: 2303.17651 [cs.CL]. URL: <https://arxiv.org/abs/2303.17651>.
- Mistral AI (2023). *Mistral 7B (v0.1) Model Card*. URL: <https://docs.mistral.ai/models/model-cards/mistral-7b-0-1>.
- Ollama (2026). *Ollama Documentation*. URL: <https://docs.ollama.com/>.
- Papineni, Kishore et al. (2002). «BLEU: a method for automatic evaluation of machine translation». En: *Proceedings of the 40th Annual Meeting on Association for Computational Linguistics*. ACL '02. Philadelphia, Pennsylvania: Association for Computational Linguistics, págs. 311-318. DOI: 10.3115/1073083.1073135. URL: <https://doi.org/10.3115/1073083.1073135>.
- Peñas, Anselmo, Eduard Hovy et al. (2013). «QA4MRE 2011-2013: Overview of Question Answering for Machine Reading Evaluation». En: *Information Access Evaluation. Multilinguality, Multimodality, and Visualization*. Ed. por Pamela Forner et al. Berlin, Heidelberg: Springer Berlin Heidelberg, págs. 303-320. ISBN: 978-3-642-40802-1.
- Peñas, Anselmo, Álvaro Rodrigo, Javier Fruns-Jiménez, Inés Soria-Pastor, Sergio Moreno-Álvarez, Alberto Pérez et al. (2026). «A Spanish Language Proficiency Dataset for AI

- Evaluation». En: *Information* 17.2. ISSN: 2078-2489. DOI: 10.3390/info17020159. URL: <https://www.mdpi.com/2078-2489/17/2/159>.
- Peñas, Anselmo, Álvaro Rodrigo, Javier Fruns-Jiménez, Inés Soria-Pastor, Sergio Moreno-Álvarez, Alberto Pérez García-Plaza et al. (2026). «A Spanish Language Proficiency Dataset for AI Evaluation». En: *Information* 17.2, pág. 159. DOI: 10.3390/info17020159.
- Platas, Alexander et al. (2025). «VICOMTECH at PROFE 2025: LLM Size is not so Important». En: *Proceedings of the Iberian Languages Evaluation Forum (IberLEF 2025)*. Vol. 4098. CEUR Workshop Proceedings. URL: https://ceur-ws.org/Vol-4098/PROFE_paper6.pdf.
- Pydantic, Inc. (2026). *Pydantic Documentation - Get started*. URL: <https://pydantic.dev/docs/validation/latest/get-started/>.
- Qwen et al. (2025). *Qwen2.5 Technical Report*. arXiv: 2412.15115 [cs.CL]. URL: <https://arxiv.org/abs/2412.15115>.
- Qwen Team (2026). *Qwen3.5: Towards Native Multimodal Agents*. URL: <https://qwen.ai/blog?id=qwen3.5>.
- Rajpurkar, Pranav et al. (2016). «SQuAD: 100, 000+ Questions for Machine Comprehension of Text». En: *CoRR* abs/1606.05250. arXiv: 1606.05250. URL: <http://arxiv.org/abs/1606.05250>.
- Rodrigo, Álvaro et al. (2026). «Overview of PROFE at IberLEF 2026: Language Proficiency Evaluation». En: *Procesamiento del Lenguaje Natural* 77. ISSN: 1135-5948.
- Rodríguez-García, Miguel Ángel et al. (2025). «URJC-Team at PROFE2025@ IberLEF: Deep Language Comprehension Using Transformers Voting Architecture». En: *Proceedings of the Iberian Languages Evaluation Forum (IberLEF 2025)*. Vol. 4098. CEUR Workshop Proceedings. URL: https://ceur-ws.org/Vol-4098/PROFE_paper5.pdf.
- Schulhoff, Sander et al. (2025). *The Prompt Report: A Systematic Survey of Prompt Engineering Techniques*. arXiv: 2406.06608 [cs.CL]. URL: <https://arxiv.org/abs/2406.06608>.
- Sergio Moreno-Álvarez y Alberto Pérez y Anselmo Peñas y Rodrigo Agerri y Javier Fruns-Jiménez y Inés Soria-Pastor, Álvaro Rodrigo y (2025). «Overview of PROFE at IberLEF 2025: Language Proficiency Evaluation». En: *Procesamiento del Lenguaje Natural* 75.0, págs. 487-497. ISSN: 1989-7553. URL: <http://journal.sepln.org/sepln/ojs/ojs/index.php/pln/article/view/6770>.
- Team, Gemma et al. (2025). *Gemma 3 Technical Report*. arXiv: 2503.19786 [cs.CL]. URL: <https://arxiv.org/abs/2503.19786>.
- Unsloth Team (2026). *Unsloth Documentation*. URL: <https://unsloth.ai/docs> (visitado 05-06-2026).
- Vaswani, Ashish et al. (2017). «Attention Is All You Need». En: *CoRR* abs/1706.03762. arXiv: 1706.03762. URL: <http://arxiv.org/abs/1706.03762>.
- Wei, Jason et al. (2022). «Chain of Thought Prompting Elicits Reasoning in Large Language Models». En: *CoRR* abs/2201.11903. arXiv: 2201.11903. URL: <https://arxiv.org/abs/2201.11903>.
- Winkler, Anna-Maria (2026). «From human subjectivity to algorithmic objectivity: Automatic Reading Comprehension Assessment in Spanish as a Foreign Language». Trabajo Fin de Máster. Madrid, España: Universidad Complutense de Madrid.

Bibliografía

- Winkler, Anna-Maria y Alberto Díaz (2025). «NIL-UCM at PROFE 2025: Adapting QA Models to Multiple-Choice Tasks». En: *Proceedings of the Iberian Languages Evaluation Forum (IberLEF 2025)*. Vol. 4098. CEUR Workshop Proceedings. URL: https://ceur-ws.org/Vol-4098/PROFE_paper2.pdf.
- Zhang, Tianyi et al. (2019). «BERTScore: Evaluating Text Generation with BERT». En: *CoRR* abs/1904.09675. arXiv: 1904.09675. URL: <http://arxiv.org/abs/1904.09675>.
- Zhang, Zhuosheng, Hai Zhao y Rui Wang (2020). «Machine Reading Comprehension: The Role of Contextualized Language Models and Beyond». En: *CoRR* abs/2005.06249. arXiv: 2005.06249. URL: <https://arxiv.org/abs/2005.06249>.
- Zheng, Lianmin et al. (2023). *Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena*. arXiv: 2306.05685 [cs.CL]. URL: <https://arxiv.org/abs/2306.05685>.

A. *Prompts* de la primera aproximación al problema

Este apéndice recoge los *prompts* completos utilizados en las distintas estrategias basadas en *prompting* exploradas durante la primera aproximación al problema de la comprensión lectora automática, descritas en la sección 3.1.3.

System prompt: Tu tarea es analizar el texto y responder a la pregunta seleccionando la opción correcta.

Debes responder EXCLUSIVAMENTE con un objeto JSON válido, sin incluir explicaciones previas ni posteriores. El formato debe ser Estrictamente este:

```
{
  "explicacion": "Aquí escribes una explicación de la respuesta elegida basándote en el texto.",
  "respuesta": "Aquí escribes SOLAMENTE la letra de la opción correcta (A, B, C, D o E)."
}
```

User prompt:

Texto: {text}

Pregunta: {question}

Opciones:

{options}

Respuesta:

Figura A.1.: *Prompts* definidos para la estrategia *zero-shot* básica para resolver la tarea ReCoRES.

A. Prompts de la primera aproximación al problema

System prompt: Eres un profesor experto en resolución de exámenes de comprensión lectora en español. Tu tarea es analizar el texto y responder a la pregunta seleccionando la opción correcta.

Debes responder EXCLUSIVAMENTE con un objeto JSON válido, sin incluir explicaciones previas ni posteriores. El formato debe ser Estrictamente este:

```
{
  "explicacion": "Aquí escribes una explicación de la respuesta elegida basándote en el texto.",
  "respuesta": "Aquí escribes SOLAMENTE la letra de la opción correcta (A, B, C, D o E)."
}
```

User prompt:

Texto: {text}

Pregunta: {question}

Opciones:

{options}

Respuesta:

Figura A.2.: Prompts definidos para la estrategia *zero-shot* con *role prompting*, que asigna al modelo el rol de profesor experto en comprensión lectora.

A. Prompts de la primera aproximación al problema

User prompt:

A continuación te muestro un ejemplo de cómo debes explicar tu respuesta y responder a la pregunta:

— EJEMPLO 1 —

Texto: La fotosíntesis es el proceso mediante el cual las plantas producen su alimento usando luz solar.

Pregunta: ¿Qué necesitan las plantas para la fotosíntesis?

Opciones: A) Carne B) Luz solar C) Viento D) Rocas E) Arena

Respuesta:

```
{
  "explicacion": "Las plantas utilizan la luz solar para producir su alimento mediante un proceso llamado fotosíntesis.",
  "respuesta": "B"
}
```

— EJEMPLO 2 —

Texto: La Revolución Industrial, iniciada en Gran Bretaña en el siglo XVIII, transformó la economía agraria en una dominada por la industria y la manufactura de maquinaria.

Pregunta: ¿Cuál fue el cambio principal provocado por la Revolución Industrial?

Opciones: A) El aumento de la agricultura manual E) La transformación hacia una economía industrial

Respuesta:

```
{
  "explicacion": "El cambio principal fue el paso de una economía agraria a una dominada por la industria y la manufactura de maquinaria.",
  "respuesta": "E"
}
```

Ahora, analiza el siguiente texto y responde a la pregunta con el mismo formato JSON:

Texto: {text}

Pregunta: {question}

Opciones:

{options}

Respuesta:

Figura A.3.: *User prompt* definido para la estrategia *few-shot*, que incorpora ejemplos resueltos para orientar al modelo sobre el formato de respuesta esperado, manteniendo el mismo *system prompt* que la estrategia *zero-shot* básica (figura A.1).

A. Prompts de la primera aproximación al problema

System prompt: Eres un profesor experto en resolución de exámenes de comprensión lectora en español. Analiza el texto con rigor académico y responde a la pregunta seleccionando la opción correcta.

Debes responder EXCLUSIVAMENTE con un objeto JSON válido, sin incluir explicaciones previas ni posteriores. El formato debe ser Estrictamente este:

```
{
  "razonamiento": "Aquí escribes todo el razonamiento necesario.",
  "explicacion": "Aquí escribes una breve explicación de la respuesta elegida basándote en el texto.",
  "respuesta": "Aquí escribes SOLAMENTE la letra de la opción correcta (A, B, C, D o E)."
```

User prompt:

Texto: {text}

Pregunta: {question}

Opciones:

{options}

Responde a la pregunta siguiendo estos PASOS:

1. Razona dentro del campo "razonamiento" para cada una de las opciones y descarta una a una aquellas que sean falsas basándote en la información del texto.
2. En el campo "explicacion", explica brevemente basándote en el texto por qué la opción final es la correcta.
3. Indica la opción (letra) correcta en el campo "respuesta" del JSON.

Figura A.4.: Prompts definidos para la estrategia que combina *role prompting* con *chain-of-thought*, obligando al modelo a descartar las opciones una a una antes de emitir su respuesta final.

B. Ejemplos de ejercicios para las tareas de selección multiple y emparejamiento

Este apéndice recoge ejemplos de exámenes reales del Instituto Cervantes para las dos subtarefas abordadas en este trabajo (*multiple choice* y *matching*), publicados por los organizadores en la página oficial de la competición¹, junto con su representación en formato JSON dentro del *dataset* IC-UNED-RC-ES (Peñas, Rodrigo, Fruns-Jiménez, Soria-Pastor, Moreno-Álvarez, Pérez García-Plaza et al. 2026). El objetivo es mostrar la estructura concreta de los datos con los que se ha trabajado, incluyendo los distintos tipos de ejercicio que puede haber dentro de cada subtarea, y facilitar así la comprensión de las soluciones descritas en la sección 3.4.


¹<https://sites.google.com/view/profe2026/submission-and-dev-data>

B.1. Ejercicio de selección múltiple

Usted va a leer un correo electrónico de Luisa a su amigo Javier. A continuación, tiene que leer las preguntas (de la 1 a la 5) y seleccionar la opción correcta (A, B, o C).

Tiene que marcar la opción elegida en la **Hoja de respuestas**.

0. ☐ A ☐ B ☐ C



The screenshot shows an email client window. On the left is a vertical toolbar with icons for 'Enviar' (Send) and 'Recibir' (Receive). The main area contains the email header and body. The header has fields for 'Para...' (To: Javier123@gmail.com), 'CC...' (Carbon Copy), 'CCO...' (Blind Carbon Copy), and 'Asunto:' (Subject: Saludos). The email body contains the following text:

Hola, Javier:

¿Qué tal? A ver si esta semana salimos y tomamos algo. Juan y yo vamos a jugar al tenis el miércoles a las cinco y luego al cine. ¿Quieres venir?

Ah, estoy muy contenta porque este año en la universidad puedo aprender chino por la tarde. Son dos días a la semana, de cinco a siete. Para mí es perfecto; es que por la mañana tengo que ir a trabajar al restaurante de mis tíos.

Oye, quiero alquilar una habitación de mi casa a una estudiante, ¿conoces a alguien? La habitación es grande, con todo nuevo: la cama, el armario, la mesa...

Otra cosa: el próximo mes es el cumpleaños de mi hermano y no sé qué comprarle. Quiero ir a tu tienda y comprarle algo de ropa: unos pantalones, una camisa... Si no le gustan, puede cambiarlos, ¿verdad?

Bueno, te dejo que voy a dar un paseo con el perro. Esta noche no quiero cocinar. Voy a llamar luego al restaurante chino donde vamos siempre para pedir allí la cena.

Nos vemos.

PREGUNTAS


1. Luisa le dice a Javier que esta semana va a...
 - a) tomar algo con Juan.
 - b) hacer deporte con un amigo.
 - c) ver una película a las cinco.
2. En el texto se dice que Luisa...
 - a) tiene un restaurante.
 - b) es profesora de idiomas.
 - c) va a estudiar por la tarde.
3. Luisa le dice a Javier que...
 - a) tiene un piso grande.
 - b) busca una compañera de piso.
 - c) va a comprar cosas para su piso.
4. Luisa le dice a Javier que...
 - a) va a ir a su tienda a comprar algo.
 - b) ya tiene el regalo de su hermano.
 - c) quiere cambiar un regalo que no le gusta.
5. ¿Qué va a hacer Luisa ahora?



A



B



C

Figura B.1.: Ejemplo de ejercicio de selección múltiple del conjunto IC-UNED-RC-ES, con el texto y las instrucciones (arriba) y las preguntas correspondientes, incluyendo una con opciones de respuesta en formato imagen (abajo).

ejemplo_multiple_choice.json

```
{
  "level": "A1",
  "examId": "A1_2020-07-01",
  "exercises": [
    {
      "exerciseID": "A1_2020-07-01_E1",
      "type": "multiple-choice",
      "instructions": "Usted va a leer un correo electrónico de Luisa a su
        amigo Javier. A continuación, tiene que leer las preguntas (de la 1
```

B. Ejemplos de ejercicios para las tareas de selección múltiple y emparejamiento

```
a la 5) y seleccionar la opción correcta (A, B, o C).\nTiene que
marcar la opción elegida en la Hoja de respuestas.\n",
"num-questions": 5,
"exercise": {
  "text": "email para: Javier123@gmail.com\nAsunto: Saludos\nHola,
Javier:\n¿Qué tal? A ver si esta semana salimos y tomamos algo.
Juan y yo vamos a jugar al tenis el miércoles a las cinco y luego
al cine. ¿Quieres venir?\nAh, estoy muy contenta porque este año
en la universidad puedo aprender chino por la tarde. Son dos días
a la semana, de cinco a siete. Para mí es perfecto; es que por la
mañana tengo que ir a trabajar al restaurante de mis tíos.\nOye,
quiero alquilar una habitación de mi casa a una estudiante, ¿
conoces a alguien? La habitación es grande, con todo nuevo: la
cama, el armario, la mesa...\nOtra cosa: el próximo mes es el
cumpleaños de mi hermano y no sé qué comprarle. Quiero\nir a tu
tienda y comprarle algo de ropa: unos pantalones, una camisa... Si
no le gustan, puede cambiarlos, ¿verdad?\nBueno, te dejo que voy
a dar un paseo con el perro. Esta noche no quiero cocinar. Voy a
llamar luego al restaurante chino donde vamos siempre para pedir
allí la cena.\nNos vemos.\nLuisa",
"image-path": "",
"questions": [
  {
    "questionId": "A1_2020-07-01_E1_Q1",
    "text": "Luisa le dice a Javier que esta semana va a...",
    "image-path": "",
    "correct-option": "B",
    "options": [
      { "optionId": "A", "text": "tomar algo con Juan.", "image-path":
        "" },
      { "optionId": "B", "text": "hacer deporte con un amigo.", "image-
        path": "" },
      { "optionId": "C", "text": "ver una película a las cinco.", "
        image-path": "" }
    ]
  },
  {
    "questionId": "A1_2020-07-01_E1_Q2",
    "text": "En el texto se dice que Luisa...",
    "image-path": "",
    "correct-option": "C",
    "options": [
      { "optionId": "A", "text": "tiene un restaurante.", "image-path
        ": "" },
      { "optionId": "B", "text": "es profesora de idiomas.", "image-
        path": "" },
      { "optionId": "C", "text": "va a estudiar por la tarde.", "image
        -path": "" }
    ]
  },
  {
    "questionId": "A1_2020-07-01_E1_Q3",
    "text": "Luisa le dice a Javier que...",
    "image-path": "",
    "correct-option": "B",
    "options": [
      { "optionId": "A", "text": "tiene un piso grande.", "image-path
        ": "" },
      { "optionId": "B", "text": "busca una compa\u00f1era de piso.",
        "image-path": "" },
      { "optionId": "C", "text": "va a comprar cosas para su piso.", "
        image-path": "" }
    ]
  }
],
{
```

B. Ejemplos de ejercicios para las tareas de selección múltiple y emparejamiento

```
    "questionId": "A1_2020-07-01_E1_Q4",
    "text": "Luisa le dice a Javier que...",
    "image-path": "",
    "correct-option": "A",
    "options": [
      { "optionId": "A", "text": "va a ir a su tienda a comprar algo",
        "image-path": "" },
      { "optionId": "B", "text": "ya tiene el regalo de su hermano.",
        "image-path": "" },
      { "optionId": "C", "text": "quiere cambiar un regalo que no le gusta.",
        "image-path": "" }
    ]
  },
  {
    "questionId": "A1_2020-07-01_E1_Q5",
    "text": "¿Que va a hacer Luisa ahora?",
    "image-path": "",
    "correct-option": "C",
    "options": [
      { "optionId": "A", "text": "", "image-path": "img/A1_2020-07-01_E1_Q5_A.jpg" },
      { "optionId": "B", "text": "", "image-path": "img/A1_2020-07-01_E1_Q5_B.jpg" },
      { "optionId": "C", "text": "", "image-path": "img/A1_2020-07-01_E1_Q5_C.jpg" }
    ]
  }
]
}
```

Figura B.2.: Archivo JSON correspondiente al ejercicio de selección múltiple de la figura B.1, donde puede verse que la pregunta con imágenes representa cada opción de respuesta mediante una referencia al fichero correspondiente en lugar de texto.

B.2. Ejercicios de emparejamiento

INSTRUCCIONES

Usted va a leer tres textos de tres españolas que hablan de su experiencia de trabajo fuera de España. Relacione las preguntas (14 - 19) con los textos (A, B o C).

Marque las opciones elegidas en la **Hoja de respuestas**.

PREGUNTAS

		A. ALICIA	B. EVA	C. SILVIA
14.	¿Quién no necesita hablar el idioma del país en su trabajo?			
15.	¿Quién no tenía que pagar el alojamiento?			
16.	¿Quién tenía un amigo que le habló de ese país?			
17.	¿A quién le presentaron a una persona que le dio trabajo en ese país?			
18.	¿Quién fue a ese país para aprender el idioma?			
19.	¿Quién conoció a su pareja en ese país?			

TEXTOS

A. ALICIA



Hace tres años, mi hermana me habló de unos amigos suyos españoles que estaban en Amsterdam y querían una chica para cuidar a sus dos hijos. No lo pensé y me fui a Holanda. Me pagaban muy poco pero comía y dormía gratis. Los primeros meses no tenía amigos porque no hablaba el idioma, solo un poco de inglés. Por las mañanas iba a clases de holandés e inglés y allí conocí a un chico que era profesor de la escuela. Dos años más tarde, nos casamos y tuvimos un hijo. Ahora hablo holandés y trabajo en una tienda de ropa en Amsterdam.

B. EVA



Yo vine a Suecia hace un año. Soy informática y tenía trabajo en España en una oficina de ayuda internacional, pero solo para tres meses. Ya llevaba un tiempo pensando en salir fuera del país para trabajar pero no sabía dónde. Mi amigo Lucas me ayudó a elegir Suecia porque él vivió aquí y me contó mucho de este país. Busqué trabajo por internet, pero solo miraba las ofertas donde no pedían sueco porque yo solo hablo inglés. Tuve mucha suerte y encontré un trabajo en otra empresa parecida donde hay personas de muchos países y solo se habla inglés. Ahora quiero empezar a estudiar sueco.

C. SILVIA



Yo estudié para ser cocinera y sabía que quería irme a conocer otros países. Quería estudiar inglés y me fui a EE.UU. a una escuela en verano. Fue una buena experiencia porque cambió toda mi vida. El padre de un compañero, cuando se enteró de que yo era cocinera, me presentó a un amigo suyo que tenía un restaurante muy famoso en Chicago y me preguntó si quería trabajar en su restaurante. Fue difícil tener el permiso de trabajo pero cuando me lo dieron, empecé a trabajar y aprendí muchísimo. Hoy tengo dos restaurantes en EE.UU.

Figura B.3.: Ejemplo de ejercicio de emparejamiento del conjunto IC-UNED-RC-ES, con más preguntas (arriba) que textos (abajo), lo que permite que un mismo texto pueda responder a varias de las preguntas planteadas.

ejemplo_matching_tipo_1.json

```
{
  "level": "A2",
  "examId": "A2_modelo-0",
  "exercises": [
    {
      "exerciseID": "A2_modelo-0_E3",
      "type": "matching",
      "instructions": "Usted va a leer tres textos de tres espanolas que hablan de su experiencia de trabajo fuera de Espana. Relacione las preguntas (14 - 19) con los textos (A, B o C).\nMarque las opciones elegidas en la Hoja de respuestas.",
      "num-questions": 6,
      "exercise": {
        "set1": [
```

B. Ejemplos de ejercicios para las tareas de selección múltiple y emparejamiento

```
{
  "optionId": "A",
  "text": "Alicia\nHace tres años, mi hermana me habla de unos
amigos suyos españoles que estaban en Amsterdam y querían una
chica para cuidar a sus dos hijos. No lo pensé y me fui a
Holanda. Me pagaban muy poco pero comía y dormía gratis. Los
primeros meses no tenía amigos porque no hablaba el idioma,
solo un poco de inglés. Por las mañanas iba a clases de
holandés e inglés y allí conocí a un chico que era profesor de
la escuela. Dos años más tarde, nos casamos y tuvimos un hijo
. Ahora hablo holandés y trabajo en una tienda de ropa en
Amsterdam.",
  "image-path": "img/A2_modelo-0_E3_A.jpg"
},
{
  "optionId": "B",
  "text": "Eva\nYo vine a Suecia hace un año. Soy informática y
tenía trabajo en España en una oficina de ayuda internacional,
pero solo para tres meses. Ya llevaba un tiempo pensando en
salir fuera del país para trabajar pero no sabía donde. Mi
amigo Lucas me ayudó a elegir Suecia porque él vivió aquí y me
contó mucho de este país. Busqué trabajo por internet, pero
solo miraba las ofertas donde no pedían sueco porque yo solo
hablo inglés. Tuve mucha suerte y encontré un trabajo en otra
empresa parecida donde hay personas de muchos países y solo se
habla inglés. Ahora quiero empezar a estudiar sueco.",
  "image-path": "img/A2_modelo-0_E3_B.jpg"
},
{
  "optionId": "C",
  "text": "Silvia\nYo estudie para ser cocinera y sabía que quería
irme a conocer otros países. Quería estudiar inglés y me fui a
EE.UU. a una escuela en verano. Fue una buena experiencia
porque cambió toda mi vida. El padre de un compañero, cuando
se enteró de que yo era cocinera, me presentó a un amigo suyo
que tenía un restaurante muy famoso en Chicago y me preguntó
si quería trabajar en su restaurante. Fue difícil tener el
permiso de trabajo pero cuando me lo dieron, empecé a trabajar
y aprendí muchísimo. Hoy tengo dos restaurantes en EE.UU.",
  "image-path": "img/A2_modelo-0_E3_C.jpg"
}
],
"set2": [
  {
    "optionId": 14,
    "text": "?Quién no necesita hablar el idioma del país en su
trabajo?",
    "image-path": "",
    "set1-correct-match": "B"
  },
  {
    "optionId": 15,
    "text": "?Quién no tenía que pagar el alojamiento?",
    "image-path": "",
    "set1-correct-match": "A"
  },
  {
    "optionId": 16,
    "text": "?Quién tenía un amigo que le habla de ese país?",
    "image-path": "",
    "set1-correct-match": "B"
  },
  {
    "optionId": 17,
    "text": "?A quién le presentaron a una persona que le dio trabajo
```

B. Ejemplos de ejercicios para las tareas de selección multiple y emparejamiento

```
        "en ese pais?",
        "image-path": "",
        "set1-correct-match": "C"
    },
    {
        "optionId": 18,
        "text": "?Quien fue a ese pais para aprender el idioma?",
        "image-path": "",
        "set1-correct-match": "C"
    },
    {
        "optionId": 19,
        "text": "?Quien conocio a su pareja en ese pais?",
        "image-path": "",
        "set1-correct-match": "A"
    }
]
}
```

Figura B.4.: Archivo JSON correspondiente al ejercicio de emparejamiento de la figura B.3, donde puede verse cómo una misma respuesta del primer conjunto puede repetirse y asociarse a varias preguntas del segundo.

B. Ejemplos de ejercicios para las tareas de selección múltiple y emparejamiento

INSTRUCCIONES

Usted va a leer una información sobre los cines de la ciudad. Tiene que relacionar los anuncios (A - J) con los textos (del 12 al 17). Hay diez anuncios, incluido el ejemplo. Seleccione seis.

Tiene que marcar la opción elegida en la **Hoja de respuestas**.

Ejemplo:

Texto 0: Me gusta mucho el arte, especialmente la pintura de artistas modernos.

La opción correcta es la letra **A**.

0. ☒ ☐ B ☐ C ☐ D ☐ E ☐ F ☐ G ☐ H ☐ I ☐ J

A



Cine Gran Vía

Cine de verano:
Martes, 22
Hora: 18.30 h.
Película: *Picasso*
Exposición de fotografías: Picasso y el color.
Precio: 4 euros
Horario: 20.30 h.

B



Cine Bretón

Octubre: Cine argentino.
El programa empieza con una película que cuenta la historia de cuatro policías que viven en Buenos Aires.
Horario: 20 h.

C



Cine Cervantes

Los martes y los jueves, las películas son en versión original: inglés, francés, alemán y chino.
Horario: 19.30 h.
Venta de entradas: www.cinecervantes.es

D



Cine Asturias

Presentación de la nueva película de Javier López. Una divertida historia que cuenta la vida de tres jóvenes muy simpáticos.
Horario: 20 h y 22.30 h.


E



Cine Alcalá

La Escuela de Cine de Madrid presenta seis películas de los estudiantes del curso superior.
Información: www.cinemadrid.es

F



Cine Ayala

El próximo viernes podemos ver la película musical, *Bailar toda la noche*. Los actores cantan y bailan durante dos horas.
Para toda la familia.
Horario: 17.30 h - 19.30 h.

G



Cine Ramblas

De lunes a jueves:
Precios especiales para estudiantes mayores de 18 años.
Es necesario presentar el carné.
Horario: 19 h.
Precio: 2 euros.

H



Cine Buñuel

Información:
Todos los fines de semana, a las 11 h, películas para los más pequeños de la casa.
Precios:
De 2 a 13 años: 2 euros.
De 14 a 18 años: 3 euros.
Mayores de 18 años: 5 euros.

I



Cine Paraíso

Películas clásicas en blanco y negro.
Este domingo podemos ver la historia de amor de dos personas de diferente nacionalidad.
Precio: 4 euros.

J



Cine Trueba

Programa especial de películas sobre la naturaleza.
El próximo miércoles, *Los espacios naturales de Hispanoamérica*, una película de Chile.
Horario: 18 h.

B. Ejemplos de ejercicios para las tareas de selección múltiple y emparejamiento

	TEXTOS		
0.	Me gusta mucho el arte, especialmente la pintura de artistas modernos.		A
12.	Normalmente, mis amigas y yo vamos al cine el miércoles porque es más barato.		
13.	El sábado por la mañana, queremos ir al cine con nuestros hijos porque tenemos tiempo libre.		
14.	En vacaciones vamos a la montaña para caminar y hacer fotografías de los árboles, de las plantas, del campo...		
15.	Yo prefiero ver una historia divertida, para reír; las películas de miedo no me gustan nada.		
16.	Estudio en la Escuela Oficial de Idiomas. Siempre voy al cine para ver películas en otras lenguas.		
17.	Me gusta mucho cantar, escuchar música y tocar el piano.		

Figura B.5.: Ejemplo de ejercicio de emparejamiento del conjunto IC-UNED-RC-ES, con más textos en el primer conjunto (arriba) que en el segundo (abajo), lo que da lugar a la presencia de distractores. Algunos de los textos incluyen además imágenes que no siempre aportan información relevante para resolver el ejercicio.

B. Ejemplos de ejercicios para las tareas de selección multiple y emparejamiento

```
ejemplo_matching_tipo_2.json
```

```
{
  "level": "A1",
  "examId": "A1_2019-11-23",
  "exercises": [
    {
      "exerciseID": "A1_2019-11-23_E3",
      "type": "matching",
      "instructions": "Usted va a leer una informacion sobre los cines de la ciudad. Tiene que relacionar los anuncios (A - J)\ncon los textos ( del 12 al 17). Hay diez anuncios, incluido el ejemplo. Seleccione seis.\n\nTiene que marcar la opcion elegida en la Hoja de respuestas .",
      "num-questions": 7,
      "exercise": {
        "set1": [
          {
            "optionId": "A",
            "text": "Cine Gran Via\nCine de verano: Martes. 22 Hora: 18.30 h.\nPel\u00edcula: Picasso Exposicion de fotografias: Picasso y el color.\nPrecio: 4 euros\nHorario: 20.30 h.",
            "image-path": ""
          },
          {
            "optionId": "B",
            "text": "Cine Breton\nOctubre: Cine argentino. El programa empieza con una pelicula que cuenta la historia de\ncuatro policias que viven en Buenos Aires.\nHorario: 20 h.",
            "image-path": ""
          },
          {
            "optionId": "C",
            "text": "Cine Cervantes\nLos martes y los jueves, las peliculas son en version original: ingles, frances, aleman y chino.\nHorario: 19.30 h. Venta de entradas: www.cinecervantes.es",
            "image-path": ""
          },
          {
            "optionId": "D",
            "text": "Cine Asturias\nPresentacion de la nueva pelicula de Javier Lopez. Una divertida historia que\ncuenta la vida de tres jovenes muy simpaticos. Horario: 20 h y 22.30 h",
            "image-path": ""
          },
          {
            "optionId": "E",
            "text": "Cine Alcala\nLa Escuela de Cine de Madrid presenta seis peliculas de los estudiantes del curso superior.\nInformacion: www.cinemadrid.es",
            "image-path": ""
          },
          {
            "optionId": "F",
            "text": "Cine Ayala\n\nEl proximo viernes podemos ver la pelicula musical, Bailar toda la noche. Los actores cantan y bailan durante dos horas. Para toda la familia. Horario: 17.30 h - 19.30 h.",
            "image-path": ""
          },
          {
            "optionId": "G",
            "text": "Cine Ramblas\nDe lunes a jueves: Precios especiales para estudiantes mayores de 18 anos. Es necesario presentar el
```

B. Ejemplos de ejercicios para las tareas de selección múltiple y emparejamiento

```
        carne.\nHorario: 19 h.\nPrecio: 2 euros.",
    "image-path": ""
  },
  {
    "optionId": "H",
    "text": "Cine Bunuel\nInformacion:\nTodos los fines de semana, a
    las 11 h, películas para los mas pequeños de la casa. Precios
    :\nDe 2 a 13 años: 2 euros.\nDe 14 a 18 años: 3 euros.\n
    nMayores de 18 años: 5 euros.",
    "image-path": ""
  },
  {
    "optionId": "I",
    "text": "Cine Paraiso\nPelículas clásicas en blanco y negro.\nEste
    domingo podemos ver la historia de amor de dos personas de
    diferente nacionalidad. Precio: 4 euros.",
    "image-path": ""
  },
  {
    "optionId": "J",
    "text": "Cine Trueba\nPrograma especial de películas sobre la
    naturaleza.\nEl próximo miércoles, Los espacios naturales de
    Hispanoamérica, una película de Chile. Horario: 18 h.",
    "image-path": ""
  }
],
"set2": [
  {
    "optionId": 0,
    "text": "Me gusta mucho el arte, especialmente la pintura de
    artistas modernos.",
    "image-path": "img/A1_2019-11-23_E3_set2_0.jpg",
    "set1-correct-match": "A"
  },
  {
    "optionId": 12,
    "text": "Normalmente, mis amigas y yo vamos al cine el miércoles
    porque es mas barato.",
    "image-path": "img/A1_2019-11-23_E3_set2_12.jpg",
    "set1-correct-match": "G"
  },
  {
    "optionId": 13,
    "text": "El sábado por la mañana, queremos ir al cine con nuestros
    hijos porque tenemos tiempo libre.",
    "image-path": "img/A1_2019-11-23_E3_set2_13.jpg",
    "set1-correct-match": "H"
  },
  {
    "optionId": 14,
    "text": "En vacaciones vamos a la montaña para caminar y hacer
    fotografías de los árboles, de las plantas, del campo...",
    "image-path": "img/A1_2019-11-23_E3_set2_14.jpg",
    "set1-correct-match": "J"
  },
  {
    "optionId": 15,
    "text": "Yo prefiero ver una historia divertida, para reír; las
    películas de miedo no me gustan nada.",
    "image-path": "img/A1_2019-11-23_E3_set2_15.jpg",
    "set1-correct-match": "D"
  },
  {
    "optionId": 16,
    "text": "Estudio en la Escuela Oficial de Idiomas. Siempre voy al
```

B. Ejemplos de ejercicios para las tareas de selección múltiple y emparejamiento

```
        "cine para ver películas en otras lenguas.",
        "image-path": "img/A1_2019-11-23_E3_set2_16.jpg",
        "set1-correct-match": "C"
    },
    {
        "optionId": 17,
        "text": "Me gusta mucho cantar, escuchar música y tocar el piano",
        "image-path": "img/A1_2019-11-23_E3_set2_17.jpg",
        "set1-correct-match": "F"
    }
]
}
```

Figura B.6.: Archivo JSON correspondiente al ejercicio de emparejamiento de la figura B.5, donde puede verse cómo se representan los textos adicionales que actúan como distractores y las imágenes asociadas a algunos de los textos.

C. Repositorio de código

Este apéndice contiene el enlace al repositorio donde se encuentra disponible públicamente todo el código desarrollado a lo largo de este trabajo, incluyendo todas las soluciones implementadas, los conjuntos de datos utilizados para evaluarlas y los resultados obtenidos con cada una de ellas.

Repositorio de GitHub:

<https://github.com/NILGroup/TFM2526-ExamenesComprensionLectora>